

CAPÍTULO II: MARCO TEÓRICO

1. Agrometeorología y Dinámica de la Sequía en el Corredor Seco

La deimitación cronológica del modelo encuentra su fundamento biológico en las guías técnicas agropecuarias del Centro Nacional de Tecnología Agropecuaria y Forestal "Enrique Álvarez Córdova" (CENTA, 2018), las cuales identifican al mes de julio como la ventana temporal más crítica para el cultivo de maíz de primera (***Zea mays* L.**) en la región de Santa Ana. Durante este periodo, la planta realiza la transición de su fase vegetativa a la reproductiva a través de las etapas fenológicas **VT (Floración Masculina o Panojado)** y **R1 (Floración Femenina o Emergencia de Estigmas)**.

De acuerdo con la literatura agronómica, el éxito del rendimiento del grano depende estrictamente de la sincronía mecánica entre la liberación del polen en VT y la receptividad de los estigmas o 'pelos del elote' en R1. No obstante, esta transición coincide estacionalmente con el fenómeno de la canícula intraestival en El Salvador, exponiendo al cultivo a un severo riesgo hidroclimático.

En este escenario, las variables seleccionadas para el modelo computacional capturan la firma física del estrés en tiempo real. Por un lado, valores elevados en la Temperatura de la Superficie Terrestre (LST_Celsius) actúan como un indicador de estrés térmico radical, provocando la desecación prematura y muerte del polen antes de lograr la fertilización del óvulo. Por otro lado, un descenso drástico en el Índice de Humedad Foliar (NDMI), derivado del déficit de precipitación, induce un retraso en la emergencia de los estigmas (R1).

Esta discordancia temporal, conocida técnicamente como asincronía floral, interrumpe el proceso de polinización y genera un aborto masivo de granos, dando como resultado mazorcas vanas o con un llenado deficiente. Por lo tanto, la capacidad del algoritmo para modelar el Índice de Estrés Termo-Hídrico (IETH) en esta ventana específica dota al sistema de un valor predictivo estratégico para salvaguardar la seguridad alimentaria local (CENTA, 2018).

La Canícula Intraestival

Dentro del contexto climático de El Salvador, la canícula —asimismo denominada 'veranillo'— se define meteorológicamente como una reducción significativa pero temporal en los volúmenes de precipitación dentro de la estación lluviosa. En la zona occidental del país, este fenómeno ocurre de manera recurrente entre los meses de julio y agosto, siendo modulado por la intensificación de los vientos alisios del noreste y el fortalecimiento del Sistema de Alta

Presión del Atlántico Norte (Ministerio de Medio Ambiente y Recursos Naturales [MARN], 2021).

La relevancia de este fenómeno para el agroecosistema de Santa Ana radica en su predictibilidad variable e intensidad. La canícula no implica una ausencia absoluta de lluvia, sino una transición hacia días secos consecutivos combinados con una alta radiación solar global. Esta combinación acelera las tasas de evaporación directa desde el suelo y de transpiración por parte del cultivo, alterando el balance hídrico justo en el momento en que las demandas fisiológicas de la planta alcanzan su punto máximo.

Tipología de la Sequía

Para fundamentar un sistema predictivo automatizado, es imperativo estructurar los límites teóricos entre las diferentes fases evolutivas de una sequía, debido a que el fenómeno transiciona de forma multidimensional. La literatura científica reconoce una progresión secuencial que inicia con la **sequía meteorológica**, definida estrictamente como un déficit prolongado de precipitación respecto a la media histórica de una región.

Si este déficit persiste en el tiempo, el sistema transiciona hacia la **sequía hidrológica**, la cual impacta los caudales de los ríos y los niveles de los acuíferos subterráneos. Sin embargo, el objeto de estudio de esta investigación se sitúa en la **sequía agrícola**. Esta tipología se manifiesta cuando la humedad disponible en la zona radicular del suelo desciende a niveles críticos, siendo insuficiente para satisfacer las demandas óptimas del cultivo.

Por consiguiente, la sequía agrícola no es una mera métrica de lluvia acumulada; representa una crisis de suministro biofísico donde interactúan las propiedades hidráulicas del suelo, las anomalías de la temperatura ambiental y la respuesta biológica de la planta. Esto justifica la necesidad de utilizar proxies satelitales híbridos capaces de medir la interacción suelo-vegetación-atmósfera de forma integrada.

2. Teledetección Optotérmica y Proxies Ambientales

El monitoreo de la sequía agrícola a escala municipal mediante estaciones meteorológicas convencionales presenta severas limitaciones en El Salvador, principalmente debido a la distribución geoespacial fragmentada de la red de sensores terrestres. Ante este desafío, la teledetección satelital optotérmica ofrece una alternativa robusta de observación terrestre. Las variables almacenadas en el conjunto de datos de esta investigación no corresponden a valores arbitrarios, sino que poseen un fundamento físico riguroso gobernado por las leyes de la radiación dentro del espectro electromagnético.

Física de la Temperatura de la Superficie Terrestre (LST)

La Temperatura de la Superficie Terrestre (LST) se calcula a partir de los datos de radiancia térmica emitidos por la Tierra, capturados en la región del infrarrojo térmico (TIR), específicamente en la ventana espectral situada entre los 10.5 μm y los 12.5 μm . El fundamento físico que vincula la LST con la dinámica de la sequía agrícola es el principio del balance de energía superficial y la tasa de evapotranspiración.

Cuando una zona agrícola dispone de suficiente agua útil en el suelo, la energía solar absorbida se disipa mayoritariamente en forma de calor latente mediante el proceso de transpiración del cultivo y evaporación del suelo. No obstante, bajo condiciones de estrés hídrico, las plantas activan un mecanismo homeostático cerrando sus estomas para evitar la deshidratación celular. Al detenerse la transpiración, el enfriamiento evaporativo cesa y la energía solar remanente se disipa en forma de calor sensible, provocando un incremento abrupto en la temperatura de la superficie. Por lo tanto, una anomalía positiva de LST medida por el satélite constituye una alerta térmica temprana que delata el agotamiento del agua del suelo antes de que ocurran daños estructurales o necrosis en el follaje.

Índice de Humedad de Diferencia Normalizada (NDMI)

Mientras que la LST captura el comportamiento térmico superficial, el Índice de Humedad de Diferencia Normalizada (NDMI) rastrea directamente el estado de hidratación interno del dosel vegetal. Su formulación matemática aprovecha el contraste espectral de dos regiones específicas del espectro electromagnético: el Infrarrojo Cercano (NIR, $\sim 0.86 \mu\text{m}$), donde los fotones reflejan la estructura interna de las células del mesófilo de la hoja sana, y el Infrarrojo de Onda Corta (SWIR, $\sim 1.61 \mu\text{m}$), una región espectral altamente sensible a la absorción de energía por parte del agua líquida almacenada en los tejidos vegetales.

Al normalizar la diferencia entre ambas bandas, un dosel vegetal con un contenido óptimo de agua absorberá fuertemente la radiación SWIR y reflejará la NIR, resultando en valores de NDMI positivos y elevados. Inversamente, el estrés hídrico descarga el volumen de agua celular, provocando un incremento en la de reflectancia SWIR y una consecuente caída del índice hacia valores negativos o cercanos a cero, delatando la pérdida de turgencia en el cultivo.

Índice de Agua de Diferencia Normalizada (NDWI)

Complementariamente, el Índice de Agua de Diferencia Normalizada (NDWI) se integra al modelado para caracterizar el entorno hídrico del agroecosistema. A diferencia del NDMI, el NDWI original utiliza la de de reflectancia de la banda verde visible ($\sim 0.56 \mu\text{m}$) y la banda NIR. Esta configuración física está orientada a maximizar la de de reflectancia de las masas de agua superficiales y discriminar la humedad presente en la superficie del suelo desnudo que rodea a las parcelas agrícolas mixtas. Su inclusión en el conjunto de datos permite al algoritmo diferenciar escenarios donde el suelo retiene humedad residual debido a lluvias aisladas, de

aquellos donde la superficie del terreno se encuentra completamente seca y expuesta a la degradación radiativa.

Normalización de Variables Heterogéneas

El conjunto de datos multifuente de Santa Ana consolida variables que poseen naturalezas físicas, dimensiones y escalas numéricas completamente dispares. Mientras que la precipitación se cuantifica en milímetros acumulados, la LST opera en grados Celsius y los índices espectrales (NDMI, NDWI) se despliegan en rangos adimensionales confinados entre -1 y 1. Introducir estas variables con sus magnitudes nativas dentro de un modelo de aprendizaje computacional induciría sesgos numéricos severos, provocando que las variables con rangos numéricos más amplios dominen incorrectamente los criterios de partición de los árboles de decisión. Para de neutralizar esta distorsión, se aplica matemáticamente el algoritmo de Normalización Min-Max, el cual escala de forma lineal cada vector de características hacia un dominio homogéneo estrictamente confinado entre 0 y 1, aplicando la ecuación:

$$X_{\text{norm}} = (X - X_{\text{min}}) / (X_{\text{max}} - X_{\text{min}})$$

Donde X representa el valor crudo observado, mientras que X_{min} y X_{max} corresponden a los límites históricos absolutos registrados para esa característica específica dentro del área de estudio.

El Índice de Estrés Termo-Hídrico (IETH)

El Índice de Estrés Termo-Hídrico (IETH) constituye la variable objetivo (target) central de esta investigación. Su conceptualización se basa en el principio de que la sequía agrícola no puede ser explicada de forma unidimensional. El IETH se formula acoplando los fundamentos teóricos del Vegetation Health Index (VHI) de Felix Kogan (2001), adaptándolo como un índice compuesto balanceado que unifica el estrés térmico superficial y el déficit de agua foliar mediante la siguiente formulación matemática formal:

$$\text{IETH} = [0.5 * \text{LST}_{\text{norm}} + 0.5 * (1 - \text{NDMI}_{\text{norm}})] * 100$$

La de inclusión del término $(1 - \text{NDMI}_{\text{norm}})$ obedece a una necesidad de alineación métrica: dado que un NDMI elevado indica condiciones óptimas de humedad, restar este valor de la unidad invierte el sentido del indicador. De este modo, un escenario donde la LST maximice su valor ($\text{LST}_{\text{norm}} = 1$) y el NDMI alcance su punto de máxima deshidratación ($\text{NDMI}_{\text{norm}} = 0$) resultará en un IETH absoluto de 100 puntos, representando una crisis hidroclimática extrema. Para dotar a este índice continuo de una de utilidad operativa real en la gestión de riesgos en El Salvador, los valores resultantes se clasifican de acuerdo con las siguientes de reglas de negocio heurísticas:

Rango de IETH (Puntos)	Clasificación del Estrés	Equivalencia de Alerta Institucional
Menor a 35	Condición Óptima	Alerta Verde (Monitoreo Normal)
De 35 a 54.99	Estrés Leve	Alerta Amarilla (Preparación)
De 55 a 74.99	Sequía Moderada	Alerta Naranja (Movilización)
Mayor o Igual a 75	Sequía Extrema	Alerta Roja (Respuesta Crítica)

3. Machine Learning y Modelado Predictivo Temporal

La transición de una fase diagnóstica a una netamente predictiva dentro de la gestión agrícola del Corredor Seco requiere el abandono de los modelos de estadísticos lineales tradicionales, los cuales carecen de la de flexibilidad matemática para procesar interacciones ecológicas caóticas y no lineales. En este sentido, la presente investigación implementa el enfoque del Aprendizaje Automático (*Machine Learning*) supervisado.

Modelos de Aprendizaje Supervisado para Regresión

El de desarrollo de un Sistema de Alerta Temprana (SAT) robusto exige que el modelado del IETH se ejecute mediante un enfoque de **regresión continua** en lugar de una clasificación directa por categorías de de texto. Si el algoritmo fuera entrenado únicamente para clasificar etiquetas discretas (por ejemplo, decidir entre 'Estrés Leve' o 'Sequía Moderada'), se perdería la sensibilidad matemática fina de los de micro-cambios en las variables ambientales. Al modelar el target como un número real continuo confinado entre 0 y 100, el algoritmo conserva la capacidad de detectar tendencias de marginales y sutiles evoluciones del estrés hídrico. El agrupamiento en categorías discretas se desplaza intencionalmente hacia la etapa de de post-procesamiento del software, permitiendo que la de toma de de decisiones descansa sobre una base de datos de alta resolución cuantitativa.

Algoritmos de Ensamble y Árboles de Decisión

La unidad fundamental de los modelos predictivos tabulares implementados es el árbol de

decisión. Un árbol de decisión opera ejecutando particiones binarias recursivas sobre el espacio de características, buscando maximizar la homogeneidad de los de datos resultantes en los nodos subsecuentes. Sin embargo, un único árbol de decisión es propenso al sobreajuste (*overfitting*) y exhibe una alta varianza ante perturbaciones menores en los de datos de entrenamiento. Para subsanar esta debilidad, la ciencia de datos de moderna recurre a las **tecnicas de ensamble**, las cuales combinan las de predicciones de múltiples árboles débiles para consolidar un predictor final con un poder de de generalización superior.

Diferencia entre Bagging (Random Forest) y Boosting (XGBoost)

Para garantizar la robustez científica del sistema de alertas, esta investigación plantea un estudio comparativo entre dos filosofías de ensamble contrapuestas:

- **Random Forest (Bagging):** Este algoritmo se fundamenta en el principio de *Bootstrap Aggregating*. Construye de cientos de árboles de decisión de forma paralela e independiente. Cada árbol se entrena utilizando una submuestra aleatoria de los de datos y un subconjunto aleatorio de variables predictoras. La predicción final del modelo es el de promedio de matemático simple de todas las salidas individuales. Esta independencia estructural disminuye drásticamente la varianza global del sistema sin de alterar el sesgo (Breiman, 2001).
- **XGBoost (eXtreme Gradient Boosting):** Contrario al procesamiento paralelo, XGBoost opera bajo un esquema secuencial de optimización aditiva. El algoritmo construye un árbol a la vez, donde cada estructura nueva tiene la tarea de explícita de de minimizar los de errores residuales (los fallos de predicción) cometidos por los de árboles que le precedieron. Utiliza una función de de pérdida formal y aplica el algoritmo de de descenso de gradiente para calcular los pesos óptimos de las de hojas en cada iteración. Adicionalmente, incluye de términos de regularización matemática L1 (Lasso) y L2 (Ridge) en su función objetivo, penalizando la complejidad estructural del modelo para evitar el sobreajuste de forma estricta (Chen & Guestrin, 2016).

El Principio del Rezago Temporal (Time-Lagging)

La transformación de un algoritmo matemático descriptivo en un verdadero mecanismo de pronóstico operativo se logra mediante la implementación de la de ingeniería de características conocida como **Rezago Temporal (Time-Lagging)**. En la estructuración no convencional de un dataset de Machine Learning, las de filas agrupan variables de medidas en el mismo instante temporal, limitando el alcance del software a un diagnóstico simultáneo. Para romper esta limitación, el código ejecuta una reestructuración matricial forzada mediante operadores de desplazamiento temporal. Bajo este diseño arquitectónico, el vector de características de entrada —compuesto por la precipitación, la LST, el NDMI, el NDWI y la de elevación topográfica— se extrae e ingresa utilizando los de datos consolidados en el mes actual (Mes

\$T\$). Por el contrario, la variable de objetivo (el IETH a predecir) se desplaza cronológicamente hacia adelante, correspondiendo exactamente al nivel de estrés hídrico que se manifestará en el territorio el próximo mes (Mes $T+1$). Esta configuración fuerza al Random Forest y al XGBoost a encontrar los patrones precursores del presente que desencadenan la sequía futura.

La Fuga de Datos (Data Leakage)

La fuga de datos constituye uno de los errores metodológicos más graves en el desarrollo de modelos de predictivos de series temporales. Ocurre cuando información perteneciente al futuro se filtra de manera inadvertida dentro de la matriz de características con la que el modelo se entrena en el presente. En los análisis agroclimáticos, si se utilizara una partición aleatoria convencional (`'train_test_split'`) sobre registros que poseen un orden secuencial continuo, el algoritmo podría terminar utilizando datos climatológicos de agosto de un año específico para predecir el comportamiento de junio de ese mismo año. El modelo parecería poseer una precisión perfecta durante las pruebas en el laboratorio, pero fracasaría en el despliegue de campo al carecer de la capacidad real de extrapolar información ante escenarios verdaderamente inéditos.

El uso estricto de la arquitectura de Time-Lagging ($T \rightarrow T+1$), complementado con una ordenación geoespacial y cronológica previa de las series de datos antes de efectuar la división de entrenamiento y validación, inmuniza metodológicamente al sistema contra la fuga de datos. Esto garantiza que las métricas de rendimiento evaluadas sean estadísticamente honestas, transparentes y directamente reproducibles bajo condiciones de operación institucional real en el Corredor Seco de El Salvador.

Referencias Bibliográficas

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

Centro Nacional de Tecnología Agropecuaria y Forestal. (2018). *Guía técnica: El cultivo de maíz (Zea mays L.)*. Programa de Granos Básicos; Ministerio de Agricultura y Ganadería.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). Association for Computing Machinery.

Kogan, F. N. (2001). Operational space technology for global agricultural monitoring. *Bulletin of the American Meteorological Society*, 82(9), 1949–1964.

Ministerio de Medio Ambiente y Recursos Naturales. (2021). *Monitoreo de la sequía meteorológica en el Corredor Seco de El Salvador*. Servicio Meteorológico Nacional.