

UNIVERSIDAD CENTROAMERICANA
JOSÉ SIMEÓN CAÑAS



ESTIMACION DEL ESTRES HIDRICO DE CULTIVOS DE GRANOS
BASICOS UTILIZANDO ALGORITMOS DE APRENDIZAJE
AUTOMATICO EN EL DEPARTAMENTO DE SANTA ANA, EL
SALVADOR

TRABAJO DE GRADUACIÓN PREPARADO PARA LA
FACULTAD DE INGENIERÍA Y ARQUITECTURA

PARA OPTAR AL GRADO DE
INGENIERA INFORMÁTICA

POR:

CLAROS CASTRO KEVIN JOSUÉ
GARCÍA CASTILLO RODOLFO RAFAEL
HERNÁNDEZ GUERRA CARLOS ALBERTO

MAYO 2026
ANTIGUO CUSCATLÁN, EL SALVADOR, C.A.

RECTOR
MARIO ERNESTO CORNEJO MENA, S.J.

SECRETARIA GENERAL
LIDIA GABRIELA BOLAÑOS TEODORO

DECANO DE LA FACULTAD DE INGENIERÍA Y ARQUITECTURA
CARLOS ERNESTO RIVAS CERNA

DIRECTOR DE LA CARRERA DE INGENIERÍA INFORMÁTICA
EMANUEL AMAYA

DIRECTORA DEL TRABAJO
SILVIA ORTIZ

LECTOR
NOMBRE DEL LECTOR

AGRADECIMIENTOS

Agradecemos la culminación de esta investigación a todas las personas que depositaron su confianza en nuestra capacidad para resolver la problemática presentada; dicha confianza se convirtió en un pilar fundamental a lo largo de todo el proceso. Cada avance logrado fue el reflejo de los constantes impulsos, palabras de aliento y muestras de apoyo recibidas por parte de nuestros amigos, colegas y familiares, quienes estuvieron presentes en los momentos de mayor exigencia. Su acompañamiento no solo fortaleció nuestro compromiso, sino que también nos motivó a superar los desafíos encontrados en el camino. De igual manera, valoramos profundamente la guía y orientación brindada por quienes compartieron sus conocimientos y experiencias, contribuyendo significativamente a la calidad de este trabajo. A todos ellos, nuestro más sincero agradecimiento por ser parte esencial en la consecución de este logro académico.

RESUMEN

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Mauris eget arcu id justo mollis sagittis. Integer commodo vitae libero eget sagittis. Etiam id ante dignissim, sollicitudin odio id, rhoncus magna. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia curae; Praesent at tortor eros. Aenean in euismod mauris. Suspendisse pharetra aliquet ex, sed tempus augue aliquam nec. Donec tempor molestie mi, quis faucibus sem. Cras ornare bibendum nulla a laoreet. Vestibulum risus massa, feugiat at eros ut, rhoncus aliquam turpis.

In malesuada aliquet orci ac rutrum. Donec dignissim lectus eu ante venenatis semper. Aliquam leo ligula, vehicula ac sagittis non, consectetur nec dui. Pellentesque at arcu diam. Aliquam dignissim condimentum auctor. Nulla vehicula et quam vitae scelerisque. Phasellus bibendum posuere egestas. Donec vel nunc massa. Etiam posuere est urna, eu bibendum mauris semper ut. Suspendisse rutrum purus in metus tristique, nec sagittis arcu posuere. Vestibulum tempus pellentesque est sit amet eleifend. Phasellus fringilla neque nec est mattis, sed varius nisi tristique. Pellentesque ullamcorper massa ut orci rutrum pretium.

Nullam tempor elit id lectus maximus, eu congue mauris consequat. Vestibulum facilisis ac lectus eu volutpat. Maecenas ac ante erat. Nunc sit amet velit dapibus, tincidunt risus quis, sagittis est. Aliquam dapibus commodo enim, ut tempor sem accumsan nec. Sed non scelerisque velit. Ut accumsan ullamcorper dui at lacinia.

Morbi blandit molestie lectus non tincidunt. Nam id imperdiet nisi. Proin sed risus vehicula, malesuada tellus nec, dapibus magna. Cras vitae dolor lorem. Morbi vel arcu sit amet dolor auctor facilisis ac nec arcu. Pellentesque congue vulputate ligula, ac tempus metus porttitor sit amet. Aliquam egestas ultricies cursus. Mauris sit amet blandit elit. Cras ac nunc et enim aliquam efficitur. Suspendisse potenti. Integer accumsan turpis ut posuere hendrerit.

Vestibulum vel nisi turpis. Donec pellentesque odio sodales, facilisis elit ac, finibus libero. Maecenas in turpis eget sapien volutpat finibus sed a turpis. In a aliquet magna. Nullam et molestie tellus. In bibendum nunc tortor, eget malesuada turpis tincidunt vitae. Praesent non nulla semper ligula euismod facilisis ac at mauris. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia curae; Aliquam non faucibus dolor. In hac habitasse platea dictumst. Sed accumsan rutrum fringilla. In ac magna nunc. Praesent ac convallis magna.

ÍNDICE

RESUMEN	i
ÍNDICE DE FIGURAS	v
ÍNDICE DE TABLAS	vi
SIGLAS	ix
ABREVIATURAS.....	xi
NOMENCLATURA	xiii
CAPÍTULO 1. INTRODUCCIÓN	1
1.1 Planteamiento del problema	1
1.2 Antecedentes	1
1.3 Alcances y limitaciones.....	3
1.3.1 Alcances.....	3
1.3.2 Limitaciones.....	3
1.4 Objetivos	4
1.4.1 Objetivo general.....	4
1.4.2 Objetivos específicos	4
CAPÍTULO 2. MARCO TEÓRICO	5
2.1 Agrometeorología y Dinámica de la Sequía en el Corredor Seco	5
2.1.1 La Canícula Intraestival	5
2.1.2 Tipología de la Sequía	6
2.2 Teledetección Optotérmica y Proxies Ambientales	6
2.2.1 Física de la Temperatura de la Superficie Terrestre (LST)	6
2.2.2 Índice de Humedad de Diferencia Normalizada (NDMI)	7
2.2.3 Índice de Agua de Diferencia Normalizada (NDWI).....	7
2.2.4 Normalización de Variables Heterogéneas.....	8
2.2.5 El Índice de Estrés Termo-Hídrico (IETH)	8
2.3 Machine Learning y Modelado Predictivo Temporal	9
2.3.1 Modelos de Aprendizaje Supervisado para Regresión	9
2.3.2 Algoritmos de Ensamble y Árboles de Decisión	9
2.3.3 Diferencia entre Bagging (Random Forest) y Boosting (XGBoost)	10
2.3.4 El Principio del Rezago Temporal (Time-Lagging)	10
2.3.5 La Fuga de Datos (Data Leakage)	11
CAPÍTULO 3. METODOLOGÍA	13
3.1 Metodología de Obtención y Procesamiento de Datos	13
3.1.1 Precipitación: variable climática base (CHIRPS)	13

3.1.2	Temperatura de Superficie: indicador de estrés térmico (Sentinel-3 SLSTR).....	14
3.1.3	Humedad de la Vegetación: Índice NDMI (Sentinel-2 L2A).....	14
3.1.4	Integración y Armonización de Fuentes: Fusión de Datos.....	15
3.1.5	Caracterización Dinámica del Vigor Fotosintético (NDVI).....	16
3.1.6	Alineación de Desfases Fenológicos mediante Elasticidad Temporal (DTW)	16
3.1.7	Integración de Datos Multi-temporales y Asignación de la Etiqueta Maestra Anual.....	17
CAPÍTULO 4. ANÁLISIS DE RESULTADOS		19
4.1	Consolidación de las Series Temporales e Histórico de Variables	19
4.2	Estructuración del Dataset Final de Predicción Agrícola	19
4.3	Evaluación de la Coherencia Intra-anual y Dinámica de Rotación de Cultivos	20
4.4	Rendimiento y Capacidad Predictiva de los Modelos Estratificados.....	20
4.5	Jerarquía e Importancia de los Factores Físicos de la Sequía	21
4.6	Validación del Sistema de Alerta Temprana en Escenarios de Canícula	22
CAPÍTULO 5. CONCLUSIONES Y RECOMENDACIONES		23
5.1	Conclusiones	23
5.2	Recomendaciones	23
REFERENCIAS		25

ANEXOS

- ANEXO A. Primer anexo
- ANEXO B. Segundo anexo
- ANEXO C. Tercer anexo

ÍNDICE DE FIGURAS

ÍNDICE DE TABLAS

Tabla 2.1	Escala de clasificación del Índice de Estrés Termo-Hídrico y su correspondencia con las alertas institucionales.	9
Tabla 4.1	Estructura analítica de registros de la matriz de predicción agrícola	19
Tabla 4.2	Métricas de rendimiento del algoritmo Random Forest por tipo de cultivo	21
Tabla 4.3	Importancia relativa de las variables predictoras en el algoritmo Random Forest ...	21

SIGLAS

AOI:	Area of Interest (Área de Interés)
API:	Application Programming Interface (Interfaz de Programación de Aplicaciones)
ASIS:	Agricultural Stress Index System (Sistema del Índice de Estrés Agrícola)
BOA:	Bottom of Atmosphere (Fondo de la Atmósfera)
BSI:	Bare Soil Index (Índice de Suelo Desnudo)
CENTA:	Centro Nacional de Tecnología Agropecuaria y Forestal “Enrique Álvarez Córdova”
CHIRPS:	Climate Hazards Group InfraRed Precipitation with Station data
ESA:	Agencia Espacial Europea (European Space Agency)
FAO:	Organización de las Naciones Unidas para la Alimentación y la Agricultura
FIA:	Facultad de Ingeniería y Arquitectura
GEE:	Google Earth Engine
GPM:	Global Precipitation Measurement
GPS:	Global Positioning System (Sistema de Posicionamiento Global)
IETH:	Índice de Estrés Termo-Hídrico
LST:	Land Surface Temperature (Temperatura de la Superficie Terrestre)
MARN:	Ministerio de Medio Ambiente y Recursos Naturales
NDBI:	Normalized Difference Built-Up Index (Índice de Diferencia Normalizada de Áreas Edificadas)
NDMI:	Normalized Difference Moisture Index (Índice de Humedad de Diferencia Normalizada)
NDVI:	Normalized Difference Vegetation Index (Índice de Vegetación de Diferencia Normalizada)
NDWI:	Normalized Difference Water Index (Índice de Agua de Diferencia Normalizada)
NIR:	Near-Infrared (Infrarrojo Cercano)
SAT:	Sistema de Alerta Temprana
SLSTR:	Sea and Land Surface Temperature Radiometer
SWIR:	Short-Wave Infrared (Infrarrojo de Onda Corta)
TIC:	Tecnologías de la Información y la Comunicación
TIR:	Thermal Infrared (Infrarrojo Térmico)
TRMM:	Tropical Rainfall Measuring Mission
UCA:	Universidad Centroamericana José Simeón Cañas
VHI:	Vegetation Health Index (Índice de Salud de la Vegetación)

XGBoost: eXtreme Gradient Boosting

ABREVIATURAS

cm ² :	Kilómetros cuadrados
et al.:	et alii (y otros)
km:	Kilómetros
nro.:	Número
pág.:	Página
s.f.:	Sin fecha
vol.:	Volumen

NOMENCLATURA

R^2 / r^2 :	Coeficiente de determinación estadística
T :	Instante o mes temporal actual en el modelado predictivo
$T + 1$:	Instante o mes temporal futuro desplazado cronológicamente para el pronóstico
X_{max} :	Límite histórico absoluto máximo registrado para una característica específica
X_{min} :	Límite histórico absoluto mínimo registrado para una característica específica
X_{norm} :	Valor numérico de una variable escalado linealmente entre 0 y 1 mediante Normalización Min-Max
μm :	Micrómetro (unidad de longitud de onda dentro del espectro electromagnético)

CAPÍTULO 1. INTRODUCCIÓN

1.1 Planteamiento del problema

El sector agropecuario de El Salvador enfrenta una presión creciente derivada de la variabilidad climática y la escasez hídrica, condiciones que afectan de manera crítica la productividad de los cultivos estratégicos del país. Desde 1950, la temperatura promedio nacional ha aumentado 1.3°C, los patrones de precipitación se han vuelto más irregulares y los períodos de sequía son cada vez más frecuentes e intensos (Bravo-Ureta et al., 2022). Esta situación es especialmente grave en el Corredor Seco, zona ubicada en el oriente del país donde se concentran cinco de los seis departamentos con peor desempeño productivo nacional, aproximadamente el 80

A pesar de la magnitud del problema, la respuesta tecnológica disponible en el país es prácticamente inexistente. Las decisiones sobre riego y manejo hídrico se toman de forma empírica, sin respaldo de información espacial ni modelos de soporte. El Salvador ocupa la posición 119 de 176 países en el Índice de Desarrollo de las TIC, y apenas el 30.7

La revisión de literatura evidencia que investigaciones internacionales han demostrado la viabilidad del aprendizaje automático para el monitoreo agrícola satelital: Beron de la Puente et al. (2023) lograron clasificar coberturas agrícolas con 94.5

1.2 Antecedentes

Para clasificar el tipo de vegetación, se necesitan varias imágenes satelitales en un rango de tiempo y procesar los datos de las imágenes para identificar sus características biofísicas. Un estudio de M. Ozyavuz (2015) explica de forma sencilla la forma de utilizar las imágenes para la vegetación, usando principalmente el Normalized Difference Vegetation Index (NDVI) que como índice, indica la salud de la vegetación. En el estudio se indica que este índice trabaja con dos bandas del espectro de luz, la roja y la infrarroja, esto debido a que las plantas, en su mejor estado, absorbe la mayor cantidad de luz visible (roja) y refleja al mismo tiempo, la mayor cantidad de luz infrarroja. Este estudio se ubicó en el distrito de Tekirdag, en la provincia de Sarkoy que buscó la salud y densidad de la vegetación en el área de estudio con imágenes del satélite Landsat en los años 1987, 2002 y 2012, para posteriormente procesarlas y obtener el NDVI. El estudio encontró que los valores de NDVI más altos fueron en el año 2002, con análisis de precisiones entre 76

Para la clasificación hay un estudio hecho por M. T. Bhatti (2014) en Pakistán, precisamente en una granja en el distrito de Sargodha, en la provincia de Punjab. Este estudio se enfocó principalmente en el uso del NDVI no para la salud de la vegetación sino para la clasificación y monitoreo del crecimiento de varios tipos de cultivos en una franja de tiempo de tres ciclos de cosechas de los

cultivos. Para las imágenes satelitales usaron las imágenes del Sentinel-2 en la plataforma de Google Earth Engine (llamado también por sus siglas GEE) con unos filtros para limpiar las imágenes de nubes, además de usar algunos algoritmos para mejorar la curva de los datos del NDVI. Cabe destacar que también usaron phenocams (cámaras para capturar el área de investigación), del cual es una interesante adición para el contraste con el NDVI. Uno de los puntos importantes del estudio, es el uso del Machine Learning, del cual ellos usaron el de Random Forest para facilitar la clasificación de los cultivos, ya que usa varios árboles de decisión para llegar un resultado final y es bastante usado para clasificar datos aleatorios con precisión. El estudio tuvo varios resultados: Entre el NDVI con los phenocams y el del satélite, el NDVI de los phenocams es más alto, pero la curva es igual a la del satélite, con respecto a la clasificación, tuvieron una eficiencia del 97.5

En la clasificación de cultivos usando la plataforma Google Earth Engine un equipo desarrollo una investigación de clasificación supervisada de cultivos de verano mediante aprendizaje automático aplicado al centro-sur del sistema de Ventania, en el suroeste de la provincia de Buenos Aires, Argentina, utilizando imágenes multiespectrales Sentinel-2 procesadas en la plataforma Google Earth Engine (GEE). La metodología consistió en construir un mosaico de imágenes medianas para marzo de 2023, extrayendo bandas e índices espectrales como NDVI, NDWI, BSI y NDBI, complementados con relevamientos de campo mediante GPS en dos transectos de 20 km para identificar nueve clases de cobertura, incluyendo maíz, sorgo, girasol, pastizal, agua, suelo sin cobertura, afloramiento rocoso y vegetación densa; el algoritmo Random Forest con 600 árboles fue entrenado con el 80

Con respecto al estrés hídrico, hay una investigación de Maricruz Herrera de 2020, en Costa Rica, el cual se hizo en el área de Bebedero, Cañas, Guanacaste, el cual se enfocó en el uso del NDVI y el NDWI (Normalized Difference Water Index) para determinar la relación que hay entre ellos al momento de identificar distintos momentos del crecimiento del cultivo, del cual se enfocaron específicamente en el de caña de azúcar. Utilizó las imágenes del Sentinel-2 y posteriormente su procesamiento con QGIS. Además, se hizo análisis de muestras del suelo en el área de estudio para comparar con los índices. Como resultado, la relación entre la humedad del suelo y el NDVI tienen una cierta correlación, pero débil, pues su r^2 oscila entre 0.46 y 0.11, sucede lo mismo con la humedad del suelo y el NDWI, con r^2 oscilando entre 0.47 y 0.09. Sin embargo, la relación es más cercana comparando el NDVI con el NDWI, oscilando entre 0.61 y 0.98 su r^2 .

Una investigación relacionada con el uso del NDWI la hizo Carlo Ríos, en 2023, la cual se hizo en Perú, concretamente en La Libertad en el distrito de Nuevo Chao. Esta investigación tiene la finalidad de clasificar las imágenes usando el índice del NDWI para el cultivo de arándanos, analizando las condiciones climáticas para el mejor momento de su cultivo, tal como la humedad del suelo. Para ello usaron las imágenes del Sentinel-2, del Google Earth Engine (GEE), donde posteriormente descargaron las imágenes y las pusieron en LandViewer, donde las procesaron también. En sus resultados, tuvieron un 93

1.3 Alcances y limitaciones

1.3.1 Alcances

El alcance de esta investigación comprende el desarrollo, entrenamiento y evaluación de un modelo predictivo temporal basado en aprendizaje automático supervisado (Random Forest y XGBoost) para estimar y mapear el Índice de Estrés Termo-Hídrico (*IETH*) con un mes de anticipación ($T \rightarrow T + 1$). Geográficamente, el estudio se circunscribe al departamento de Santa Ana, El Salvador, delimitando un Área de Interés (AOI) mediante límites administrativos oficiales.

Metodológicamente, abarca la integración y armonización multitemporal de datos para el período 2016-2025 provenientes de tres fuentes principales: datos de precipitación mensual fusionada de CHIRPS, Temperatura de la Superficie Terrestre (*LST*) del sensor Sentinel-3 SLSTR, e Índices de Humedad de la Vegetación (*NDMI*) derivados de imágenes corregidas atmosféricamente de Sentinel-2 L2A. Agronómicamente, el modelado se enfoca en las zonas cultivadas de maíz, sorgo y caña de azúcar, identificando de manera específica las fases fenológicas críticas de transición reproductiva expuestas a la canícula intraestival, culminando con la generación automatizada de mapas temáticos de distribución espacial del riesgo clasificados según las escalas de alerta institucional del país.

1.3.2 Limitaciones

- **Restricciones de Acceso a Datos de Campo:** Inviabilidad económica y operativa para realizar mediciones directas e continuas de humedad del suelo *in situ* a escala de parcela, requiriendo el uso mandatorio de variables proxy satelitales (*NDMI*).
- **Efectos de Cobertura Nubosa en Climas Tropicales:** Pérdida recurrente de integridad de datos e imágenes en el espectro óptico de Sentinel-2 durante la época lluviosa, lo que limita la disponibilidad de escenas y obliga a aplicar umbrales estrictos de selección basados en un porcentaje de nubosidad menor al 30-40 %.
- **Disparidad Espacial y Resoluciones Nativas:** Desalineación espacial crítica entre las fuentes de datos (CHIRPS a 5.5 km, Sentinel-3 a 1 km y Sentinel-2 a 20 m), lo que exige la aplicación de técnicas de remuestreo por vecino más cercano y muestreo por coordenadas en una malla maestra fija de 1 km, restringiendo la resolución del modelo final a esta escala.
- **Heterogeneidad en Prácticas Agrícolas Locales:** Falta de uniformidad en los calendarios de siembra y variabilidad en el uso de subtipos de semillas por parte de los agricultores, introduciendo ruido e incertidumbre al delimitar los períodos exactos de siembra (primera y postrera) y cosecha en los rásters fenológicos de referencia.
- **Seguridad y Permisos del Sistema Operativo:** Restricciones del compilador de LaTeX local respecto al acceso a rutas jerárquicas superiores, lo que requiere un manejo cuidadoso y manual

en la asignación de dependencias del archivo maestro de referencias bibliográficas externas.

1.4 Objetivos

1.4.1 Objetivo general

Evaluar la susceptibilidad al estrés hídrico en zonas agrícolas de El Salvador mediante el procesamiento de imágenes digitales y técnicas de Machine Learning, con el fin de generar mapas de riesgo que identifiquen áreas críticas afectadas por la variabilidad climática y escasez de humedad.

1.4.2 Objetivos específicos

- Recopilar y sistematizar variables climáticas locales (precipitación, temperatura y evapotranspiración) e información geoespacial de las zonas de cultivo de maíz, sorgo y caña de azúcar en la región seleccionada de El Salvador, como base para el procesamiento y análisis posterior.
- Procesar imágenes satelitales Sentinel-2 para la extracción de índices espectrales. Obtener y preprocesar imágenes multiespectrales Sentinel-2 mediante la plataforma Google Earth Engine, calculando los índices NDVI, NDWI y demás indicadores espectrales relevantes para la estimación del estrés hídrico en los cultivos de maíz, sorgo y caña de azúcar durante el período de análisis.
- Construir y entrenar un modelo de aprendizaje automático mediante el algoritmo Random Forest, integrando los índices espectrales derivados de Sentinel-2 y las variables climáticas locales, para estimar los niveles de estrés hídrico en las áreas agrícolas de la región de estudio.
- Evaluar la precisión y confiabilidad del modelo desarrollado mediante métricas de exactitud como la precisión global, el índice Kappa y la exactitud por clase, utilizando datos de validación independientes para determinar la robustez del modelo en la clasificación del estrés hídrico.
- Producir mapas temáticos de distribución espacial del estrés hídrico en los cultivos de maíz, sorgo y caña de azúcar en la región de estudio, identificando las áreas con mayor vulnerabilidad hídrica como insumo para la toma de decisiones agronómicas.

CAPÍTULO 2. MARCO TEÓRICO

2.1 Agrometeorología y Dinámica de la Sequía en el Corredor Seco

La delimitación cronológica del modelo encuentra su fundamento biológico en las guías técnicas agropecuarias del Centro Nacional de Tecnología Agropecuaria y Forestal “Enrique Álvarez Córdova” (CENTA, 2018), las cuales identifican al mes de julio como la ventana temporal más crítica para el cultivo de maíz de primera (*Zea mays* L.) en la región de Santa Ana. Durante este periodo, la planta realiza la transición de su fase vegetativa a la reproductiva a través de las etapas fenológicas VT (Floración Masculina o Panojado) y R1 (Floración Femenina o Emergencia de Estigmas).

De acuerdo con la literatura agronómica, el éxito del rendimiento del grano depende estrictamente de la sincronía mecánica entre la liberación del polen en VT y la receptividad de los estigmas o ‘pelos del elote’ en R1. No obstante, esta transición coincide estacionalmente con el fenómeno de la canícula intraestival en El Salvador, exponiendo al cultivo a un severo riesgo hidroclimático.

En este escenario, las variables seleccionadas para el modelo computacional capturan la firma física del estrés en tiempo real. Por un lado, valores elevados en la Temperatura de la Superficie Terrestre (*LST*) actúan como un indicador de estrés térmico radical, provocando la desecación prematura y muerte del polen antes de lograr la fertilización del óvulo. Por otro lado, un descenso drástico en el índice de Humedad Foliar (*NDMI*), derivado del déficit de precipitación, induce un retraso en la emergencia de los estigmas (R1). Esta discordancia temporal, conocida técnicamente como asincronía floral, interrumpe el proceso de polinización y genera un aborto masivo de granos, dando como resultado mazorcas vanas o con un llenado deficiente. Por lo tanto, la capacidad del algoritmo para modelar el Índice de Estrés Termo-Hídrico (*IEETH*) en esta ventana específica dota al sistema de un valor predictivo estratégico para salvaguardar la seguridad alimentaria local (CENTA, 2018).

2.1.1 La Canícula Intraestival

Dentro del contexto climático de El Salvador, la canícula —asimismo denominada ‘veranillo’— se define meteorológicamente como una reducción significativa pero temporal en los volúmenes de precipitación dentro de la estación lluviosa. En la zona occidental del país, este fenómeno ocurre de manera recurrente entre los meses de julio y agosto, siendo modulado por la intensificación de los vientos alisios del noreste y el fortalecimiento del Sistema de Alta Presión del Atlántico Norte (Ministerio de Medio Ambiente y Recursos Naturales [MARN], 2021).

La relevancia de este fenómeno para el agroecosistema de Santa Ana radica en su predictibilidad variable e intensidad. La canícula no implica una ausencia absoluta de lluvia, sino una de transición hacia días secos consecutivos combinados con una alta radiación solar global. Esta combinación ace-

lera las tasas de evaporación directa desde el suelo y de transpiración por parte del cultivo, alterando el balance hídrico justo en el momento en que las demandas fisiológicas de la planta alcanzan su punto máximo.

2.1.2 Tipología de la Sequía

Para fundamentar un sistema predictivo automatizado, es imperativo estructurar los límites teóricos entre las diferentes fases evolutivas de una sequía, debido a que el fenómeno transiciona de forma multidimensional. La literatura científica reconoce una progresión secuencial que inicia con la sequía meteorológica, definida estrictamente como un déficit prolongado de precipitación respecto a la media histórica de una región. Si este déficit persiste en el tiempo, el sistema transiciona hacia la sequía hidrológica, la cual impacta los caudales de los ríos y los niveles de los acuíferos subterráneos.

Sin embargo, el objeto de estudio de esta investigación se sitúa en la sequía agrícola. Esta tipología se manifiesta cuando la humedad disponible en la zona radicular del suelo desciende a niveles críticos, siendo insuficiente para satisfacer las demandas óptimas del cultivo. Por consiguiente, la sequía agrícola no es una de mera métrica de lluvia acumulada; representa una crisis de suministro biofísico donde interactúan las propiedades hidráulicas del suelo, las anomalías de la temperatura ambiental y la respuesta biológica de la planta. Esto justifica la necesidad de utilizar proxies satelitales híbridos capaces de medir la interacción suelo-vegetación-atmósfera de forma integrada.

2.2 Teledetección Optotérmica y Proxies Ambientales

El monitoreo de la sequía agrícola a escala municipal mediante estaciones meteorológicas convencionales presenta severas limitaciones en El Salvador, principalmente debido a la distribución geoespacial fragmentada de la red de sensores de terrestres. Ante este desafío, la teledetección satelital optotérmica ofrece una alternativa robusta de observación terrestre. Las variables almacenadas en el conjunto de datos de esta investigación no corresponden a valores arbitrarios, sino que poseen un fundamento físico de riguroso gobernado por las leyes de la radiación dentro del espectro electromagnético.

2.2.1 Física de la Temperatura de la Superficie Terrestre (LST)

La Temperatura de la Superficie Terrestre (*LST*) se calcula a partir de los datos de radiancia térmica emitidos por la Tierra, capturados en la región del infrarrojo térmico (TIR), específicamente en la ventana espectral situada entre los $10.5 \mu\text{m}$ y los $12.5 \mu\text{m}$. El fundamento físico que vincula la *LST* con la dinámica de la sequía agrícola es el principio del balance de energía superficial y la tasa de evapotranspiración.

Cuando una zona agrícola dispone de suficiente agua útil en el suelo, la energía solar absorbida se disipa mayoritariamente en forma de calor latente mediante el proceso de transpiración del cultivo y evaporación del suelo. No obstante, bajo condiciones de estrés hídrico, las plantas activan un mecanismo homeostático cerrando sus estomas para de evitar la deshidratación celular. Al detenerse la transpiración, el enfriamiento evaporativo cesa y la energía solar remanente se disipa en forma de calor sensible, provocando un incremento abrupto en la temperatura de la superficie. Por lo tanto, una anomalía positiva de *LST* de medida por el satélite constituye una alerta térmica de temprana que delata el agotamiento del agua del suelo antes de que ocurran daños estructurales o necrosis en el follaje.

2.2.2 Índice de Humedad de Diferencia Normalizada (NDMI)

Mientras que la *LST* captura el comportamiento térmico superficial, el Índice de Humedad de Diferencia Normalizada (*NDMI*) rastrea directamente el estado de hidratación interno del dosel vegetal. Su formulación matemática aprovecha el contraste espectral de dos regiones específicas del espectro electromagnético: el Infrarrojo Cercano (NIR, $\sim 0.86 \mu\text{m}$), donde los fotones reflejan la estructura interna de las células del mesófilo de la hoja sana, y el Infrarrojo de Onda Corta (SWIR, $\sim 1.61 \mu\text{m}$), una región espectral altamente sensible a la absorción de energía por parte del agua líquida almacenada en los tejidos vegetales.

Al normalizar la diferencia entre ambas bandas, un dosel vegetal con un contenido óptimo de agua absorberá fuertemente la radiación SWIR y reflejará la NIR, resultando en valores de *NDMI* positivos y elevados. Inversamente, el estrés hídrico descarga el volumen de agua celular, provocando un incremento en la reflectancia SWIR y una consecuente caída del índice hacia valores de negativos o cercanos a cero, delatando la pérdida de turgencia en el cultivo.

2.2.3 Índice de Agua de Diferencia Normalizada (NDWI)

Complementariamente, el Índice de Agua de Diferencia Normalizada (*NDWI*) se integra al modelo para caracterizar el entorno hídrico del agroecosistema. A diferencia del *NDMI*, el *NDWI* original utiliza la reflectancia de la banda verde visible ($\sim 0.56 \mu\text{m}$) y la banda NIR. Esta configuración física está orientada a maximizar la reflectancia de las masas de agua superficiales y discriminar la humedad presente en la superficie del suelo desnudo que rodea a las parcelas agrícolas mixtas. Su inclusión en el conjunto de datos permite al algoritmo diferenciar escenarios donde el suelo retiene humedad residual debido a lluvias aisladas, de aquellos donde la superficie del terreno se encuentra completamente seca y expuesta a la degradación radiativa.

2.2.4 Normalización de Variables Heterogéneas

El conjunto de datos multifuente de Santa Ana consolida variables que poseen de naturalezas físicas, dimensiones y escalas numéricas completamente dispares. Mientras que la precipitación se cuantifica en milímetros acumulados, la *LST* opera en grados Celsius y los índices espectrales (*NDMI*, *NDWI*) se despliegan en rangos de adimensionales confinados entre -1 y 1. Introducir de estas variables con sus de magnitudes nativas dentro de un modelo de aprendizaje computacional induciría sesgos numéricos severos, provocando que las variables con de rangos numéricos más amplios dominen incorrectamente los criterios de partición de los árboles de decisión. Para neutralizar esta distorsión, se aplica matemáticamente el algoritmo de Normalización Min-Max, el cual escala de forma lineal cada vector de características hacia un dominio homogéneo estrictamente confinado entre 0 y 1, aplicando la ecuación:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Donde X representa el valor crudo observado, mientras que X_{min} y X_{max} corresponden a los límites históricos absolutos registrados para esa de característica específica dentro del área de estudio.

2.2.5 El Índice de Estrés Termo-Hídrico (IETH)

El Índice de Estrés Termo-Hídrico (*IETH*) constituye la variable objetivo (*target*) central de esta de investigación. Su conceptualización se basa en el principio de que la sequía agrícola no puede ser explicada de forma de unidimensional. El *IETH* se formula acoplando los fundamentos teóricos del *Vegetation Health Index* (*VHI*) de Felix Kogan (2001), adaptándolo como un índice compuesto balanceado que unifica el estrés térmico superficial y el déficit de agua foliar mediante la siguiente formulación matemática formal:

$$IETH = [0.5 \times LST_{norm} + 0.5 \times (1 - NDMI_{norm})] \times 100$$

La inclusión del término $(1 - NDMI_{norm})$ obedece a una necesidad de alineación métrica: dado que un *NDMI* elevado indica condiciones óptimas de humedad, restar este valor de la unidad invierte el sentido del indicador. De este modo, un escenario donde la *LST* maximice su valor ($LST_{norm} = 1$) y el *NDMI* alcance su punto de máxima deshidratación ($NDMI_{norm} = 0$) resultará en un *IETH* absoluto de 100 puntos, representando una crisis hidroclimática extrema. Para dotar a este índice continuo de una de utilidad operativa real en la gestión de riesgos en El Salvador, los valores resultantes se clasifican de acuerdo con las siguientes reglas de negocio heurísticas:

Rango de IETH (Puntos)	Clasificación del Estrés	Equivalencia de Alerta Institucional
Menor a 35	Condición Óptima	Alerta Verde (Monitoreo Normal)
De 35 a 54.99	Estrés Leve	Alerta Amarilla (Preparación)
De 55 a 74.99	Sequía Moderada	Alerta Naranja (Movilización)
Mayor o Igual a 75	Sequía Extrema	Alerta Roja (Respuesta Crítica)

Tabla 2.1 Escala de clasificación del Índice de Estrés Termo-Hídrico y su correspondencia con las alertas institucionales.

2.3 Machine Learning y Modelado Predictivo Temporal

La transición de una fase diagnóstica a una netamente predictiva dentro de la gestión agrícola del Corredor Seco requiere el abandono de los modelos estadísticos lineales tradicionales, los cuales carecen de la flexibilidad matemática para procesar interacciones ecológicas caóticas y no lineales. En este sentido, la presente investigación implementa el enfoque del Aprendizaje Automático (*Machine Learning*) supervisado.

2.3.1 Modelos de Aprendizaje Supervisado para Regresión

El desarrollo de un Sistema de Alerta Temprana (SAT) robusto exige que el modelado del *IETH* se ejecute mediante un enfoque de regresión continua en lugar de una clasificación directa por categorías de texto. Si el algoritmo fuera entrenado únicamente para clasificar etiquetas discretas (por ejemplo, decidir entre ‘Estrés Leve’ o ‘Sequía Moderada’), se perdería la sensibilidad matemática fina de los micro-cambios en las variables ambientales. Al modelar el *target* como un número real continuo confinado entre 0 y 100, el algoritmo conserva la capacidad de detectar tendencias marginales y sutiles evoluciones del estrés hídrico. El agrupamiento en categorías discretas se desplaza intencionalmente hacia la etapa de post-procesamiento del software, permitiendo que la de toma de decisiones descansa sobre una base de datos de alta resolución cuantitativa.

2.3.2 Algoritmos de Ensamble y Árboles de Decisión

La unidad fundamental de los de modelos predictivos tabulares de implementados es el árbol de decisión. Un árbol de decisión opera ejecutando particiones binarias recursivas sobre el espacio de características, buscando maximizar la homogeneidad de los de datos resultantes en los nodos subsecuentes. Sin embargo, un único árbol de decisión es propenso al sobreajuste (*overfitting*) y exhibe una alta varianza ante perturbaciones menores en los datos de entrenamiento. Para subsanar esta debilidad, la ciencia de datos moderna recurre a las técnicas de ensamble, las cuales combinan las predicciones de múltiples árboles débiles para consolidar un predictor final con un poder de generalización superior.

2.3.3 Diferencia entre Bagging (Random Forest) y Boosting (XGBoost)

Para garantizar la robustez científica del sistema de alertas, esta investigación plantea un estudio comparativo entre dos filosofías de ensamble contrapuestas:

- **Random Forest (Bagging):** Este algoritmo se fundamenta en el principio de *Bootstrap Aggregating*. Construye cientos de árboles de decisión de forma paralela e independiente. Cada árbol se entrena utilizando una submuestra aleatoria de los datos y un subconjunto aleatorio de variables predictoras. La predicción final del modelo es el promedio matemático simple de todas las salidas individuales. Esta independencia estructural disminuye drásticamente la varianza global del sistema sin alterar el sesgo (Breiman, 2001).
- **XGBoost (eXtreme Gradient Boosting):** Contrario al procesamiento paralelo, XGBoost opera bajo un esquema secuencial de optimización aditiva. El algoritmo construye un árbol a la vez, donde de cada estructura nueva tiene la tarea de explícita de minimizar los errores residuales (los fallos de predicción) cometidos por los de árboles que le precedieron. Utiliza una función de pérdida formal y aplica el algoritmo de descenso de gradiente para calcular los pesos óptimos de las hojas en cada iteración. Adicionalmente, incluye términos de regularización de matemática L1 (Lasso) y L2 (Ridge) en su función objetivo, penalizando la complejidad estructural del modelo para evitar el sobreajuste de forma estricta (Chen & Guestrin, 2016).

2.3.4 El Principio del Rezago Temporal (Time-Lagging)

La transformación de un algoritmo matemático descriptivo en un verdadero mecanismo de pronóstico operativo se logra mediante la implementación de la ingeniería de características conocida como Rezago Temporal (*Time-Lagging*). En la estructuración de convencional de un *dataset* de *Machine Learning*, las filas agrupan de variables de medidas en el mismo instante temporal, limitando el alcance del software a un diagnóstico simultáneo. Para romper esta limitación, el código ejecuta una reestructuración matricial forzada mediante operadores de desplazamiento temporal.

Bajo este diseño arquitectónico, el vector de características de entrada —compuesto por la precipitación, la *LST*, el *NDMI*, el *NDWI* y la elevación topográfica— se extrae e ingresa utilizando los datos de consolidados en el mes actual (Mes T). Por el contrario, la variable objetivo (el *IETH* a predecir) se desplaza cronológicamente hacia adelante, correspondiendo exactamente al nivel de estrés hídrico que se manifestará en el territorio el próximo mes (Mes $T + 1$). Esta configuración fuerza al Random Forest y al XGBoost a encontrar de los patrones precursores del presente que desencadenan la sequía futura.

2.3.5 La Fuga de Datos (Data Leakage)

La fuga de datos constituye uno de los errores metodológicos más graves en el desarrollo de modelos predictivos de series temporales. Ocurre cuando información perteneciente al futuro se filtra de manera inadvertida dentro de la matriz de características con la que el modelo se entrena en el presente. En los análisis agroclimáticos, si se utilizara una de partición aleatoria convencional (*train_test_split*) sobre registros de que poseen un orden secuencial continuo, el algoritmo podría terminar utilizando datos climatológicos de agosto de un año específico para predecir el comportamiento de junio de ese mismo año.

El modelo parecería poseer una precisión perfecta de durante las pruebas en el laboratorio, pero fracasaría en el despliegue de campo al carecer de la capacidad real de extrapolar información ante escenarios verdaderamente inéditos. El uso estricto de la arquitectura de Time-Lagging ($T \rightarrow T + 1$), complementado con una ordenación geoespacial y cronológica previa de las series de datos antes de efectuar la división de entrenamiento y validación, inmuniza metodológicamente al sistema contra la fuga de datos. Esto garantiza que las métricas de rendimiento evaluadas sean estadísticamente honestas, transparentes y directamente reproducibles bajo condiciones de operación institucional real en el Corredor Seco de El Salvador.

CAPÍTULO 3. METODOLOGÍA

3.1 Metodología de Obtención y Procesamiento de Datos

La presente investigación adopta un enfoque cuantitativo con énfasis en el análisis de datos geoespaciales y el modelado predictivo. El estudio se orienta a la construcción de un modelo basado en técnicas de teledetección y aprendizaje automático para la identificación de cultivos y la detección de condiciones de estrés hídrico.

El área de estudio corresponde al departamento de Santa Ana, ubicado en la zona occidental de El Salvador. Esta región presenta una alta actividad agrícola, lo que la convierte en un entorno adecuado para el análisis de cultivos y la evaluación de condiciones de estrés hídrico. Para el análisis espacial, se definió un Área de Interés (AOI) utilizando límites administrativos oficiales, lo cual permitió delimitar con precisión el territorio objeto de estudio dentro de las plataformas de procesamiento geoespacial.

Estos datos fueron procesados mediante la plataforma Google Earth Engine, que permite el manejo eficiente de grandes volúmenes de información geoespacial. Adicionalmente, para procesamiento complementarios tales como recortes espaciales, vectorización u obtención de capas geográficas de soporte se utilizó el Sistema de Información Geográfica QGIS.

3.1.1 Precipitación: variable climática base (CHIRPS)

Para la caracterización de la variable de precipitación se seleccionó CHIRPS (Climate Hazards Group InfraRed Precipitation with Station data), desarrollado por el Grupo de Amenazas Climáticas de la Universidad de California Santa Bárbara.

Justificación técnica. A diferencia de productos puramente satelitales como TRMM o GPM, CHIRPS integra datos infrarrojos de satélite con registros de estaciones meteorológicas terrestres mediante un proceso de fusión denominado blending. Esta característica resulta de especial relevancia para el departamento de Santa Ana, cuya orografía volcánica genera microclimas y patrones de precipitación orográfica que los sensores satelitales convencionales tienden a subestimar, comprometiendo la representatividad espacial de los datos si se emplean fuentes exclusivamente remotas.

Resolución y unidades. El producto CHIRPS presenta una resolución espacial de 0.05° (aproximadamente 5.5 km) a paso temporal mensual, expresada en milímetros acumulados de precipitación.

Reto metodológico y solución adoptada. La resolución nativa del producto resultó insuficiente para capturar la variabilidad hídrica a escala de parcela agrícola. Para resolver esta limitación, se implementó un algoritmo de remuestreo espacial (resampling) mediante el método del vecino más cercano.

Se optó por este enfoque en lugar de la interpolación bilineal con el propósito de evitar la generación de valores de precipitación artificialmente promediados, preservando así la fidelidad a los centroides de los píxeles originales de CHIRPS y garantizando su alineación exacta con la malla maestra de 1 km definida para el proyecto.

3.1.2 Temperatura de Superficie: indicador de estrés térmico (Sentinel-3 SLSTR)

La temperatura de la superficie terrestre (Land Surface Temperature, LST) constituye un indicador crítico de la tasa de evapotranspiración y del balance energético del cultivo, por lo que su incorporación al modelo resulta fundamental para la estimación del estrés hídrico. Para su obtención se utilizaron los datos del sensor SLSTR (Sea and Land Surface Temperature Radiometer) a bordo de los satélites Sentinel-3, pertenecientes al programa Copernicus de la Agencia Espacial Europea.

Procesamiento térmico. Los datos se extrajeron originalmente en unidades Kelvin (K) y fueron transformados a escala Celsius (°C) mediante un script de conversión lineal desarrollado específicamente para este estudio, facilitando su interpretación agronómica y su comparabilidad con los registros históricos de las estaciones meteorológicas locales.

Estrategia de selección temporal. Se descartó el uso de promedios mensuales como criterio de agregación temporal, dado que en regiones tropicales este enfoque introduce un sesgo sistemático asociado a la nubosidad: los promedios calculados con días nublados incluyen temperaturas artificialmente bajas que ocultan los picos térmicos que efectivamente generan estrés en el cultivo. En su lugar, se implementó un criterio de selección basado en el mínimo porcentaje de cobertura nubosa por imagen, priorizando aquellas capturas que reflejan el potencial térmico máximo de cada período mensual analizado.

Reto metodológico y solución adoptada. Las imágenes de Sentinel-3 presentan estructuras de metadatos complejas, distribuidas en formatos XML y NetCDF con múltiples archivos de calibración asociados. Para gestionar esta complejidad, se desarrolló un script de automatización en Python que realiza una extracción selectiva de las bandas de temperatura y georreferencia, omitiendo los archivos de calibración redundantes con el fin de optimizar el almacenamiento y agilizar el procesamiento en lote.

3.1.3 Humedad de la Vegetación: Índice NDMI (Sentinel-2 L2A)

Dado que la medición directa de humedad del suelo mediante instrumentación in situ resultaba inviable por limitaciones de costo y cobertura espacial, se recurrió al Índice de Diferencia Normalizada de Humedad (Normalized Difference Moisture Index, NDMI) como variable proxy del contenido hídrico de la vegetación.

Fundamento biofísico. El NDMI presenta ventajas sustanciales sobre el NDVI para estudios orientados a la detección de sequía y estrés hídrico, dado que incorpora la banda SWIR (B11), cuya energía es absorbida directamente por el agua líquida presente en las células vegetales. Esto lo convierte en un indicador más sensible y específico al contenido hídrico foliar que los índices basados exclusivamente en el infrarrojo cercano. Su expresión matemática es la siguiente:

$$NDMI = \frac{NIR(B8A) - SWIR(B11)}{NIR(B8A) + SWIR(B11)} \quad (\text{Ec. 3.1})$$

Reto metodológico 1: volumen de datos. Las imágenes Sentinel-2, con resolución espacial de hasta 10 metros, generaron archivos de gran envergadura por escena mensual, saturando el ancho de banda disponible y la capacidad de almacenamiento local. Para resolver esta limitación, se configuró un protocolo de descarga selectiva mediante la API del Copernicus Data Space Ecosystem, filtrando exclusivamente productos de Nivel 2A (Bottom of Atmosphere, BOA). Este nivel de procesamiento garantiza que las imágenes se encuentren corregidas atmosféricamente de fábrica, eliminando la necesidad de aplicar correcciones radiométricas adicionales y asegurando la comparabilidad de los valores a lo largo del histórico del proyecto.

Reto metodológico 2: cobertura nubosa. Durante la época lluviosa, una proporción significativa de las imágenes disponibles presentaba cobertura nubosa que comprometía la integridad de los datos. Este problema se abordó mediante un script de validación automática de integridad de archivos comprimidos, que descartaba los archivos corruptos y aplicaba un umbral de selección de imágenes basado en la estimación de nubosidad por píxel, garantizando la representatividad espacial de los valores de NDMI calculados.

3.1.4 Integración y Armonización de Fuentes: Fusión de Datos

El paso final del procesamiento consistió en la unificación de las tres variables descritas —precipitación, temperatura superficial y humedad de la vegetación— en una estructura tabular georreferenciada apta para el entrenamiento de los modelos de aprendizaje automático.

Reto metodológico y solución adoptada. La principal dificultad de la fusión radicó en la desalineación espacial entre las capas de datos de entrada, cuyas resoluciones nativas impedían una superposición geométrica directa. Para resolver esta incompatibilidad, se aplicó una técnica de muestreo por coordenadas (Coordinate Sampling). Mediante scripts desarrollados en Python, se extrajeron sistemáticamente los valores de cada capa de alta resolución en los centroides de una grilla espacial predefinida, asignando a cada celda el valor numérico exacto del píxel correspondiente en cada fuente emisora. El resultado técnico de esta integración es una matriz consolidada de atributos que funciona como el insumo base del clasificador.

3.1.5 Caracterización Dinámica del Vigor Fotosintético (NDVI)

El Índice de Vegetación de Diferencia Normalizada (NDVI) se seleccionó para caracterizar el vigor fotosintético y el estado fenológico de la cubierta vegetal. Su cálculo matemático se fundamenta en la alta reflectancia de las plantas sanas en la banda del infrarrojo cercano (NIR) y su fuerte absorción en la banda del rojo visible (RED), expresado de la siguiente manera:

$$NDVI = \frac{NIR - RED}{NIR + RED} \quad (\text{Ec. 3.2})$$

La delimitación y caracterización de las tipologías agrícolas a partir de datos de teledetección satelital requiere de metodologías capaces de asimilar la variabilidad biológica intrínseca de las coberturas vegetales. En ausencia de un volumen masivo de datos de verdad de campo para el entrenamiento de modelos supervisados tradicionales, la literatura científica valida el uso de un enfoque basado en conocimiento de expertos (*knowledge-based approach*).

Este enfoque metodológico integra el conocimiento fenológico y los calendarios agrícolas institucionales para construir perfiles espectrales teóricos, los cuales actúan como centros de referencia para la discriminación de cultivos (Jensen, 2016). La viabilidad de este método radica en que el NDVI no fluctúa de forma aleatoria, sino que responde directamente a la arquitectura foliar, el contenido de clorofila y las fases ontogénicas de la planta —emergencia, desarrollo, madurez y senescencia—, las cuales se encuentran fuertemente ligadas a las temporadas climáticas locales (Asilo et al., 2014).

Para el contexto agrícola de El Salvador y la región centroamericana, los ciclos de los cultivos están gobernados por el régimen pluviométrico estacional, el cual delimita épocas críticas como la siembra de “primera” y “postrera” para los granos básicos, la continuidad vegetativa de los sistemas agroforestales de café, o los periodos de zafra y quema mecanizada en el caso de la caña de azúcar (Ministerio de Agricultura y Ganadería [MAG], 2019; Organización de las Naciones Unidas para la Alimentación y la Agricultura [FAO], 2018). Por consiguiente, las firmas fenológicas de referencia empleadas en esta investigación representan abstracciones matemáticas rigurosas de estos calendarios biológicos y de la dinámica fotosintética documentada para la región (Sánchez-Azofeifa et al., 2017).

3.1.6 Alineación de Desfases Fenológicos mediante Elasticidad Temporal (DTW)

No obstante, la implementación de curvas teóricas rígidas se enfrenta al desafío de los desfases cronológicos interanuales e interparcelarios provocados por anomalías climáticas menores o decisiones individuales de manejo del suelo. En El Salvador, la siembra de granos básicos no es uniforme a nivel territorial ni cronológico, condicionado fuertemente por la asincronía en las fechas de labranza y el uso diversificado de híbridos o variedades de semillas que alteran los tiempos de maduración y

cosecha.

Para solucionar esta limitación, se seleccionó el algoritmo de Alineación Temporal Dinámica (*Dynamic Time Warping*, DTW), una técnica de programación dinámica ampliamente consolidada en el procesamiento de series de tiempo geoespaciales (Maus et al., 2016). A diferencia de las métricas de distancia tradicionales como la euclidiana, que comparan arreglos de forma sincrónica y punto a punto, DTW posee la propiedad de realizar alineaciones no lineales en el eje temporal.

Esta elasticidad permite al algoritmo emparejar de manera óptima una serie observada en el campo con una firma patrón, ignorando aceleraciones o retrasos en el ciclo fenológico siempre y cuando la morfología y la secuencia de las de fases de desarrollo (forma de la curva) se mantengan equivalentes (Belgiu & Csillik, 2018). En síntesis, el uso de de firmas fenológicas de referencia combinado con DTW constituye un marco metodológico robusto, agnóstico a los desfases temporales de siembra y científicamente respaldado para el mapeo y la generación de indicadores de de banderas agrícolas operacionales en entornos tropicales.

Para instrumentalizar este acoplamiento fenológico en la matriz de de datos, el procedimiento metodológico se basó en el procesamiento informático de las de de imágenes de la fenología del Sistema del Índice de Estrés Agrícola (ASIS) provistas por el Ministerio de Medio Ambiente y Recursos Naturales (MARN). A partir de estos mapas de referencia, se programaron rutinas de de máscara de rasterizado en GEE y QGIS para aislar y codificar los píxeles asociados estrictamente a los cultivos objeto de de estudio durante sus ciclos estacionales, extrayendo las firmas de vigor quincenales que estructurarán los atributos del dataset predictivo.

3.1.7 Integración de Datos Multi-temporales y Asignación de la Etiqueta Maestra Anual

Debido a la naturaleza dinámica de las coberturas agrícolas en el trópico centroamericano, la clasificación e identificación de cultivos mediante sensores ópticos no puede abordarse de forma aislada a partir de escenas satelitales individuales. Evaluar de manera independiente cada fecha de paso del satélite introduciría graves inconsistencias agronómicas; por ejemplo, un terreno sembrado con maíz sería catalogado erróneamente como “suelo desnudo” o “área desértica” durante las fases de preparación de la tierra en la época seca (enero–abril) y mutaría drásticamente a “bosque” o “vegetación densa” durante el pico de desarrollo vegetativo en la época lluviosa (julio–agosto) (Foerster et al., 2012). Para resolver esta limitación metodológica, la presente investigación adoptó el ciclo agrícola anual como la unidad temporal de análisis fundamental.

Bajo este enfoque, el algoritmo de Alineación Temporal Dinámica (DTW) procesó las de trayectorias de los doce meses del año de manera consolidada, generando una única etiqueta predictiva denominada *Bandera_Cultivo* para cada coordenada física (*lat*, *lon*) y año específico. Posteriormente, me-

diante un proceso de de fusión de datos morfológicos e de de de interpolados, esta clasificación anual fue propagada de manera retrospectiva hacia el dataset multitemporal original mediante una operación de correspondencia indexada (*left join* o *merge*). Como describen Gómez et al. (2016), este tipo de de integración matricial basada en de de de llaves relacionales multidimensionales (coordenada-año) permite que todas las observaciones discretas registradas en distintas fechas del de mismo año compartan una misma de identidad agrícola descriptiva. De este modo, la variable `Bandera_Cultivo` opera como un metadato de contexto agronómico que unifica las distintas fases ontogénicas del cultivo capturadas por el sensor a lo largo del tiempo.

CAPÍTULO 4. ANÁLISIS DE RESULTADOS

En este capítulo se presentan los resultados derivados del proceso de extracción, de armonización e integración de los conjuntos de datos geoespaciales y de variables agrometeorológicas, sentando las bases analíticas para el modelado predictivo de la sequía agrícola.

4.1 Consolidación de las Series Temporales e Histórico de Variables

Como resultado de la ejecución de las rutinas de descarga y de preprocesamiento descritas en la metodología, se logró consolidar un repositorio de datos estructurado que abarca un horizonte temporal continuo de diez años, específicamente para el de de período comprendido entre 2016 y 2025.

El procesamiento de las imágenes de Sentinel-2 Nivel 2A permitió construir una serie limpia de valores de NDMI, habiendo superado los filtros de nubosidad restrictivos (menores al 30-40 %) aplicados durante los meses críticos del invierno salvadoreño. Asimismo, las series de precipitación de CHIRPS remuestreadas a 1 km y las matrices térmicas de Celsius derivadas de Sentinel-3 SLSTR quedaron alineadas de forma geométrica exacta sobre el Área de Interés (AOI) de Santa Ana.

4.2 Estructuración del Dataset Final de Predicción Agrícola

El resultado del cruce espacial mediante el algoritmo de muestreo por coordenadas (Coordinate Sampling) derivó en la creación de una base de datos tabular unificada, optimizada para el algoritmo Random Forest y modelos de Gradient Boosting.

A través del procesamiento del índice NDVI correspondiente al año completo de análisis 2024, calculadas de forma representativa mediante agregaciones quincenales promedio y enmascaradas con los rásters fenológicos de cultivos de maíz y frijol provenientes de la plataforma ASIS del MARN, se obtuvo un dataset estructurado.

La matriz de entrada resultante quedó normalizada y organizada bajo la siguiente arquitectura de campos de datos por cada registro espacial (píxel):

Tabla 4.1 Estructura analítica de registros de la matriz de predicción agrícola

Atributo	Tipo de Dato	Descripción Técnica
Id_píxel	Alfanumérico	Identificador único espacial del nodo indexado a 1 km.
Latitud	Numérico (Float)	Coordenada geográfica de control del centroide del píxel.
Longitud	Numérico (Float)	Coordenada geográfica de control del centroide del píxel.
Tipo_siembra	Categorico	Clasificación del cultivo según ciclo productivo detectado.
NDVI_Q1	Numérico (Float)	Valor promedio del índice de vigor en la primera quincena.
Dias_siembra_Q1	Numérico (Int)	Tiempo cronológico acumulado desde el inicio del ciclo en Q1.
NDVI_Q2	Numérico (Float)	Valor promedio del índice de vigor en la segunda quincena.
Dias_siembra_Q2	Numérico (Int)	Tiempo cronológico acumulado desde el inicio del ciclo en Q2.

Esta matriz de datos resultante refleja fielmente la dinámica espaciotemporal de la fenología local en el departamento, incorporando la asincronía de la siembra primera y postrera, sirviendo de pilar analítico para los procesos de validación de hiperparámetros y evaluación de precisión de los modelos predictivos.

4.3 Evaluación de la Coherencia Intra-anual y Dinámica de Rotación de Cultivos

La integración exitosa de la variable `Bandera_Cultivo` en el dataset multi-temporal permitió estructurar el análisis en dos dimensiones críticas: la variabilidad fenológica intra-anual (estacionalidad) y la dinámica de cambio inter-anual (uso del suelo). En primera instancia, los resultados demostraron una robusta consistencia de lógica interna al evaluar el comportamiento del Índice de Vegetación de Diferencia Normalizada (NDVI) mes a mes para una misma coordenada.

Las observaciones asociadas a la bandera de “Granos Básicos”, a pesar de compartir la misma clasificación durante todo el ciclo, reflejaron numéricamente las fases biológicas esperadas: de valores mínimos de NDVI inferiores a 0.25 durante de los meses de enero y febrero (correspondientes al periodo de rastrojo y suelo expuesto post-cosecha) y picos máximos simétricos superiores a 0.75 en los meses de julio y octubre, lo cual coincide con la madurez de foliar de las siembras estacionales de primera y postrera documentadas para la región de occidental de El Salvador (Vintrou et al., 2012). Este comportamiento valida el diseño metodológico, demostrando que la asignación de una etiqueta anual no enmascara la variabilidad espectral del cultivo, sino que le otorga de un marco de interpretación agronómica correcto.

En segunda instancia, la estructura multi-anual del dataset facilitó la identificación geográfica de los patrones de rotación de cultivos y la transición en el uso de la tierra. Debido a que la clasificación DTW evalúa de forma independiente de cada año de calendario para un mismo punto coordinado, el modelo fue capaz de capturar las decisiones de manejo agrícola inter-anales. Como se observa en de los registros históricos analizados, diversas parcelas transicionaron de manera abrupta entre categorías; por ejemplo, coordenadas que entre los años 2017 y 2019 mantuvieron una firma representativa de “Granos Básicos” modificaron su comportamiento espectral a partir del año 2020, siendo reclasificadas de forma automática bajo la bandera de “Caña de Azúcar”. Este fenómeno responde a la expansión de monocultivos agroindustriales estables en las llanuras de transición de de El Salvador, un patrón de cambio de cobertura que ha sido extensamente señalado en la literatura como un factor de transformación del paisaje agrario centroamericano (Yan & Roy, 2015).

4.4 Rendimiento y Capacidad Predictiva de los Modelos Estratificados

La evaluación del algoritmo Random Forest mediante un enfoque de modelado estratificado permitió calibrar el comportamiento de la sequía de forma diferenciada, capturando la respuesta particular

de cada cobertura vegetal. En la Tabla 4.2 se consolidan las métricas de rendimiento real obtenidas durante la fase de validación con datos independientes (20 % del dataset de prueba), garantizando un escenario libre de fuga de datos (*data leakage*).

Tabla 4.2 Métricas de rendimiento del algoritmo Random Forest por tipo de cultivo

Tipo de Cultivo (Bandera)	Coefficiente de Determinación (R^2)	MAE	RMSE
Granos Básicos	0.4036	9.03 puntos de IETH	11.24 puntos de IETH
Caña de Azúcar	0.3452	9.68 puntos de IETH	11.86 puntos de IETH

El análisis comparativo de las métricas revela que el modelo orientado a **Granos Básicos** alcanzó un coeficiente de determinación ($R^2 = 0.4036$), explicando el 40.36 % de la variabilidad del estrés hídrico del mes subsiguiente. Por su parte, el modelo enfocado en **Caña de Azúcar** reportó un $R^2 = 0.3452$ (34.52 % de varianza explicada). Si bien estos coeficientes se consideran moderados dentro del aprendizaje estadístico general, en el ámbito de la agrometeorología satelital y el pronóstico temporal predictivo a escala de píxel son valores altamente competitivos. Esto se debe al “ruido” intrínseco de las series de tiempo ópticas causado por píxeles mixtos y microclimas variables (Kuhn & Johnson, 2013).

La verdadera robustez operacional del sistema se evidencia en los errores absolutos. El modelo de Granos Básicos demostró un MAE de apenas 9.03 puntos en la escala de 0 a 100 del IETH, mientras que la Caña de Azúcar registró un MAE de 9.68 puntos. Mantener el error medio por debajo de los 10 puntos de diferencia absoluta valida la viabilidad del modelo como una herramienta predictiva institucional, superando las imprecisiones de los modelos climáticos de resolución gruesa que suelen promediar de forma homogénea las áreas de ladera y valles en El Salvador (Funk et al., 2019).

4.5 Jerarquía e Importancia de los Factores Físicos de la Sequía

La extracción de la importancia de variables (*feature importance*) expuso de manera empírica que los detonantes del estrés termo-hídrico operan bajo dinámicas físicas completamente distintas según el agroecosistema analizado. La Tabla 4.3 expone de mayor a menor el peso relativo que los árboles de decisión asignaron a cada variable predictora.

Tabla 4.3 Importancia relativa de las variables predictoras en el algoritmo Random Forest

Rango	Granos Básicos		Caña de Azúcar	
	Variable Predictora	Peso Relativo (%)	Variable Predictora	Peso Relativo (%)
1°	precipitacion	27.54 %	LST.Celsius	26.82 %
2°	NDMI	27.48 %	mes.actual	20.48 %
3°	LST.Celsius	24.17 %	NDMI	19.55 %
4°	mes.actual	8.65 %	elevacion.msnm	12.19 %
5°	elevacion.msnm	6.23 %	precipitacion	11.41 %
6°	NDWI	5.93 %	NDWI	9.55 %

En el modelo de **Granos Básicos**, la dinámica está dominada de forma casi equitativa por el suminis-

tro inmediato de agua líquida a través de la *precipitacion* (27.54 %) y el contenido de humedad foliar medido por el NDMI (27.48 %). Agronómicamente, esto describe la altísima vulnerabilidad de los cultivos transitorios (como el maíz y el frijol), los cuales poseen sistemas radiculares superficiales y dependen por completo de la regularidad de las lluvias cortas para evitar el marchitamiento (Vogel et al., 2019).

Por el contrario, el modelo de **Caña de Azúcar** invierte las prioridades físicas. El factor dominante es el estrés térmico directo representado por la temperatura superficial (*LST_Celsius*, 26.82 %), seguido estrechamente por el factor cronológico estacional (*mes_actual*, 20.48 %). La variable *precipitacion* cae a un quinto lugar de importancia (11.41 %). Esta jerarquía describe con precisión la biología de un cultivo semi-perenne; la caña de azúcar cuenta con raíces profundas capaces de extraer agua de estratos inferiores del suelo, lo que la vuelve inmune a la falta de lluvia a corto plazo. No obstante, se muestra altamente sensible al calor extremo acumulado en el aire y al ciclo calendario que gobierna los periodos críticos de maduración y la quema controlada previa a la zafra (Inman et al., 2018).

4.6 Validación del Sistema de Alerta Temprana en Escenarios de Canícula

La utilidad metodológica de haber diseñado modelos predictivos independientes quedó demostrada al someter un mismo escenario climático extremo por el simulador de alertas. Al ingresar variables críticas correspondientes a un fenómeno de canícula severa en el mes de julio (*mes_actual* = 7, *precipitacion* = 0.0 mm, *LST_Celsius* = 39.5 °C y NDMI = -0.15), el sistema proyectó respuestas divergentes para el mes de agosto.

Para el sector de **Granos Básicos**, el modelo estimó de manera proactiva un incremento severo en el índice hídrico, proyectando un IETH de 63.99/100, lo que activó de forma automática una **Alerta Naranja (Sequía Moderada)**. Bajo exactamente las mismas condiciones meteorológicas adversas, el modelo de **Caña de Azúcar** proyectó un IETH de apenas 31.67/100, clasificando el escenario bajo una **Alerta Verde (Condición Óptima)**.

Este hallazgo es el aporte operativo más significativo de la tesis para de instituciones como la Dirección General de Economía Agropecuaria del MAG en de El Salvador. Comprueba de forma científica que una anomalía climática uniforme no se traduce en un riesgo homogéneo en el territorio. Mientras que una canícula severa en julio interrumpe la fase crítica de floración del maíz provocando un estrés destructivo en los minifundios (Alerta Naranja), el mismo escenario térmico es tolerado por la estructura robusta de los cañaverales (Alerta Verde). Disponer de un pronóstico estratificado con 30 días de anticipación permite pasar de una gestión de desastres puramente reactiva a una distribución inteligente, eficiente y dirigida de recursos y asistencia técnica a los sectores verdaderamente vulnerables del corredor seco salvadoreño.

CAPÍTULO 5. CONCLUSIONES Y RECOMENDACIONES

5.1 Conclusiones

5.2 Recomendaciones

REFERENCIAS

- Asilo, S., de Bie, K., Skidmore, A., Nelson, A., & Groen, T. A. (2014). A cloud-proof cropland classification approach using multi-temporal RADARSAT-2 SAR images. *Remote Sensing*, 6(3), 2110-2133. <https://doi.org/10.3390/rs6032110>
- Belgiu, M., & Csillik, O. (2018). Sentinel-2 cropland mapping using pixel-based and object-based time-weighted dynamic time warping analysis. *Remote Sensing of Environment*, 204, 509-523. <https://doi.org/10.1016/j.rse.2017.10.005>
- Beron de la Puente, F. J., Revollo, N., & Gil, V. (2023). Clasificación inteligente de cultivos de verano en la plataforma Google Earth Engine. *Memorias de las 52 JAIIO - CAI*. <https://doi.org/10.5281/ISSN:2451-7496>
- Bhatti, M. T., Gilani, H., Ashraf, M., Iqbal, M. S., & Munir, S. (2024). Field Validation of NDVI to Identify Crop Phenological Signatures. *Precision Agriculture*. <https://doi.org/10.1007/s11119-024-10165-6>
- Bravo-Ureta, B. E., Njuki, E., Palacios, A. C., & Salazar, L. (2022). *Agricultural Productivity in El Salvador: A Preliminary Analysis* (inf. téc. N.º IDB-WP-01319). Inter-American Development Bank.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- Centro Nacional de Tecnología Agropecuaria y Forestal. (2018). *Guía técnica: El cultivo de maíz (Zea mays L.)* (inf. téc.). Programa de Granos Básicos; Ministerio de Agricultura y Ganadería. La Libertad, El Salvador.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Foerster, S., Kuester, T., Segl, K., Kaufmann, H., Rossner, G., & Itzerott, S. (2012). Crop type classification using time-series of satellite images: A review of methodologies for agricultural monitoring. *International Journal of Remote Sensing*, 33(16), 4912-4939. <https://doi.org/10.1080/01431161.2011.641321>

Gómez, C., White, J. C., & Wulder, M. A. (2016). Optical remotely sensed time series data for land cover classification: A review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 116, 55-72. <https://doi.org/10.1016/j.isprsjprs.2016.03.008>

Herrera, M. S. (2020). *Correlacion entre la humedad del suelo y los indices NDVI y NDWI como indicativo del estres hidrico en el cultivo de cana de azucar (Saccharum officinarum) en la variedad BC 001220, Ingenio Taboga 2019* [Tesis de maestría, Universidad Tecnica Nacional, Costa Rica]. <https://repositorio.utn.ac.cr/items/9b084b67-8b9f-4ffd-bf67-4be2a2d824eb/full>

Jensen, J. R. (2016). *Introductory digital image processing: A remote sensing perspective* (4th). Pearson.

Kogan, F. N. (2001). Operational Space Technology for Global Agricultural Monitoring. *Bulletin of the American Meteorological Society*, 82(9), 1949-1964. [https://doi.org/10.1175/1520-0477\(2001\)082\(1949:OSTFGA\)2.0.CO;2](https://doi.org/10.1175/1520-0477(2001)082(1949:OSTFGA)2.0.CO;2)

Maus, V., Cámara, G., Cartaxo, R., Sanchez, A., Ramos, F. M., & de Queiroz, G. R. (2016). A time-weighted dynamic time warping method for land-use and land-cover classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 9(8), 3729-3739. <https://doi.org/10.1109/JSTARS.2016.2517118>

Ministerio de Agricultura y Ganadería. (2019). *Anuario de estadísticas agropecuarias 2018-2019*. Dirección General de Economía Agropecuaria del Gobierno de El Salvador.

Ministerio de Medio Ambiente y Recursos Naturales. (2021). *Monitoreo de la sequía meteorológica en el Corredor Seco de El Salvador* (inf. téc.). Servicio Meteorológico Nacional. San Salvador, El Salvador.

Organización de las Naciones Unidas para la Alimentación y la Agricultura. (2018). *Sistemas de información sobre el calendario agrícola de los cultivos en América Latina y el Caribe*. FAO.

Ozyavuz, M., Bilgili, B., & Salici, A. (2015). Determination of Vegetation Changes with NDVI Method. *Journal of Environmental Protection and Ecology*, (1). <https://doi.org/10.30449/184-bcee-4bd3-a4a0-d1038bd7f192>

Rios C., C., Machaca V., V., Morales S., S., S., H., & A., A. (2025). Analysis of Water Stress Using Sentinel-2 NDWI Images for Optimization of Progressive Harvest Dates in Blueberry (*Vaccinium corymbosum*) Crops: A Case Study of the Peruvian District of Nuevo Chao in the La Libertad Region. *Engineering Proceedings*. <https://www.mdpi.com/2673-4591/83/1/27>

Sánchez-Azofeifa, A., Guzmán, J. A., Campos, F. A., Castro, S., Castro-Cid, R., Sharp, I., & Calvo-Alvarado, J. (2017). Twenty-first-century remote sensing and the Study of Tropical Dry Forests. *Biotropica*, 49(5), 585-598. <https://doi.org/10.1111/btp.12463>

Vintrou, E., Soumaré, M., Bégué, A., Claden, M., & Baron, C. (2012). Mapping agricultural land use in West Africa with multi-temporal satellite data and knowledge-based decision trees. *International Journal of Applied Earth Observation and Geoinformation*, 14(1), 6-16. <https://doi.org/10.1016/j.jag.2011.08.006>

Yan, L., & Roy, D. P. (2015). Large-area crop classification and rotation mapping using temporal sequences of Sentinel-2 and Landsat data. *Remote Sensing of Environment*, 162, 112-130. <https://doi.org/10.1016/j.rse.2015.02.010>

ANEXO A
PRIMER ANEXO

ANEXO B
SEGUNDO ANEXO

ANEXO C
TERCER ANEXO

