

UNIVERSIDAD CENTROAMERICANA
JOSÉ SIMEÓN CAÑAS



MODELADO PREDICTIVO DEL ESTRÉS TERMO-HÍDRICO EN
CULTIVOS AGRÍCOLAS ESTRATÉGICOS MEDIANTE
TELEDETECCIÓN Y APRENDIZAJE AUTOMÁTICO EN SANTA ANA,
EL SALVADOR

TRABAJO DE GRADUACIÓN PREPARADO PARA LA
FACULTAD DE INGENIERÍA Y ARQUITECTURA

PARA OPTAR AL GRADO DE
INGENIERA INFORMÁTICA

POR:
CLAROS CASTRO KEVIN JOSUÉ
GARCÍA CASTILLO RODOLFO RAFAEL
HERNÁNDEZ GUERRA CARLOS ALBERTO

JUNIO 2026
ANTIGUO CUSCATLÁN, EL SALVADOR, C.A.

RECTOR
MARIO ERNESTO CORNEJO MENA, S.J.

SECRETARIA GENERAL
LIDIA GABRIELA BOLAÑOS TEODORO

DECANO DE LA FACULTAD DE INGENIERÍA Y ARQUITECTURA
CARLOS ERNESTO RIVAS CERNA

DIRECTOR DE LA CARRERA DE INGENIERÍA INFORMÁTICA
JOSÉ ENMANUEL AMAYA ARAUJO

DIRECTORA DEL TRABAJO
SILVIA CAROLINA ORTIZ CUÉLLAR

LECTORA
METZI RUTILIA AGUILAR MUNGUÍA

AGRADECIMIENTOS

Agradecemos la culminación de esta investigación a todas las personas que depositaron su confianza en nuestra capacidad para resolver la problemática presentada; dicha confianza se convirtió en un pilar fundamental a lo largo de todo el proceso. Cada avance logrado fue el reflejo de los constantes impulsos, palabras de aliento y muestras de apoyo recibidas por parte de nuestros amigos, colegas y familiares, quienes estuvieron presentes en los momentos de mayor exigencia. Su acompañamiento no solo fortaleció nuestro compromiso, sino que también nos motivó a superar los desafíos encontrados en el camino. De igual manera, valoramos profundamente la guía y orientación brindada por quienes compartieron sus conocimientos y experiencias, contribuyendo significativamente a la calidad de este trabajo. A todos ellos, nuestro más sincero agradecimiento por ser parte esencial en la consecución de este logro académico.

RESUMEN

La intensificación de las anomalías climáticas ha incrementado la vulnerabilidad agrícola y la ha posicionado como uno de los principales desafíos para la seguridad alimentaria, especialmente en regiones propensas a sequías recurrentes, como el Corredor Seco Centroamericano. En este contexto, el sector agropecuario del departamento de Santa Ana, El Salvador, enfrenta condiciones críticas asociadas a la alta variabilidad hidroclimática, las cuales comprometen la productividad de cultivos estratégicos para la región. En particular, la producción de granos básicos, como el maíz y el frijol, así como el rendimiento agroindustrial de la caña de azúcar, se ven amenazados por episodios recurrentes de estrés hídrico y térmico.

Ante esta problemática, la presente investigación propone el desarrollo de un modelo predictivo orientado a la estimación del Índice de Estrés Termo-Hídrico Agrícola (IETH) con un mes de anticipación temporal ($T + 1$). Dicho índice fue formulado empíricamente durante el estudio como una métrica compuesta capaz de cuantificar la convergencia entre anomalías térmicas, déficit de humedad y respuesta espectral de la cobertura vegetal, con el propósito de anticipar condiciones de estrés agrícola en zonas de interés productivo.

Para el modelado del índice se integraron datos satelitales provenientes de múltiples sensores, incluyendo información de precipitación de CHIRPS, temperatura de la superficie terrestre de MODIS e índices de vegetación obtenidos mediante Sentinel-2. Estos datos fueron armonizados espacialmente mediante técnicas de muestreo por coordenadas sobre una malla con resolución de 1 km². Se evaluaron diferentes algoritmos de aprendizaje automático supervisado, contrastando el rendimiento de métodos de ensamble como Random Forest y XGBoost. Asimismo, se incorporó un diseño de retardos temporales (*time-lags*), estructurado específicamente para prevenir la fuga de datos y capturar la inercia de las condiciones climáticas. La validación experimental determinó que el modelo XGBoost presentó el mejor desempeño predictivo, alcanzando un coeficiente de determinación (R^2) de 0.9122 y un Error Absoluto Medio (MAE) de 4.90 puntos de IETH. Adicionalmente, para abordar la asincronía en el desarrollo fenológico de los cultivos analizados, se implementó la técnica de alineamiento temporal dinámico (*Dynamic Time Warping*, DTW), la cual permitió alinear las series temporales de las firmas espectrales y comparar estados biológicos equivalentes.

A nivel operativo, las proyecciones geoespaciales generadas evidenciaron la capacidad analítica del sistema para anticipar dinámicas de estrés termo-hídrico en escenarios reales. La focalización territorial de estas alertas demuestra la viabilidad de la arquitectura propuesta como una herramienta de apoyo para la toma de decisiones y la formulación de políticas públicas, permitiendo a las autoridades agrícolas transitar de una respuesta reactiva hacia una planificación preventiva y priorizar estrategias de mitigación en las zonas agrícolas del Corredor Seco.

ÍNDICE

RESUMEN	i
ÍNDICE DE FIGURAS	vi
ÍNDICE DE TABLAS	viii
SIGLAS	xi
ABREVIATURAS.....	xiii
NOMENCLATURA	xv
CAPÍTULO 1. INTRODUCCIÓN	1
1.1 Planteamiento del problema	1
1.2 Antecedentes	1
1.3 Alcances y limitaciones.....	3
1.3.1 Alcances.....	3
1.3.2 Limitaciones.....	4
1.4 Objetivos	4
1.4.1 Objetivo general.....	4
1.4.2 Objetivos específicos	5
CAPÍTULO 2. MARCO TEÓRICO	7
2.1 Agrometeorología y dinámica de la sequía en el corredor seco	7
2.1.1 La Canícula Intraestival	7
2.1.2 Tipología de la Sequía	8
2.2 La Teledetección.....	8
2.2.1 Sentinel-2	9
2.2.2 Características del Sentinel-2	9
2.2.3 Física de la Temperatura de la Superficie Terrestre (LST)	10
2.2.4 Índice de Humedad de Diferencia Normalizada (NDMI)	10
2.2.5 Índice de Agua de Diferencia Normalizada (NDWI).....	11
2.2.6 Índice de Vegetación de Diferencia Normalizada	11
2.2.7 Normalización de Variables Heterogéneas.....	11
2.2.8 El Índice de Estrés Termo-Hídrico (IETH)	12
2.3 Machine Learning y Modelado Predictivo Temporal	13
2.3.1 Modelos de Aprendizaje Supervisado para Regresión	13
2.3.2 Algoritmos de Ensamble y Árboles de Decisión	13
2.3.3 Diferencia entre Bagging (Random Forest) y Boosting (XGBoost)	13
2.3.4 El Principio del Rezago Temporal (Time-Lagging)	14
2.3.5 La Fuga de Datos (Data Leakage)	14

CAPÍTULO 3. METODOLOGÍA	17
3.1 Enfoque metodológico	17
3.2 Construcción y estandarización de la malla espacial de referencia.....	18
3.2.1 Definición del marco de referencia y entorno de desarrollo	18
3.2.2 Depuración y validación geoespacial	19
3.3 Integración espacio-temporal y construcción del panel mensual	20
3.3.1 Preprocesamiento e ingeniería de datos	20
3.3.2 Consolidación del panel mensual balanceado.....	22
3.4 Integración y armonización de fuentes satelitales y climáticas.....	22
3.4.1 Ingesta y depuración de repositorios satelitales	22
3.4.2 Uniones relacionales y consolidación de la matriz enriquecida	22
3.4.3 Normalización paramétrica y prevención de sesgo temporal.....	24
3.4.4 Cálculo del índice objetivo y construcción de la variable futura	24
3.4.5 Ingeniería de características: predictores dinámicos y anomalías	25
3.5 Entrenamiento y evaluación de modelos predictivos temporales	26
3.5.1 Configuración y ajuste de algoritmos de aprendizaje automático	26
3.5.2 Evaluación multidimensional: Regresión numérica y clasificación de alertas	27
3.5.3 Análisis estratificado espacio-temporal.....	28
3.6 Comparación de experimentos y selección del modelo definitivo	29
3.6.1 Diseño de escenarios experimentales de inferencia.....	29
3.6.2 Cuantificación y contraste de métricas de desempeño	30
3.6.3 Regla de decisión heurística para la selección del modelo.....	30
3.7 Consolidación y empaquetado del modelo definitivo.....	30
3.7.1 Ingesta de criterios de decisión y resolución analítica	31
3.7.2 Validación estructural del espacio de características	31
3.7.3 Serialización persistente y generación del manifiesto operativo.....	31
3.8 Explicabilidad del modelo y generación de atribuciones SHAP	32
3.8.1 Reconstrucción relacional del espacio de características	32
3.8.2 Cálculo de contribuciones locales (Valores SHAP) y validación de integridad.....	32
3.8.3 Cuantificación de la confianza operativa heurística.....	33
3.8.4 Traducción semántica y estructuración para inferencia.....	33
3.9 Validación agronómica e interpretación de las explicaciones.....	34
3.9.1 Análisis de direccionalidad global y correlación de atribuciones	34
3.9.2 Estratificación y selección de casos agrícolas de estudio.....	34
3.10 Implementación funcional de AgroAlerta	35
3.10.1 Propósito de la implementación	35

3.10.2 Integración del modelo predictivo en el servicio de inferencia	35
3.10.3 Interfaz de consulta y visualización de resultados	36
3.10.4 Asistente conversacional inteligente.....	36
CAPÍTULO 4. ANÁLISIS DE RESULTADOS	37
4.1 Consolidación de las Series Temporales e Histórico de Variables	37
4.2 Estructuración del Dataset Final de Predicción Agrícola	37
4.3 Evaluación de la Coherencia Intra-anual y Dinámica de Rotación de Cultivos	38
4.4 Evaluación del aporte de la clasificación fenológica de cultivos.....	39
4.5 Análisis exploratorio de modelos estratificados por cultivo.....	41
4.6 Jerarquía e Importancia de los Factores Físicos de la Sequía.....	42
4.7 Validación del Sistema de Alerta Temprana en Escenarios de Canícula	42
4.7.1 Interpretabilidad de las Predicciones.....	43
CAPÍTULO 5. CONCLUSIONES Y RECOMENDACIONES	45
5.1 Conclusiones	45
5.2 Recomendaciones	46
REFERENCIAS	49

ANEXOS

ANEXO A.	Primer anexo
ANEXO B.	Segundo anexo
ANEXO C.	Tercer anexo

ÍNDICE DE FIGURAS

Figura 3.1	Arquitectura general del flujo metodológico para la integración de datos, generación del $IETH$ y modelado predictivo del estrés termo-hídrico agrícola.....	18
Figura 3.2	Esquema del desplazamiento temporal para la generación de la variable objetivo $IETH_{t+1}$	25
Figura 3.3	Discretización del Índice de Estrés Termo-Hídrico (IETH) en niveles de alerta operativa.	28
Figura 3.4	Flujo simplificado de interacción del agente de inteligencia artificial integrado en AgroAlerta.....	36
Figura 4.1	Esquema comparativo del modelo predictivo de $IETH$ con y sin cultivo fenológico estimado.	40

ÍNDICE DE TABLAS

Tabla 2.1	Características espectrales y espaciales de las bandas del sensor Sentinel-2 utilizadas en el análisis.....	9
Tabla 2.2	Escala de clasificación del Índice de Estrés Termo-Hídrico y su correspondencia con las alertas institucionales.	12
Tabla 4.1	Estructura analítica de registros de la matriz de predicción agrícola	38
Tabla 4.2	Métricas de rendimiento del algoritmo Random Forest por tipo de cultivo	41
Tabla 4.3	Importancia relativa de las variables predictoras en el algoritmo Random Forest ...	42

SIGLAS

AOI:	Area of Interest (Área de Interés)
API:	Application Programming Interface (Interfaz de Programación de Aplicaciones)
ASIS:	Agricultural Stress Index System (Sistema del Índice de Estrés Agrícola)
BOA:	Bottom of Atmosphere (Fondo de la Atmósfera)
BSI:	Bare Soil Index (Índice de Suelo Desnudo)
CENTA:	Centro Nacional de Tecnología Agropecuaria y Forestal “Enrique Álvarez Córdova”
CHIRPS:	Climate Hazards Group InfraRed Precipitation with Station data
ESA:	Agencia Espacial Europea (European Space Agency)
FAO:	Organización de las Naciones Unidas para la Alimentación y la Agricultura
FIA:	Facultad de Ingeniería y Arquitectura
GEE:	Google Earth Engine
GPM:	Global Precipitation Measurement
GPS:	Global Positioning System (Sistema de Posicionamiento Global)
IETH:	Índice de Estrés Termo-Hídrico
LST:	Land Surface Temperature (Temperatura de la Superficie Terrestre)
MARN:	Ministerio de Medio Ambiente y Recursos Naturales
NDBI:	Normalized Difference Built-Up Index (Índice de Diferencia Normalizada de Áreas Edificadas)
NDMI:	Normalized Difference Moisture Index (Índice de Humedad de Diferencia Normalizada)
NDVI:	Normalized Difference Vegetation Index (Índice de Vegetación de Diferencia Normalizada)
NDWI:	Normalized Difference Water Index (Índice de Agua de Diferencia Normalizada)
NIR:	Near-Infrared (Infrarrojo Cercano)
SAT:	Sistema de Alerta Temprana
SLSTR:	Sea and Land Surface Temperature Radiometer
SWIR:	Short-Wave Infrared (Infrarrojo de Onda Corta)
TIC:	Tecnologías de la Información y la Comunicación
TIR:	Thermal Infrared (Infrarrojo Térmico)
TRMM:	Tropical Rainfall Measuring Mission
UCA:	Universidad Centroamericana José Simeón Cañas
VHI:	Vegetation Health Index (Índice de Salud de la Vegetación)

XGBoost: eXtreme Gradient Boosting

ABREVIATURAS

cm ² :	Kilómetros cuadrados
et al.:	et alii (y otros)
km:	Kilómetros
nro.:	Número
pág.:	Página
s.f.:	Sin fecha
vol.:	Volumen

NOMENCLATURA

R^2 / r^2 :	Coeficiente de determinación estadística
T :	Instante o mes temporal actual en el modelado predictivo
$T + 1$:	Instante o mes temporal futuro desplazado cronológicamente para el pronóstico
X_{max} :	Límite histórico absoluto máximo registrado para una característica específica
X_{min} :	Límite histórico absoluto mínimo registrado para una característica específica
X_{norm} :	Valor numérico de una variable escalado linealmente entre 0 y 1 mediante Normalización Min-Max
μm :	Micrómetro (unidad de longitud de onda dentro del espectro electromagnético)

CAPÍTULO 1. INTRODUCCIÓN

1.1 Planteamiento del problema

El sector agropecuario de El Salvador enfrenta una presión creciente derivada de la variabilidad climática y la escasez hídrica, condiciones que afectan de manera crítica la productividad de los cultivos estratégicos del país. Desde 1950, la temperatura promedio nacional ha experimentado un incremento de 1.3 °C, los patrones de precipitación se han vuelto más irregulares y los períodos de sequía son cada vez más frecuentes e intensos (Bravo-Ureta et al., 2022). Esta situación es especialmente grave en zonas de alta vulnerabilidad climática, donde las anomalías térmicas y los déficits de humedad comprometen directamente los rendimientos agrícolas y amenazan la seguridad alimentaria de los productores locales.

Frente a esta problemática, si bien instituciones como el Ministerio de Agricultura y Ganadería (MAG) han implementado herramientas de monitoreo e información agrometeorológica, los sistemas actuales operan predominantemente bajo un enfoque de diagnóstico reactivo o a una escala macroespacial. La brecha tecnológica principal radica en la carencia de modelos predictivos de alta resolución que logren anticipar el estrés termo-hídrico antes de que el cultivo sufra daños fisiológicos irreversibles. Al no contar con proyecciones operativas, las decisiones estratégicas de mitigación en el territorio continúan siendo limitadas, impidiendo una priorización preventiva y eficiente de los recursos.

La revisión de literatura evidencia que investigaciones internacionales han demostrado la viabilidad y superioridad del aprendizaje automático, también conocido como *Machine Learning*, para superar estas limitaciones en el monitoreo agrícola satelital. Estudios como el de Beron de la Puente et al. (2023) lograron clasificar coberturas y detectar anomalías con precisiones del 94.5 %, comprobando que la inteligencia artificial es capaz de procesar la complejidad de las dinámicas climáticas. Por lo tanto, la integración de algoritmos predictivos avanzados a las plataformas de vigilancia nacional representa una necesidad urgente para modernizar la gestión del riesgo agrícola y dotar a las autoridades de herramientas analíticas que permitan anticipar el estrés hídrico con precisión.

1.2 Antecedentes

Para clasificar el tipo de vegetación, se necesitan varias imágenes satelitales en un rango de tiempo y procesar los datos de las imágenes para identificar sus características biofísicas. Un estudio de M. Ozyavuz (2015) explica de forma sencilla la forma de utilizar las imágenes para la vegetación, usando principalmente el Normalized Difference Vegetation Index (NDVI) que como índice, indica la salud de la vegetación. En el estudio se indica que este índice trabaja con dos bandas del espectro de luz, la roja y la infrarroja, esto debido a que las plantas, en su mejor estado, absorbe la mayor cantidad de luz

visible (roja) y refleja al mismo tiempo, la mayor cantidad de luz infrarroja. Este estudio se ubicó en el distrito de Tekirdag, en la provincia de Sarkoy que buscó la salud y densidad de la vegetación en el área de estudio con imágenes del satélite Landsat en los años 1987, 2002 y 2012, para posteriormente procesarlas y obtener el NDVI. El estudio encontró que los valores de NDVI más altos fueron en el año 2002, con análisis de precisiones entre 76 y 80 %, y un kappa index del 0.7.

Para la clasificación de cultivos, se identifica el estudio realizado por M. T. Bhatti (2014) en Pakistán, específicamente en una granja ubicada en el distrito de Sargodha, provincia de Punjab. Esta investigación se enfocó principalmente en el uso del Índice de Vegetación de Diferencia Normalizada (NDVI), no solo como indicador de salud de la vegetación, sino también como herramienta para la clasificación y el monitoreo del crecimiento de diferentes tipos de cultivos durante tres ciclos de cosecha. Para ello, se utilizaron imágenes satelitales Sentinel-2 procesadas en la plataforma Google Earth Engine (GEE), aplicando filtros para reducir la presencia de nubes y algoritmos orientados a suavizar la curva temporal del NDVI. Además, el estudio incorporó el uso de *phenocams*, es decir, cámaras instaladas en campo para capturar imágenes del área de investigación, lo cual permitió contrastar las observaciones terrestres con los valores obtenidos mediante sensores satelitales. Uno de los aspectos más relevantes del estudio fue la aplicación de técnicas de aprendizaje automático, específicamente el algoritmo Random Forest, empleado para facilitar la clasificación de cultivos a partir de múltiples árboles de decisión. Los resultados mostraron que los valores de NDVI obtenidos mediante *phenocams* fueron más altos que los derivados de las imágenes satelitales; sin embargo, ambas fuentes presentaron una tendencia temporal similar. En cuanto a la clasificación, el modelo alcanzó una eficiencia del 97.5 % y un coeficiente kappa de 0.96, lo que indica un alto nivel de precisión en la clasificación basada en imágenes satelitales. No obstante, los autores señalaron limitaciones asociadas a la presencia de niebla, nubosidad y a la dificultad para diferenciar ciertos cultivos con características espectrales similares.

En la clasificación de cultivos usando la plataforma Google Earth Engine un equipo desarrolló una investigación de clasificación supervisada de cultivos de verano mediante aprendizaje automático aplicado al centro-sur del sistema de Ventania, en el suroeste de la provincia de Buenos Aires, Argentina, utilizando imágenes multispectrales Sentinel-2 procesadas en la plataforma Google Earth Engine (GEE). La metodología consistió en construir un mosaico de imágenes medianas para marzo de 2023, extrayendo bandas e índices espectrales como NDVI, NDWI, BSI y NDBI, complementados con relevamientos de campo mediante GPS en dos transectos de 20 km para identificar nueve clases de cobertura, incluyendo maíz, sorgo, girasol, pastizal, agua, suelo sin cobertura, afloramiento rocoso y vegetación densa; el algoritmo Random Forest con 600 árboles fue entrenado con el 80 % de la muestra y validado con el 20 % restante, y la imagen resultante fue posteriormente procesada en ArcMap mediante un filtro de mayoría para eliminar píxeles aislados. El modelo alcanzó una precisión global de 94.5 % y un índice Kappa de 0.905, identificando al maíz como el cultivo dominante con 274 km², seguido del sorgo con 120 km² y el girasol con 75 km², con las principales confusiones registradas

entre afloramiento rocoso y suelo sin cobertura, y entre vegetación densa y cultivos bajo riego por pivote, demostrando que la integración de GEE con Random Forest constituye una herramienta eficaz y automatizable para la clasificación de coberturas agrícolas en zonas de heterogeneidad ambiental compleja.

Con respecto al estrés hídrico, se identifica la investigación realizada por Maricruz Herrera (2020) en Costa Rica, específicamente en el área de Bebedero, Cañas, Guanacaste. Este estudio se enfocó en el uso del Índice de Vegetación de Diferencia Normalizada (NDVI) y del Índice de Agua de Diferencia Normalizada (NDWI, por sus siglas en inglés, *Normalized Difference Water Index*) para determinar la relación existente entre ambos índices durante diferentes etapas de crecimiento del cultivo de caña de azúcar. Para ello, se utilizaron imágenes satelitales Sentinel-2, las cuales fueron procesadas posteriormente mediante QGIS. Además, se realizaron análisis de muestras de suelo en el área de estudio, con el propósito de contrastar los valores obtenidos a partir de los índices espectrales con las condiciones reales de humedad del suelo. Como resultado, se observó que la relación entre la humedad del suelo y el NDVI presentó una correlación débil, con valores de R^2 que oscilaron entre 0.46 y 0.11. De manera similar, la relación entre la humedad del suelo y el NDWI también fue débil, con valores de R^2 entre 0.47 y 0.09. Sin embargo, la relación entre el NDVI y el NDWI mostró una mayor correspondencia, con valores de R^2 que oscilaron entre 0.61 y 0.98, lo que evidencia una asociación más fuerte entre ambos índices espectrales.

Una investigación relacionada con el uso del NDWI fue desarrollada por Carlo Ríos (2023) en Perú, específicamente en el distrito de Nuevo Chao, departamento de La Libertad. El estudio tuvo como finalidad clasificar imágenes satelitales mediante el Índice de Agua de Diferencia Normalizada (NDWI), aplicado al cultivo de arándanos, con el propósito de analizar las condiciones climáticas asociadas a sus diferentes etapas de crecimiento, especialmente aquellas relacionadas con la humedad del suelo. Para ello, se utilizaron imágenes Sentinel-2 obtenidas mediante Google Earth Engine (GEE), las cuales fueron descargadas y procesadas posteriormente en la plataforma LandViewer. Entre los principales resultados, la investigación reportó una precisión del 93 % en la clasificación y detección de los distintos periodos de crecimiento del cultivo. No obstante, el autor señala que pudieron presentarse errores de clasificación durante la etapa de cosecha, debido a que esta no ocurre de manera uniforme en toda el área cultivada, lo que pudo generar zonas o puntos blancos dentro de las imágenes analizadas.

1.3 Alcances y limitaciones

1.3.1 Alcances

El alcance de esta investigación comprende el desarrollo, entrenamiento y evaluación de un modelo predictivo temporal basado en aprendizaje automático supervisado (Random Forest y XGBoost) para

estimar y mapear el Índice de Estrés Termo-Hídrico (*IETH*) con un mes de anticipación ($T \rightarrow T + 1$). Geográficamente, el estudio se circunscribe al departamento de Santa Ana, El Salvador, delimitando un Área de Interés (AOI) mediante límites administrativos oficiales.

Desde el enfoque agronómico, el modelado se centra en áreas asociadas a cultivos estratégicos para la región, principalmente granos básicos como maíz y frijol, así como café y caña de azúcar, considerando su relevancia productiva y su vulnerabilidad ante condiciones de sequía, déficit de humedad y variabilidad térmica. Metodológicamente, el estudio abarca la integración, depuración y armonización multitemporal de datos correspondientes al período 2016–2025, provenientes de tres fuentes principales: precipitación mensual estimada mediante CHIRPS (*Climate Hazards Group InfraRed Precipitation with Station data*), un conjunto de datos que combina información satelital infrarroja con registros de estaciones meteorológicas para generar estimaciones de lluvia; Temperatura de la Superficie Terrestre (*LST*) obtenida del sensor Sentinel-3 SLSTR; e Índice de Humedad de Diferencia Normalizada (*NDMI*), derivado de imágenes Sentinel-2 L2A corregidas atmosféricamente. A partir de estas variables, la investigación busca identificar patrones espaciales y temporales asociados al estrés hídrico y térmico de la vegetación, con énfasis en periodos críticos como la canícula intraestival.

1.3.2 Limitaciones

- Ausencia de mediciones directas de humedad del suelo: La investigación no dispone de sensores in situ para validar directamente la humedad en la zona radicular, por lo que utiliza índices satelitales como NDMI y NDWI como variables proxy del estado hídrico del cultivo.
- Cobertura nubosa en época lluviosa: La presencia recurrente de nubosidad en imágenes ópticas de Sentinel-2 reduce la disponibilidad de observaciones válidas durante meses críticos del ciclo agrícola, obligando a aplicar filtros de calidad y selección de escenas.
- Diferencias de resolución espacial entre fuentes: Las variables utilizadas provienen de sensores con resoluciones distintas, como CHIRPS, Sentinel-3 y Sentinel-2, por lo que fue necesario armonizarlas en una malla común. Esta decisión mejora la integración de datos, pero limita la interpretación del resultado a la escala espacial definida por la malla maestra.
- Variabilidad en prácticas agrícolas locales: La heterogeneidad en fechas de siembra, variedades utilizadas, manejo de suelo y disponibilidad de riego introduce incertidumbre en la relación entre las señales satelitales y el comportamiento real de cada parcela.

1.4 Objetivos

1.4.1 Objetivo general

Evaluar la susceptibilidad al estrés termo-hídrico en zonas agrícolas del departamento de Santa Ana,

El Salvador, mediante el procesamiento de imágenes satelitales, variables agrometeorológicas y técnicas de aprendizaje automático supervisado, con el propósito de estimar anticipadamente el Índice de Estrés Termo-Hídrico (IETH) y apoyar la toma de decisiones en cultivos estratégicos como maíz, frijol, café y caña de azúcar.

1.4.2 Objetivos específicos

- Calcular índices espectrales asociados al vigor y humedad de la vegetación, tales como NDVI, NDWI y NDMI, con el fin de caracterizar la dinámica fenológica e hídrica de los cultivos estratégicos analizados.
- Construir el Índice de Estrés Termo-Hídrico (IETH) a partir de la integración normalizada de variables térmicas e hídricas, estableciendo rangos de interpretación asociados a niveles de alerta agrícola.
- Estimar el cultivo dominante probable en zonas agrícolas mediante patrones fenológicos derivados de índices espectrales, variables climáticas y características espaciales.
- Entrenar y comparar modelos de aprendizaje automático supervisado, como Random Forest y XGBoost, bajo una arquitectura de rezago temporal ($T \rightarrow T + 1$), para estimar el nivel de estrés termo-hídrico del mes siguiente.
- Evaluar el desempeño predictivo de los modelos mediante métricas de regresión como el coeficiente de determinación (R^2), el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE), complementando el análisis con la clasificación posterior de los valores de IETH en niveles de alerta.
- Analizar las predicciones del modelo en función de los cultivos fenológicamente estimados para facilitar la interpretación agrícola de los resultados.

CAPÍTULO 2. MARCO TEÓRICO

2.1 Agrometeorología y dinámica de la sequía en el corredor seco

La delimitación cronológica del modelo encuentra su fundamento biológico en las guías técnicas agropecuarias del Centro Nacional de Tecnología Agropecuaria y Forestal “Enrique Álvarez Córdova” (CENTA, 2018), las cuales identifican al mes de julio como la ventana temporal más crítica para el cultivo de maíz de primera (*Zea mays* L.) en la región de Santa Ana. Durante este periodo, la planta realiza la transición de su fase vegetativa a la reproductiva a través de las etapas fenológicas VT (Floración Masculina o Panojado) y R1 (Floración Femenina o Emergencia de Estigmas).

De acuerdo con la literatura agronómica, el éxito del rendimiento del grano depende estrictamente de la sincronía mecánica entre la liberación del polen en VT y la receptividad de los estigmas o ‘pelos del elote’ en R1. No obstante, esta transición coincide estacionalmente con el fenómeno de la canícula intraestival en El Salvador, exponiendo al cultivo a un severo riesgo hidroclimático.

En este escenario, las variables seleccionadas para el modelo computacional capturan la firma física del estrés en tiempo real. Por un lado, valores elevados en la Temperatura de la Superficie Terrestre (*LST*) actúan como un indicador de estrés térmico radical, provocando la desecación prematura y muerte del polen antes de lograr la fertilización del óvulo. Por otro lado, un descenso drástico en el índice de Humedad Foliar (*NDMI*), derivado del déficit de precipitación, induce un retraso en la emergencia de los estigmas (R1). Esta discordancia temporal, conocida técnicamente como asincronía floral, interrumpe el proceso de polinización y genera un aborto masivo de granos, dando como resultado mazorcas vanas o con un llenado deficiente. Por lo tanto, la capacidad del algoritmo para modelar el Índice de Estrés Termo-Hídrico (*IEETH*) en esta ventana específica dota al sistema de un valor predictivo estratégico para salvaguardar la seguridad alimentaria local (CENTA, 2018).

2.1.1 La Canícula Intraestival

Dentro del contexto climático de El Salvador, la canícula, asimismo denominada ‘veranillo’, se define meteorológicamente como una reducción significativa pero temporal en los volúmenes de precipitación dentro de la estación lluviosa. En la zona occidental del país, este fenómeno ocurre de manera recurrente entre los meses de julio y agosto, siendo modulado por la intensificación de los vientos alisios del noreste y el fortalecimiento del Sistema de Alta Presión del Atlántico Norte (Ministerio de Medio Ambiente y Recursos Naturales [MARN], 2021).

La relevancia de este fenómeno para el agroecosistema de Santa Ana radica en su predictibilidad variable e intensidad. La canícula no implica una ausencia absoluta de lluvia, sino una de transición hacia días secos consecutivos combinados con una alta radiación solar global. Esta combinación ace-

lera las tasas de evaporación directa desde el suelo y de transpiración por parte del cultivo, alterando el balance hídrico justo en el momento en que las demandas fisiológicas de la planta alcanzan su punto máximo.

2.1.2 Tipología de la Sequía

Para fundamentar un sistema predictivo automatizado, es imperativo estructurar los límites teóricos entre las diferentes fases evolutivas de una sequía, debido a que el fenómeno transiciona de forma multidimensional. La literatura científica reconoce una progresión secuencial que inicia con la sequía meteorológica, definida estrictamente como un déficit prolongado de precipitación respecto a la media histórica de una región. Si este déficit persiste en el tiempo, el sistema transiciona hacia la sequía hidrológica, la cual impacta los caudales de los ríos y los niveles de los acuíferos subterráneos.

Sin embargo, el objeto de estudio de esta investigación se sitúa en la sequía agrícola. Esta tipología se manifiesta cuando la humedad disponible en la zona radicular del suelo desciende a niveles críticos, siendo insuficiente para satisfacer las demandas óptimas del cultivo. Por consiguiente, la sequía agrícola no es una de mera métrica de lluvia acumulada; representa una crisis de suministro biofísico donde interactúan las propiedades hidráulicas del suelo, las anomalías de la temperatura ambiental y la respuesta biológica de la planta. Esto justifica la necesidad de utilizar proxies satelitales híbridos capaces de medir la interacción suelo-vegetación-atmósfera de forma integrada.

2.2 La Teledetección

La teledetección es una tecnología que permite obtener información de la superficie terrestre sin necesidad de establecer contacto directo con el objeto o área de estudio. Este proceso se realiza mediante sensores remotos, instalados principalmente en satélites, drones o plataformas aéreas, los cuales registran la energía reflejada, emitida o retrodispersada por los elementos presentes en la superficie. En el contexto agrícola, la teledetección permite analizar el comportamiento de la vegetación, identificar cambios en la humedad del suelo y de la cobertura vegetal, estimar condiciones térmicas y monitorear la evolución de los cultivos a lo largo del tiempo.

En el marco de esta investigación, la teledetección constituye una base fundamental para el análisis del estrés termo-hídrico agrícola, ya que permite integrar información satelital multitemporal relacionada con índices de vegetación y humedad, como el NDVI y el NDMI, así como variables térmicas como la Temperatura de la Superficie Terrestre (*LST*). Asimismo, el uso de productos climáticos derivados de sensores remotos y estaciones meteorológicas, como CHIRPS, permite complementar el análisis mediante datos de precipitación. De esta manera, la teledetección facilita el monitoreo espacial y temporal de las zonas agrícolas, especialmente en áreas donde la disponibilidad de mediciones de campo es limitada (herrera2020).

Por tanto, la teledetección no solo permite observar la superficie terrestre, sino que también proporciona insumos cuantitativos para construir modelos predictivos orientados a la detección temprana de condiciones de estrés hídrico y térmico en cultivos.

2.2.1 Sentinel-2

El Sentinel-2 es una misión europea del programa Copernicus. Esta busca ofrecer imágenes multi-espectrales de alta resolución y amplia franja de cobertura que respalda los estudios de monitoreo terrestre del programa Copernicus. Son dos satélites idénticos en la misma órbita (Google for Developers, n.d.). La mayor ventaja del uso de este satélite es la disponibilidad de las imágenes, ya que estas se pueden descargar fácilmente desde su sitio oficial, o sino por la plataforma de Google Earth Engine (GEE). Este también tiene una revisita de 10 días entre los satélites 2A y 2B, lo que ayuda a tener una disponibilidad cíclica en una franja de tiempo muy aceptable para la investigación (Beron de la puente, 2023). Dentro de GEE, está el dataset *COPERNICUS/S2_SR_HARMONIZED* la cual cuenta con el nivel 2A, la cual ofrece las imágenes con corrección atmosférica, proporcionando reflectancia de la superficie, lo que permite análisis directos de la tierra y la vegetación. Además, está armonizado, esto significa que los datos de escenas están desplazados para que las más recientes se encuentren en el mismo rango que las más antiguas.

2.2.2 Características del Sentinel-2

Banda	Escala	Resolución Espacial	Longitud de Onda	Descripción
B1	0.0001	60 m	443.9 nm (S2A) / 442.3 nm (S2B)	Aerosoles
B2	0.0001	10 m	496.6 nm (S2A) / 492.1 nm (S2B)	Azul
B3	0.0001	10 m	560 nm (S2A) / 559 nm (S2B)	Verde
B4	0.0001	10 m	664.5 nm (S2A) / 665 nm (S2B)	Rojo
B5	0.0001	20 m	703.9 nm (S2A) / 703.8 nm (S2B)	Borde Rojo 1
B6	0.0001	20 m	740.2 nm (S2A) / 739.1 nm (S2B)	Borde Rojo 2
B7	0.0001	20 m	782.5 nm (S2A) / 779.7 nm (S2B)	Borde Rojo 3
B8	0.0001	10 m	835.1 nm (S2A) / 833 nm (S2B)	Infrarrojo Cercano (NIR)
B8A	0.0001	20 m	864.8 nm (S2A) / 864 nm (S2B)	Borde Rojo 4
B9	0.0001	60 m	945 nm (S2A) / 943.2 nm (S2B)	Vapor de Agua
B11	0.0001	20 m	1613.7 nm (S2A) / 1610.4 nm (S2B)	SWIR 1
B12	0.0001	20 m	2202.4 nm (S2A) / 2185.7 nm (S2B)	SWIR 2

Tabla 2.1 Características espectrales y espaciales de las bandas del sensor Sentinel-2 utilizadas en el análisis.

Fuente: elaboración propia.

2.2.3 Física de la Temperatura de la Superficie Terrestre (LST)

La Temperatura de la Superficie Terrestre (*LST*) se calcula a partir de los datos de radiancia térmica emitidos por la Tierra, capturados en la región del infrarrojo térmico (TIR), específicamente en la ventana espectral situada entre los $10.5 \mu\text{m}$ y los $12.5 \mu\text{m}$. El fundamento físico que vincula la *LST* con la dinámica de la sequía agrícola es el principio del balance de energía superficial y la tasa de evapotranspiración.

Cuando una zona agrícola dispone de suficiente agua útil en el suelo, la energía solar absorbida se disipa mayoritariamente en forma de calor latente mediante los procesos de transpiración del cultivo y evaporación del suelo. No obstante, bajo condiciones de estrés hídrico, las plantas activan mecanismos fisiológicos de regulación, como el cierre estomático, con el fin de evitar la deshidratación celular. Al reducirse la transpiración, disminuye el enfriamiento evaporativo y una mayor proporción de la energía solar remanente se disipa en forma de calor sensible, lo que provoca un incremento en la temperatura de la superficie. Por lo tanto, una anomalía positiva de la Temperatura de la Superficie Terrestre (*LST*), estimada mediante sensores satelitales, puede constituir una alerta térmica temprana que evidencia el agotamiento progresivo del agua en el suelo antes de que se presenten daños estructurales visibles o necrosis en el follaje.

2.2.4 Índice de Humedad de Diferencia Normalizada (NDMI)

Mientras que la Temperatura de la Superficie Terrestre (*LST*) captura el comportamiento térmico superficial, el Índice de Humedad de Diferencia Normalizada (*NDMI*) permite aproximar el estado de hidratación del dosel vegetal. Su formulación matemática aprovecha el contraste espectral entre dos regiones específicas del espectro electromagnético: el infrarrojo cercano (NIR, $\sim 0.86 \mu\text{m}$), asociado con la reflectancia de la estructura interna de las células del mesófilo en hojas sanas, y el infrarrojo de onda corta (SWIR, $\sim 1.61 \mu\text{m}$), una región altamente sensible a la absorción de energía por parte del agua líquida almacenada en los tejidos vegetales.

Al normalizar la diferencia entre la banda del infrarrojo cercano (NIR) y la banda del infrarrojo de onda corta (SWIR), un dosel vegetal con contenido hídrico adecuado tiende a absorber con mayor intensidad la radiación (SWIR) y a reflejar la radiación (NIR), lo que genera valores de (NDMI) positivos y elevados. De forma inversa, bajo condiciones de estrés hídrico, la reducción del contenido de agua en el tejido foliar y en el dosel vegetal incrementa la reflectancia en la banda (SWIR), provocando una disminución del índice hacia valores cercanos a cero o negativos. Esta caída del (NDMI) constituye un indicador indirecto de pérdida de humedad en la vegetación y puede asociarse con procesos fisiológicos como la reducción de la turgencia del cultivo, especialmente cuando el déficit hídrico persiste.

2.2.5 Índice de Agua de Diferencia Normalizada (NDWI)

Complementariamente, el Índice de Agua de Diferencia Normalizada (*NDWI*) se integra al modelo para caracterizar el entorno hídrico del agroecosistema. A diferencia del *NDMI*, el *NDWI* original utiliza la reflectancia de la banda verde visible ($\sim 0.56, \mu\text{m}$) y la banda del infrarrojo cercano (*NIR*). Esta configuración espectral está orientada a resaltar la presencia de cuerpos de agua superficiales y a diferenciar áreas con mayor disponibilidad hídrica en la superficie del terreno, especialmente en zonas agrícolas mixtas donde pueden coexistir parcelas cultivadas, suelo desnudo y superficies húmedas. Su inclusión en el conjunto de datos permite al algoritmo distinguir escenarios en los que el suelo conserva humedad residual asociada a lluvias recientes, frente a aquellos donde la superficie se encuentra seca, expuesta y con menor respuesta hídrica detectable mediante sensores remotos.

2.2.6 Índice de Vegetación de Diferencia Normalizada

El Índice de Vegetación de Diferencia Normalizada (*NDVI*, por sus siglas en inglés, *Normalized Difference Vegetation Index*) se calcula a partir de la relación entre la reflectancia del infrarrojo cercano (*NIR*) y la banda roja visible (*Red*), con el propósito de evaluar la presencia, vigor y condición fotosintética de la vegetación. Este comportamiento se debe a que una planta saludable absorbe gran parte de la radiación roja visible mediante la clorofila y refleja una alta proporción de radiación en el infrarrojo cercano. En cambio, cuando la vegetación presenta deterioro, estrés o baja actividad fotosintética, la absorción en la banda roja disminuye y la reflectancia en el *NIR* tiende a reducirse, generando valores más bajos de *NDVI* Ozyavuz et al., 2015. La fórmula para su cálculo se expresa de la siguiente manera:

$$NDVI = \frac{NIR - Red}{NIR + Red} \quad (\text{Ec. 2.1})$$

donde *NIR* corresponde a la reflectancia del infrarrojo cercano y *Red* representa la reflectancia de la banda roja visible.

2.2.7 Normalización de Variables Heterogéneas

El conjunto de datos multifuente de Santa Ana consolida variables de distinta naturaleza física, dimensiones y escalas numéricas. Mientras que la precipitación se expresa en milímetros acumulados, la Temperatura de la Superficie Terrestre (*LST*) se registra en grados Celsius y los índices espectrales, como el *NDMI* y el *NDWI*, corresponden a variables adimensionales con valores generalmente comprendidos entre -1 y 1. Debido a estas diferencias, la incorporación directa de las variables en sus magnitudes originales puede dificultar la comparación entre características y afectar la estabilidad del proceso de integración de datos. Para reducir esta heterogeneidad numérica, se aplica la normalización Min-Max, la cual transforma linealmente cada variable hacia un dominio común comprendido

entre 0 y 1, preservando la distribución relativa de los valores originales. Este procedimiento permite que las variables climáticas y espectrales sean incorporadas bajo una escala homogénea dentro del conjunto de entrenamiento, de acuerdo con la siguiente ecuación:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (\text{Ec. 2.2})$$

donde X_{norm} representa el valor normalizado, X corresponde al valor original de la variable, X_{min} es el valor mínimo observado y X_{max} el valor máximo observado dentro del conjunto de datos.

2.2.8 El Índice de Estrés Termo-Hídrico (IETH)

El Índice de Estrés Termo-Hídrico (*IETH*) constituye la variable objetivo (*target*) central de esta investigación. Su diseño se fundamenta en el principio de que la sequía agrícola no puede ser explicada de manera unidimensional, debido a que involucra tanto alteraciones térmicas como déficits de humedad en la vegetación. Por ello, el *IETH* se construye a partir de los fundamentos del *Vegetation Health Index (VHI)* propuesto por Kogan, adaptándolo como un índice compuesto que combina el estrés térmico superficial con el déficit hídrico foliar. Esta integración permite caracterizar con mayor precisión las condiciones de estrés termo-hídrico presentes en las zonas agrícolas analizadas, de acuerdo con la siguiente formulación:

$$IETH = [0.5 \times LST_{norm} + 0.5 \times (1 - NDMI_{norm})] \times 100 \quad (\text{Ec. 2.3})$$

La inclusión del término $(1 - NDMI_{norm})$ obedece a una necesidad de alineación métrica: dado que un *NDMI* elevado indica condiciones óptimas de humedad, restar este valor de la unidad invierte el sentido del indicador. De este modo, un escenario donde la *LST* maximice su valor ($LST_{norm} = 1$) y el *NDMI* alcance su punto de máxima deshidratación ($NDMI_{norm} = 0$) resultará en un *IETH* absoluto de 100 puntos, representando una crisis hidroclimática extrema. Para dotar a este índice continuo de una utilidad operativa real en la gestión de riesgos en El Salvador, los valores resultantes se clasifican de acuerdo con las siguientes reglas de negocio heurísticas:

Rango de IETH (Puntos)	Clasificación del Estrés	Equivalencia de Alerta Institucional
Menor a 35	Condición Óptima	Alerta Verde (Monitoreo Normal)
De 35 a 54.99	Estrés Leve	Alerta Amarilla (Preparación)
De 55 a 74.99	Sequía Moderada	Alerta Naranja (Movilización)
Mayor o Igual a 75	Sequía Extrema	Alerta Roja (Respuesta Crítica)

Tabla 2.2 Escala de clasificación del Índice de Estrés Termo-Hídrico y su correspondencia con las alertas institucionales.

Fuente: elaboración propia.

2.3 Machine Learning y Modelado Predictivo Temporal

La transición de una fase diagnóstica a una netamente predictiva dentro de la gestión agrícola del Corredor Seco requiere el abandono de los modelos estadísticos lineales tradicionales, los cuales carecen de la flexibilidad matemática para procesar interacciones ecológicas caóticas y no lineales. En este sentido, la presente investigación implementa el enfoque del Aprendizaje Automático (*Machine Learning*) supervisado.

2.3.1 Modelos de Aprendizaje Supervisado para Regresión

El desarrollo de un Sistema de Alerta Temprana (SAT) robusto exige que el modelado del *IETH* se ejecute mediante un enfoque de regresión continua en lugar de una clasificación directa por categorías de texto. Si el algoritmo fuera entrenado únicamente para clasificar etiquetas discretas (por ejemplo, decidir entre ‘Estrés Leve’ o ‘Sequía Moderada’), se perdería la sensibilidad matemática fina de los micro-cambios en las variables ambientales. Al modelar el *target* como un número real continuo confinado entre 0 y 100, el algoritmo conserva la capacidad de detectar tendencias marginales y sutiles evoluciones del estrés hídrico. El agrupamiento en categorías discretas se desplaza intencionalmente hacia la etapa de post-procesamiento del software, permitiendo que la toma de decisiones descansa sobre una base de datos de alta resolución cuantitativa.

2.3.2 Algoritmos de Ensamble y Árboles de Decisión

La unidad fundamental de los modelos predictivos tabulares implementados corresponde al árbol de decisión. Este tipo de modelo opera mediante particiones binarias recursivas sobre el espacio de características, con el propósito de organizar los datos en nodos cada vez más homogéneos respecto a la variable objetivo. No obstante, un árbol de decisión individual puede ser propenso al sobreajuste (*overfitting*) y presentar alta varianza ante pequeñas perturbaciones en los datos de entrenamiento. Para mitigar esta limitación, se emplean técnicas de ensamble basadas en árboles, las cuales combinan múltiples modelos individuales para construir un predictor final más robusto, estable y con mayor capacidad de generalización.

2.3.3 Diferencia entre Bagging (Random Forest) y Boosting (XGBoost)

Para garantizar la robustez científica del modelo, esta investigación plantea un estudio comparativo entre dos filosofías de ensamble contrapuestas:

- **Random Forest (Bagging):** Este algoritmo se fundamenta en el principio de *Bootstrap Aggregating*. Construye cientos de árboles de decisión de forma paralela e independiente. Cada árbol se entrena utilizando una submuestra aleatoria de los datos y un subconjunto aleatorio de variables

predictoras. La predicción final del modelo es el promedio matemático simple de todas las salidas individuales. Esta independencia estructural disminuye drásticamente la varianza global del sistema sin alterar el sesgo (Breiman, 2001).

- **XGBoost (eXtreme Gradient Boosting):** Contrario al procesamiento paralelo, XGBoost opera bajo un esquema secuencial de optimización aditiva. El algoritmo construye un árbol a la vez, donde de cada estructura nueva tiene la tarea explícita de minimizar los errores residuales (los fallos de predicción) cometidos por los árboles que le precedieron. Utiliza una función de pérdida formal y aplica el algoritmo de descenso de gradiente para calcular los pesos óptimos de las hojas en cada iteración. Adicionalmente, incluye términos de regularización de matemática L1 (Lasso) y L2 (Ridge) en su función objetivo, penalizando la complejidad estructural del modelo para evitar el sobreajuste de forma estricta (Chen & Guestrin, 2016).

2.3.4 El Principio del Rezago Temporal (Time-Lagging)

La transformación de un algoritmo descriptivo en un mecanismo de pronóstico operativo se logra mediante la implementación de ingeniería de características basada en rezagos temporales (*time-lagging*). En una estructura convencional de un *dataset* de aprendizaje automático, cada fila agrupa variables observadas en un mismo instante temporal, lo que limita el análisis a una condición simultánea o diagnóstica. Para superar esta restricción, se aplica una reestructuración matricial mediante operadores de desplazamiento temporal, permitiendo que el modelo incorpore información de periodos anteriores como variables predictoras del comportamiento futuro del índice de estrés termohídrico.

Bajo este diseño arquitectónico, el vector de características de entrada, compuesto por la precipitación, la *LST*, el *NDMI*, el *NDWI* y la elevación topográfica, se extrae e ingresa utilizando los datos de consolidados en el mes actual (Mes T). Por el contrario, la variable objetivo (el *IETH* a predecir) se desplaza cronológicamente hacia adelante, correspondiendo exactamente al nivel de estrés hídrico que se manifestará en el territorio el próximo mes (Mes $T + 1$). Esta configuración fuerza al Random Forest y al XGBoost a encontrar de los patrones precursores del presente que desencadenan la sequía futura.

2.3.5 La Fuga de Datos (Data Leakage)

La fuga de datos constituye uno de los errores metodológicos más críticos en el desarrollo de modelos predictivos aplicados a series temporales. Este problema ocurre cuando información perteneciente al futuro se incorpora, de manera directa o indirecta, en la matriz de características utilizada para entrenar el modelo en el presente. En el contexto agroclimático, el uso de una partición aleatoria convencional, como `train_test_split`, sobre registros con dependencia temporal puede generar resultados artificialmente optimistas. Por ejemplo, el algoritmo podría utilizar información climática

de meses posteriores, como agosto de un año determinado, para estimar condiciones correspondientes a meses previos, como junio del mismo año.

Bajo este escenario, el modelo podría mostrar un desempeño elevado durante la validación experimental, pero fallar en un entorno operativo real al enfrentarse a escenarios verdaderamente inéditos. Para mitigar este riesgo, la investigación adopta una arquitectura basada en rezagos temporales, representada como $T \rightarrow T + 1$, complementada con una ordenación geoespacial y cronológica previa de las series de datos antes de realizar la división entre entrenamiento y validación. Este procedimiento reduce la posibilidad de fuga de datos y permite que el modelo aprenda únicamente a partir de información disponible en periodos anteriores al evento que se desea predecir. De esta manera, las métricas de rendimiento obtenidas reflejan una evaluación más honesta, transparente y reproducible, coherente con las condiciones de operación real de un sistema de alerta temprana agrícola en el Corredor Seco de El Salvador.


CAPÍTULO 3. METODOLOGÍA

3.1 Enfoque metodológico

La presente investigación adopta un enfoque cuantitativo, aplicado y experimental, orientado al desarrollo de un modelo predictivo para la estimación del estrés termo-hídrico agrícola en el departamento de Santa Ana, El Salvador. El modelo se fundamenta en la integración de sensores remotos, datos agrometeorológicos y técnicas de aprendizaje automático, con el propósito de anticipar condiciones de riesgo asociadas a sequía agrícola. El proceso metodológico se estructuró en fases secuenciales que abarcan desde la construcción de una malla espacial de referencia y la armonización multitemporal de datos satelitales y climáticos, hasta la generación del Índice de Estrés Termo-Hídrico (*IETH*), el entrenamiento de modelos predictivos temporales, la validación de resultados y la interpretación de las variables más influyentes mediante mecanismos de explicabilidad.

Como se muestra en la Figura 3.1, la metodología propuesta se organiza en un flujo secuencial que inicia con la recopilación de datos satelitales, climáticos y geoespaciales, continúa con su procesamiento, depuración y armonización temporal, y culmina con la construcción del Índice de Estrés Termo-Hídrico (*IETH*) y el entrenamiento de modelos predictivos. Esta arquitectura permite visualizar la relación entre las fuentes de información, las etapas de transformación de datos y los componentes analíticos utilizados para estimar el riesgo de estrés termo-hídrico agrícola en el área de estudio.

Arquitectura general del flujo metodológico del modelo predictivo de estrés termo-hídrico agrícola



Fuente: elaboración propia

Figura 3.1 Arquitectura general del flujo metodológico para la integración de datos, generación del *IETH* y modelado predictivo del estrés termo-hídrico agrícola.

La estructura presentada resume las fases principales del proceso metodológico, permitiendo comprender cómo las variables provenientes de sensores remotos y fuentes climáticas son transformadas en insumos predictivos para el análisis del estrés agrícola.

3.2 Construcción y estandarización de la malla espacial de referencia

Como fase inicial en el flujo de procesamiento de datos, se desarrolló un módulo dedicado a la construcción de una dimensión espacial de referencia, implementado en el lenguaje de programación Python. El objetivo principal de este procedimiento fue estandarizar los datos geográficos crudos de la zona de estudio para conformar una malla base robusta. Esta estructura fungió como el marco de referencia sobre el cual se integraron las variables meteorológicas y los productos satelitales en las etapas subsecuentes.

3.2.1 Definición del marco de referencia y entorno de desarrollo

El procedimiento informático se diseñó para operar con abstracciones tabulares y vectoriales de alto rendimiento, delegando el procesamiento geométrico a librerías de código abierto especializadas. Para la manipulación de datos tabulares se utilizaron `Pandas` y `NumPy`, mientras que el tratamiento

de información geoespacial se apoyó en GeoPandas, Shapely y PyProj, permitiendo la gestión de geometrías, sistemas de referencia espacial, reproyecciones y operaciones vectoriales. Asimismo, cuando fue necesario trabajar con capas ráster o datos derivados de sensores remotos, se consideró el uso de Rasterio para la lectura y manipulación espacial de dichas fuentes. La arquitectura del módulo permitió asegurar que cada entidad geográfica cumpliera con restricciones de integridad espacial, consistencia geométrica y coherencia de atributos antes de ser integrada al almacén de datos intermedios de la investigación.

3.2.2 Depuración y validación geoespacial

El algoritmo implementado ejecutó un flujo secuencial estructurado metodológicamente en las siguientes subfases de control:

Ingesta y validación estructural de atributos

El proceso inició con la lectura de la malla de coordenadas original utilizando la librería especializada GeoPandas. El sistema ejecutó una validación automatizada para verificar la disponibilidad de los atributos espaciales obligatorios para el modelado posterior: longitud, latitud, código y tipo de cobertura del suelo (land cover), así como la elevación sobre el nivel del mar. Este control estricto garantizó la exclusión de registros con información geográfica incompleta antes de su ingreso al repositorio de datos.

Normalización de coordenadas y control de calidad topológica

Para mitigar errores de precisión de punto flotante, frecuentes al integrar datos provenientes de múltiples sensores satelitales, el algoritmo, apoyado en las librerías Pandas y NumPy, convirtió las métricas a un formato numérico estandarizado. Se generaron llaves espaciales mediante el redondeo de la latitud y longitud a un número predefinido de cifras decimales. Posteriormente, se realizó una verificación exhaustiva de duplicidad espacial; ante la detección de coordenadas repetidas, el sistema registró la anomalía en un informe de control de calidad (QA) y detuvo el procesamiento para evitar la propagación de sesgos topológicos.

Indexación geográfica y consolidación de la malla

Una vez garantizada la integridad física y topológica de la información, el módulo procedió a estructurar los conjuntos de datos intermedios y procesados de la investigación. Estos fueron almacenados en archivos tabulares en formato CSV y archivos de metadatos en formato JSON, diferenciando las eta-

pas de construcción de la malla espacial, generación del panel mensual, enriquecimiento de variables y consolidación del dataset operativo para el entrenamiento del modelo predictivo.

Asignación de llave primaria espacial (id_{pixel})

Tras la depuración de la malla espacial, los registros se ordenaron de forma determinista en función de su latitud y longitud mediante funciones de ordenación indexada de Pandas. A cada punto único de la cuadrícula se le asignó un identificador secuencial alfanumérico estandarizado (e.g., PX000001, PX000002). La generación de esta llave primaria fue un paso crítico, dado que optimizó el procesamiento computacional al desvincular las operaciones futuras de las coordenadas geográficas directas, lo que permitió uniones relacionales (joins) más eficientes y precisas con las series temporales.

Exportación y reporte técnico del catálogo espacial

Finalmente, el algoritmo exportó la dimensión espacial consolidada hacia el directorio de datos intermedios en archivos de formato estructurado. De manera complementaria, se compiló un reporte técnico que sintetizó las estadísticas de la malla generada: el conteo total de puntos válidos incorporados, la confirmación de unicidad espacial, el rango altitudinal (elevación mínima y máxima) del área de estudio y el inventario de las clases de cobertura del suelo de la zona procesadas.

3.3 Integración espacio-temporal y construcción del panel mensual

Una vez establecido el catálogo espacial de la zona de estudio mediante la dimensión maestra de la malla, el procedimiento metodológico subsecuente consistió en la creación de un panel de datos unificado. Este proceso integró fuentes de datos heterogéneas (precipitación, temperatura superficial terrestre e índices espectrales) y las proyectó sobre la estructura espacio-temporal común para habilitar el modelado predictivo.

3.3.1 Preprocesamiento e ingeniería de datos

La articulación de esta fase con la creación de la malla maestra presentó una dependencia estructural estricta. Mientras que la primera etapa definió el componente espacial (mediante la asignación del identificador único id_{pixel} a cada coordenada), esta fase incorporó la dimensión temporal al emparejar las observaciones históricas con el catálogo espacial a través de llaves de coordenadas con una precisión geométrica predefinida.

El algoritmo desarrollado ejecutó un flujo secuencial de preprocesamiento, el cual se dividió en dos etapas críticas:

Alineación espacial y homogeneización temporal

Alineación espacial y relacional: Las bases de datos climáticas y satelitales crudas se importaron con sus respectivas coordenadas geográficas. Para unificar la información mediante operaciones vectorizadas en Pandas, el algoritmo redondeó dichas coordenadas al mismo nivel de precisión decimal definido en la dimensión maestra y ejecutó una unión por la izquierda (left join). Este emparejamiento permitió asignar el identificador `id_pixel` oficial correspondiente a cada medición ambiental. Asimismo, se implementaron mecanismos de control para documentar aquellos registros que no se vincularon con la cuadrícula oficial.

Estandarización temporal: Las fechas de adquisición originales de los datos, caracterizadas por formatos diarios o frecuencias irregulares, se estandarizaron hacia una resolución mensual unificada (indexadas al primer día de cada mes). Esta homogeneización temporal aseguró que las lecturas provenientes de los distintos sensores satelitales y estaciones se alinearan en ventanas de tiempo comparables.

Filtrado físico y reglas de agregación de variables

Dado que los sensores satelitales y las fuentes climatológicas registraron múltiples observaciones para un mismo punto dentro de un mismo mes, se aplicaron lógicas de agregación y depuración específicas por variable:

Precipitación: Se calculó el promedio mensual. De forma condicional, se evaluó si los valores equivalentes a cero representaban una ausencia real de precipitación o una omisión de reporte, aplicando máscaras de datos faltantes mediante NumPy.

Temperatura superficial terrestre (LST): El algoritmo descartó los valores atípicos que vulneraban principios físicos, aplicando umbrales absolutos que excluyeron mediciones inferiores a -5°C o superiores a 65°C . Posteriormente, se utilizó la mediana estadística mensual para consolidar un valor representativo, mitigando así el impacto de anomalías diarias o interferencias por cobertura de nubes.

Índices de vegetación y humedad: Para los indicadores espectrales (e.g., NDVI, NDWI, NDMI), se efectuó un estricto control de rango que excluyó matemáticamente los valores fuera del límite teórico válido $[-1.0, 1.0]$. La agregación mensual se realizó mediante la mediana para las variables continuas y a través de la moda estadística para los descriptores categóricos.

3.3.2 Consolidación del panel mensual balanceado

Con el propósito de prevenir la discontinuidad temporal o la pérdida de registros en meses sin reportes dentro del dataset final, el módulo construyó dinámicamente una estructura matricial de referencia. Esta estructura se generó mediante el producto cartesiano de todos los identificadores de píxel contra la totalidad de los meses comprendidos dentro del rango temporal del estudio (2015-2025).

Finalmente, los subconjuntos procesados de precipitación, temperatura e índices satelitales se integraron sobre la estructura matricial generada, acoplando de manera simultánea las variables espaciales estáticas de la malla (elevación, tipo de cobertura del suelo y coordenadas geográficas). Como producto final, se exportó el panel mensual consolidado en formato tabular y se emitió un reporte de control de calidad (QA) que certificó la densidad y disponibilidad de las variables predictoras.

3.4 Integración y armonización de fuentes satelitales y climáticas

Con el propósito de fortalecer la capacidad predictiva del modelo, se desarrolló un módulo de consolidación orientado a integrar variables ambientales provenientes de sensores satelitales y repositorios climáticos globales. Este módulo incorporó información de precipitación mensual estimada mediante CHIRPS, Temperatura de la Superficie Terrestre (*LST*) derivada de Sentinel-3 SLSTR e índices espectrales generados a partir de imágenes Sentinel-2. El procedimiento permitió armonizar fuentes de distinta naturaleza espacial y temporal, consolidando los datos en una estructura tabular coherente para su posterior análisis, generación del *IETH* y entrenamiento de los modelos predictivos.

3.4.1 Ingesta y depuración de repositorios satelitales

El algoritmo inició con la lectura sistemática del repositorio base mensual y las distintas matrices de datos externos exportadas. Como primer paso de transformación, se implementó una rutina de depuración (data cleansing) estructurada mediante operaciones en Pandas. Este proceso descartó automáticamente los atributos de metadatos residuales y columnas de control geográfico no operativas (e.g., variables de indexación interna del motor de Google Earth Engine), garantizando que las estructuras tabulares mantuvieran exclusivamente la información predictiva y las llaves de identificación necesarias.

3.4.2 Uniones relacionales y consolidación de la matriz enriquecida

Tras la estandarización estructural, se procedió a la consolidación de la información sobre la base de datos principal. Para ello, se ejecutaron sucesivas uniones relacionales (operaciones de tipo Left Join). El emparejamiento entre matrices se realizó utilizando una clave primaria compuesta bidimensional: el identificador topológico de la coordenada (*id_píxel*) y la estampa temporal estandarizada

(fecha_mes). Esta rigurosa vinculación garantizó que cada medición externa se proyectara exactamente en la ubicación física y el mes cronológico correspondiente, manteniendo intacta la continuidad espacio-temporal del repositorio.

Lógica de priorización y selección de predictores definitivos

Debido a la disponibilidad de múltiples fuentes para la medición de una misma variable física, fue imperativo diseñar un mecanismo condicional de selección para evitar la redundancia analítica. Mediante la evaluación condicional vectorizada de NumPy (`np.where`), el sistema aplicó un algoritmo de jerarquización de fuentes basado en la fiabilidad del sensor:

Precipitación Mensual: Se estableció como fuente principal el producto satelital CHIRPS. Exclusivamente en los registros donde este vector presentó valores nulos o ausentes (representados matemáticamente como NaN), el sistema imputó el valor histórico de precipitación original como medida de respaldo.

Temperatura Superficial Terrestre (LST): Se priorizó la temperatura diurna provista por el sensor MODIS como variable primaria para la estimación del estrés agrícola. Las observaciones faltantes fueron suplidas secundariamente por los registros originales validados en las etapas previas del proyecto.

Índices Espectrales (NDMI, NDWI, NDVI, entre otros): El sistema favoreció el cómputo armonizado proveniente de Sentinel-2. Aquellos registros carentes de cobertura satelital por este sensor se rellenaron con los índices espectrales basales preexistentes.

Durante este proceso, el algoritmo generó características descriptivas adicionales (flags) destinadas a documentar la fuente exacta de la cual se extrajo la lectura final, proveyendo total trazabilidad a nivel de fila y variable.

Auditoría y control de calidad del repositorio enriquecido

Como fase de cierre del módulo, se implementó una auditoría automatizada. El algoritmo cuantificó el nivel de completitud de las variables definitivas agrupadas por fecha, construyendo un panel estadístico que evaluó la disponibilidad de los predictores clave frente al total de puntos de la malla. Los resultados fueron almacenados en un reporte de control de calidad (QA), mientras que la estructura matricial consolidada fue exportada hacia el directorio de datos intermedios. Dicho repositorio enriquecido constituyó el insumo de entrada validado para las subsecuentes fases de aprendizaje automático.

3.4.3 Normalización paramétrica y prevención de sesgo temporal

El proceso algorítmico inició con la importación y el ordenamiento topológico y cronológico de la matriz enriquecida. Con el objetivo de prevenir la transferencia de sesgos de información futura (data leakage) durante la estandarización de las variables, se implementó una normalización paramétrica acotada. Se definió una ventana temporal de calibración estricta, limitando el marco histórico hasta una fecha umbral de normalización preestablecida. Sobre este subconjunto aislado, el algoritmo extrajo los percentiles 1 y 99 correspondientes a la Temperatura Superficial Terrestre (LST) y al Índice Normalizado de Humedad (NDMI). Utilizando operaciones lógicas de NumPy, estos parámetros de corte fueron aplicados universalmente para escalar las magnitudes al rango continuo $[0, 1]$, atenuando de forma robusta la influencia analítica de los valores extremos.


3.4.4 Cálculo del índice objetivo y construcción de la variable futura

A partir de las características normalizadas, se programó la derivación del Índice de Estrés Termo-Hídrico concurrente ($IETh_t$). La formulación matemática ponderó de manera equitativa la contribución térmica normalizada (LST_{norm}) y el déficit hídrico calculado como $(1 - NDMI_{norm})$. El cociente resultante fue proyectado al intervalo continuo de $[0, 100]$ y segmentado informáticamente en cuatro niveles de alerta discreta (Verde, Amarilla, Naranja y Roja), fundamentados en umbrales de riesgo agronómico.

Dado que el propósito sistémico de la investigación radica en la alerta temprana, fue indispensable derivar una variable de respuesta futura. Mediante la ejecución de operaciones de desplazamiento relacional espacial (shift) agrupadas por coordenada en Pandas, el sistema indexó el nivel de estrés proyectado para el mes cronológico posterior. Este cruce relacional generó la variable predictiva $IETh_{t+1}$, vinculando los factores ambientales del periodo actual con la condición de estrés inminente.

La Figura 3.2 resume el desplazamiento temporal aplicado para vincular las condiciones ambientales del periodo actual con el nivel de estrés termo-hídrico del mes posterior.

Desfase temporal para la predicción del IETH



El modelo vincula las condiciones del periodo actual con el estrés termo-hídrico del mes siguiente.

Figura 3.2 Esquema del desplazamiento temporal para la generación de la variable objetivo $IETH_{t+1}$.

Fuente: elaboración propia.

3.4.5 Ingeniería de características: predictores dinámicos y anomalías

Para proveer a los modelos de contexto temporal y de un marco de referencia estacional, se ejecutó una rutina de ingeniería de características (Feature Engineering). Inicialmente, la variable categórica del mes de adquisición fue sometida a una codificación cíclica continua, implementando transformaciones trigonométricas (seno y coseno) de NumPy que garantizan una representación algorítmica ininterrumpida de los ciclos anuales.

Posteriormente, se generaron rezagos históricos (Lag_1 y Lag_2) para las variables meteorológicas y los descriptores espectrales. A partir del cálculo de las diferencias absolutas entre el periodo actual y sus rezagos, se determinaron los gradientes de cambio mensual, derivando indicadores determinantes como la variación térmica (ΔLST) y la tasa de desecación temporal ($\Delta NDMI$). De forma complementaria, mediante la aplicación de ventanas de agregación móvil (rolling windows), se construyeron acumulados trimestrales de precipitación para aproximar la memoria hídrica del suelo. Finalmente, el algoritmo calculó la media climatológica histórica agrupada por mes y extrajo las anomalías individuales midiendo la desviación de cada registro frente a su norma climática.

Depuración analítica y exportación de la matriz de diseño

Como fase conclusiva de este módulo metodológico, se instauró un filtro de sanidad algorítmica para determinar la viabilidad de entrenamiento de cada vector de información. Se instituyó una máscara

lógica binaria orientada a validar la coexistencia estricta de la variable de predicción ($IETH_{t+1}$) y el bloque de características obligatorias (tales como la LST, el NDMI y las precipitaciones). Los registros que presentaron valores nulos en dichos tensores predictivos críticos fueron catalogados como no modelables y se excluyeron de manera sistemática de la estructura matricial.

El conjunto de datos operativo final, depurado de inconsistencias y carencias de continuidad, fue exportado hacia la carpeta de datos procesados de la investigación. De forma complementaria, se generó un archivo de metadatos en formato JSON, cuyo propósito fue documentar los elementos necesarios para reconstruir el proceso de generación del dataset. Este archivo registra la fórmula utilizada para calcular el Índice de Estrés Termo-Hídrico ($IETH$), los valores mínimos y máximos empleados para normalizar la Temperatura de la Superficie Terrestre (LST) y el Índice de Humedad de Diferencia Normalizada ($NDMI$), así como los umbrales definidos para clasificar el índice en los niveles de alerta Verde, Amarilla, Naranja y Roja. En el caso del dataset operativo, también se almacena la fecha de referencia utilizada para estimar los parámetros de normalización, evitando incorporar información futura dentro del proceso de entrenamiento. De esta manera, los metadatos funcionan como un mecanismo de trazabilidad metodológica, ya que permiten identificar bajo qué condiciones fue construido el dataset y facilitan la reproducibilidad del experimento de modelado predictivo.

3.5 Entrenamiento y evaluación de modelos predictivos temporales

Una vez consolidada la matriz de diseño en el repositorio operativo, la siguiente fase de la investigación consistió en el entrenamiento y evaluación de algoritmos de aprendizaje automático para la proyección del estrés agrícola. El objetivo central fue modelar las relaciones complejas y no lineales entre los predictores espacio-temporales y la variable objetivo futura ($IETH_{t+1}$). Todo el procesamiento informático se orquestó en lenguaje Python, haciendo uso de Pandas para la estructuración de particiones y NumPy para las operaciones matriciales vectorizadas de evaluación.

3.5.1 Configuración y ajuste de algoritmos de aprendizaje automático

Se seleccionaron e implementaron dos arquitecturas de modelado avanzado basadas en ensambles de árboles de decisión. Inicialmente, se implementó el algoritmo de Random Forest mediante la librería Scikit-Learn. Este modelo se configuró para reducir el sobreajuste (overfitting) mediante la limitación de la profundidad máxima de ramificación y la restricción estocástica de características evaluadas por nodo, procesando las estimaciones en paralelo.

Posteriormente, se implementó una arquitectura de potenciación del gradiente extremo utilizando la librería XGBoost. Este segundo modelo fue configurado con una función objetivo de reducción del error cuadrático medio e hiperparámetros de regularización (L1 y L2) para penalizar la complejidad

estructural. Para optimizar su convergencia computacional iterativa, el algoritmo integró una técnica de detención temprana (early stopping), deteniendo el entrenamiento si la métrica de pérdida no presentaba mejoras significativas sobre el conjunto de validación tras un número predefinido de iteraciones.

3.5.2 Evaluación multidimensional: Regresión numérica y clasificación de alertas

Las predicciones continuas generadas por ambos algoritmos fueron acotadas algorítmicamente por NumPy al intervalo válido de $[0, 100]$. La evaluación del desempeño se estructuró de forma bidimensional. En primer lugar, se calcularon métricas de regresión estándar frente al subconjunto de prueba, destacando el Error Absoluto Medio (MAE), la Raíz del Error Cuadrático Medio (RMSE), el Coeficiente de Determinación (R^2) y el Sesgo direccional (BIAS).

En segundo lugar, para alinear la evaluación con los requerimientos operativos de un sistema de alerta temprana, las proyecciones continuas se discretizaron en cuatro niveles jerárquicos categóricos (Verde, Amarilla, Naranja y Roja). Se construyeron matrices de confusión y se derivaron métricas de exactitud de alerta, midiendo tanto los aciertos exactos como aquellos con desviación de un solo nivel de severidad. De manera crítica, el sistema cuantificó informáticamente la tasa de subestimaciones y sobreestimaciones críticas (desviaciones de dos o más niveles respecto a la realidad), penalizando así los errores que podrían comprometer la toma de decisiones agronómicas. Finalmente, las métricas unificadas y los modelos optimizados fueron serializados y almacenados en formato persistente para su posterior explotación operativa.

Cuantificación del error numérico y distribución de residuales

El proceso de evaluación inició con el análisis del error continuo entre la variable objetivo real ($IETh_{t+1}$) y las estimaciones emitidas por cada modelo. Las estimaciones fueron acotadas matemáticamente al intervalo válido de $[0, 100]$ mediante operaciones vectorizadas. Posteriormente, a través del módulo de métricas de Scikit-Learn, se calcularon indicadores de regresión estándar: el Error Absoluto Medio (MAE), la Raíz del Error Cuadrático Medio (RMSE), el Coeficiente de Determinación (R^2) y el Sesgo Direccional Promedio (BIAS).

Con el propósito de identificar la magnitud de las desviaciones extremas del modelo, se ejecutó un análisis de la distribución de los residuales absolutos sobre el conjunto de prueba. Para ello, se calculó la diferencia absoluta entre el valor real del Índice de Estrés Termo-Hídrico futuro ($IETh_{t+1}$) y la predicción generada por el modelo XGBoost. Los resultados evidenciaron que el 50

De forma complementaria, el modelo obtuvo un error absoluto medio (MAE) de 4.92 puntos, una raíz del error cuadrático medio ($RMSE$) de 6.65 puntos y un coeficiente de determinación (R^2) de

0.9125 sobre el conjunto de prueba, lo que confirma un desempeño predictivo consistente para la estimación mensual del *IETH*.

Discretización y evaluación de exactitud en niveles de alerta

Para alinear los resultados estadísticos con la utilidad operativa de un sistema de alerta temprana, fue imperativo evaluar la capacidad de los modelos para categorizar correctamente el nivel de riesgo. Se implementó una rutina en NumPy (`np.select`) para discretizar los vectores continuos de predicción y realidad en cuatro rangos de alerta, fundamentados en umbrales de severidad predefinidos: Verde $[0, 35)$, Amarilla $[35, 55)$, Naranja $[55, 75)$ y Roja $[75, 100]$.

A cada categoría se le asignó un identificador numérico secuencial (de 0 a 3). Restando el vector de niveles reales del vector de niveles predichos, se derivó una métrica de distancia de error categórico. Esto permitió computar la tasa de exactitud absoluta (diferencia igual a cero) y la tasa de acierto tolerado (desviación máxima de un nivel, $\leq |1|$). Crucialmente, el algoritmo cuantificó los fallos de alta gravedad operativa, definidos como sobreestimaciones críticas (predicción de dos o más niveles por encima de la realidad) y subestimaciones críticas (proyección de dos o más niveles por debajo del riesgo materializado).

La discretización operativa del índice se presenta en la Figura 3.3, donde se muestran los umbrales utilizados para convertir el valor continuo del IETH en categorías de alerta.




Figura 3.3 Discretización del Índice de Estrés Termo-Hídrico (IETH) en niveles de alerta operativa.

Fuente: elaboración propia.

3.5.3 Análisis estratificado espacio-temporal

Para garantizar que el desempeño global no estuviese enmascarando deficiencias locales o estacionales, se ejecutó un análisis de rendimiento estratificado. Utilizando las funciones de agrupamiento (`groupby`) de Pandas, el repositorio de predicciones fue particionado sistemáticamente a través de múltiples dimensiones:

Temporalidad: Se calcularon las métricas agrupando los registros por mes calendario (`mes_target`) y

por año (anio_target), permitiendo observar la estabilidad del modelo frente a distintas fases de los ciclos fenológicos y anomalías interanuales.

Espacialidad y Cobertura: El conjunto de datos fue segmentado según las clases categóricas de cobertura del suelo (land_cover_type), evaluando si la reflectancia de los bosques o pastizales inducía mayores márgenes de error estadístico.

Condición Concurrente: Se extrajeron métricas aisladas agrupadas por la alerta real calculada, identificando así posibles sesgos del modelo en los extremos de la distribución (por ejemplo, tendencia a subestimar en condiciones de sequía severa).

Evaluación específica del dominio agrícola (Cropland)

Dado que el propósito central de la investigación recae en el monitoreo del estrés hídrico de índole agrícola, se implementó un subproceso de evaluación dedicado exclusivamente a la categoría de uso de suelo Cropland. El algoritmo aisló este subconjunto de píxeles y recalculó integralmente la batería de métricas de regresión y clasificación. Los resultados de esta partición focalizada, junto con las métricas del análisis estratificado y la distribución de residuales, fueron exportados en formato tabular unificado, conformando el soporte cuantitativo definitivo para la justificación científica de la elección del modelo óptimo.

3.6 Comparación de experimentos y selección del modelo definitivo

Como etapa decisiva en la construcción del sistema de alerta temprana, se desarrolló un módulo computacional orientado a comparar rigurosamente múltiples configuraciones de modelado. El propósito fundamental fue determinar la mejor arquitectura predictiva y evaluar el impacto real de incluir características autorregresivas en la matriz de diseño.

3.6.1 Diseño de escenarios experimentales de inferencia

Para determinar la viabilidad operativa y la capacidad de anticipación del sistema, se diseñaron y ejecutaron dos escenarios experimentales independientes. El primer experimento se estructuró incluyendo el Índice de Estrés Termo-Hídrico del periodo concurrente ($IETH_t$) como predictor directo dentro de la matriz de características. El segundo escenario, en contraste, excluyó deliberadamente esta variable para forzar a los algoritmos a inferir el estrés futuro ($IETH_{t+1}$) apoyándose de manera exclusiva en las mediciones meteorológicas y los índices espectrales derivados de los sensores satelitales. De ambos repositorios se extrajeron las proyecciones generadas por las arquitecturas de Random Forest y XGBoost.

3.6.2 Cuantificación y contraste de métricas de desempeño

La evaluación comparativa inició con la ingesta y validación estructural de los archivos de inferencias correspondientes a las particiones temporales de validación y prueba. Mediante las funciones de agrupación de la librería Pandas, el algoritmo calculó las métricas de regresión continua (Error Absoluto Medio o MAE, RMSE, R^2 , BIAS) y las métricas de clasificación discreta de alertas. De manera estricta, el análisis de desempeño fue estratificado computacionalmente en dos niveles: uno para el dominio global de la cuadrícula espacial y otro focalizado exclusivamente en los registros catalogados como zonas de vocación agrícola (Cropland).

Para visibilizar la contribución del índice concurrente, se construyó una estructura tabular de contraste directo. Dicha matriz calculó la diferencia absoluta y la variación porcentual del MAE emparejando los modelos análogos de ambos escenarios. Este proceso permitió cuantificar la ganancia o pérdida real de desempeño derivada de la supresión de la variable autorregresiva.

3.6.3 Regla de decisión heurística para la selección del modelo

Para garantizar la objetividad algorítmica en la selección del modelo definitivo, se implementó una regla de decisión heurística automatizada, fundamentada de manera exclusiva en el rendimiento sobre el subconjunto de validación. La partición de prueba fue preservada estrictamente como mecanismo de confirmación retrospectiva. El criterio matemático de selección evaluó el Error Absoluto Medio (MAE) global bajo un esquema de penalización relativa.

Se estableció un umbral de tolerancia porcentual del 5.0 %. El algoritmo comparó el mejor modelo entrenado sin el índice actual ($IETH_t$) frente al modelo de mejor rendimiento que sí lo incluía. Si el algoritmo independiente del índice presentaba una degradación del error relativa menor o igual al umbral especificado, el sistema seleccionaba esta versión. Esta regla se implementó para favorecer arquitecturas con una menor dependencia autorregresiva y mayor claridad operativa en el entorno de producción, siempre y cuando no comprometieran significativamente la precisión predictiva. Finalmente, el dictamen algorítmico, las razones de selección y las métricas confirmatorias fueron serializados y almacenados de forma persistente en un archivo de metadatos (formato JSON), estableciendo el fundamento formal para la subsecuente fase de consolidación y despliegue.

3.7 Consolidación y empaquetado del modelo definitivo

Como culminación de la fase de modelado predictivo, se desarrolló un módulo algorítmico destinado a la consolidación del modelo seleccionado. El propósito de esta etapa metodológica fue aislar la arquitectura de aprendizaje automático de mayor rendimiento y empaquetarla junto con sus especificaciones operativas, estableciendo un artefacto analítico listo para su despliegue en el sistema de

alerta temprana. El procedimiento fue codificado íntegramente en el lenguaje Python, integrando las librerías nativas json y shutil para la manipulación de archivos y transferencia de datos, así como la librería Joblib para la gestión de objetos serializados en memoria.

3.7.1 Ingesta de criterios de decisión y resolución analítica

El proceso algorítmico inició con la lectura automatizada del documento de decisión (formato JSON) generado en la etapa de evaluación comparativa previa. A partir de este registro, el sistema extrajo los hiperparámetros de la recomendación analítica: el nombre del experimento seleccionado, la arquitectura algorítmica óptima (e.g., ensamble de XGBoost) y la directriz booleana referente a la inclusión o exclusión de la variable autorregresiva concurrente ($IETh_t$). Con base en estas directrices, el algoritmo resolvió dinámicamente las rutas absolutas dentro del repositorio de almacenamiento intermedio para localizar el archivo del modelo específico a consolidar.

3.7.2 Validación estructural del espacio de características

Previo a su transferencia definitiva, se implementó una estricta rutina de validación estructural. Utilizando la librería Joblib, el objeto binario del modelo candidato fue cargado en la memoria computacional para inspeccionar su diccionario de propiedades internas. El algoritmo verificó exhaustivamente la matriz de diseño configurada (feature_columns). De manera crítica, si la regla de decisión estipulaba una arquitectura independiente del índice actual, el sistema evaluó que la variable $IETh_t$ se encontrara matemáticamente excluida del vector de características. Cualquier incongruencia detectada en esta fase detenía el procesamiento y emitía una excepción de error, previniendo así el paso a producción de un modelo con dimensiones de entrada incorrectas.

3.7.3 Serialización persistente y generación del manifiesto operativo

Una vez superada la validación estructural, el archivo binario del modelo fue duplicado sistemáticamente hacia el directorio raíz de producción mediante operaciones nativas del sistema operativo. De forma simultánea y complementaria, el algoritmo generó un Manifiesto Operativo (un archivo de metadatos estandarizado).

Dicho manifiesto almacenó de forma persistente las especificaciones funcionales del modelo, incluyendo la marca temporal de creación en formato UTC, la arquitectura seleccionada, el listado exacto de variables predictoras, los umbrales numéricos definidos para los niveles de alerta y las métricas obtenidas durante las etapas de validación y prueba, tales como el Error Absoluto Medio (MAE) y el coeficiente de determinación (R^2). Asimismo, el archivo registró explícitamente la resolución espacial utilizada, correspondiente a una malla aproximada de 1 km, y el horizonte temporal de predicción definido bajo el esquema $t \rightarrow t + 1$. La generación de este manifiesto permitió fortalecer la trazabili-

dad, reproducibilidad e interpretación del modelo predictivo, asegurando que los módulos posteriores de inferencia e interfaz de usuario utilizaran la misma configuración metodológica y operativa del experimento.

3.8 Explicabilidad del modelo y generación de atribuciones SHAP

Con la finalidad de dotar al sistema de alerta temprana de interpretabilidad analítica y superar la limitación intrínseca de opacidad (black-box) de los modelos de potenciación del gradiente, se implementó un módulo dedicado a la extracción de explicaciones matemáticas. El objetivo fue cuantificar la contribución individual de cada variable ambiental sobre la estimación final del índice de estrés. El desarrollo informático se orquestó empleando el lenguaje Python, ejecutando manipulaciones matriciales con Pandas y NumPy, y extrayendo las contribuciones algorítmicas mediante las funciones nativas de la librería XGBoost.

3.8.1 Reconstrucción relacional del espacio de características

El procedimiento inició con la ingesta automatizada del modelo definitivo consolidado y del archivo tabular contentivo de las predicciones del subconjunto de prueba. Dado que la explicabilidad requiere la matriz exacta de predictores que originó la inferencia, el algoritmo ejecutó una operación de enriquecimiento de datos. Haciendo uso de Pandas, se realizó una unión relacional (Left Join) contra el repositorio analítico operativo, utilizando como llaves primarias compuestas el identificador espacial (id_pixel) y la estampa temporal (fecha_mes).

Posteriormente, el sistema reconstruyó dinámicamente las variables derivadas, tales como los componentes trigonométricos de la estacionalidad (seno y coseno del mes) y la codificación binaria (one-hot encoding) del tipo de cobertura vegetal. Como medida estricta de control de calidad, se instituyeron validaciones automatizadas para asegurar la ausencia de valores nulos o registros duplicados, garantizando la perfecta alineación entre la matriz de inferencia original y el espacio de características reconstruido.

3.8.2 Cálculo de contribuciones locales (Valores SHAP) y validación de integridad

Para la atribución matemática de las decisiones del modelo, se empleó el enfoque de Explicaciones Aditivas de Shapley (SHAP, por sus siglas en inglés). La matriz de características validada se transformó en una estructura matricial de referencia optimizada (DMatrix de XGBoost). Invocando el motor computacional subyacente del modelo mediante el parámetro de contribuciones predictivas (pred_contribs=True), el sistema calculó los valores SHAP locales para cada vector de la matriz.

Este proceso produjo una matriz extendida que cuantificó el impacto direccional (positivo o negativo)

de cada predictor, además de aislar el valor base (esperanza matemática del modelo). Para certificar la consistencia del cálculo, se ejecutó una auditoría de reconstrucción mediante NumPy: se validó informáticamente que la sumatoria del valor base y el vector completo de valores SHAP de una fila fuera matemáticamente equivalente a la proyección continua original emitida por el modelo ($P_{base} + \sum_{i=1}^n SHAP_i \approx \hat{Y}$). Adicionalmente, el algoritmo calculó la importancia global de cada variable obteniendo la media absoluta de los valores SHAP a lo largo de todo el repositorio, exportando dicha jerarquía hacia el directorio de metadatos.

3.8.3 Cuantificación de la confianza operativa heurística

En el contexto de un sistema de alerta temprana, proveer un margen de certidumbre es tan crítico como la proyección misma. Por consiguiente, se diseñó e implementó un algoritmo para cuantificar la "Confianza Operativa" de cada inferencia. Esta métrica se estructuró como una clasificación heurística fundamentada en los errores históricos (Error Absoluto Medio o MAE), absteniéndose de interpretarse como una probabilidad estadística pura.

El algoritmo extrajo de forma matricial el error histórico global del modelo, el error específico asociado al mes calendario proyectado (MAE_{mes}), y el error vinculado al tipo de cobertura vegetal analizada ($MAE_{cobertura}$). Se determinó el umbral de error máximo esperado como el valor superior de esta terna. Simultáneamente, se midió la distancia matemática absoluta entre la predicción continua y los límites de las categorías de alerta predefinidos, correspondientes a [35.0, 55.0, 75.0]. Invocando lógicas condicionales vectorizadas, el sistema asignó niveles de confianza (Alta, Media o Baja): una inferencia se penalizaba con una confianza Baja si el error esperado superaba la distancia hacia el límite de la siguiente categoría de riesgo, sugiriendo una alta susceptibilidad a falsos positivos o negativos por oscilaciones del error algorítmico.

3.8.4 Traducción semántica y estructuración para inferencia

Como fase conclusiva de este módulo, los tensores matemáticos abstractos fueron transformados en estructuras de datos semánticamente comprensibles. Para cada registro espacial, el algoritmo iteró sobre las contribuciones SHAP, clasificando los impactos como factores que "aumentan el riesgo" (valores positivos) o "reducen el riesgo" (valores negativos). El sistema aisló los tres factores dominantes de cada espectro, emparejándolos con un diccionario de etiquetas descriptivas amigables (e.g., relacionando `LST_final.Celsius` con "temperatura superficial").

Finalmente, esta información fue consolidada en dos formatos de almacenamiento persistente. Por un lado, se exportó una matriz tabular CSV enriquecida con los factores de influencia; por otro lado, se serializó un repositorio en formato JSON Lines (.jsonl). Este último documento integró la coordenada espacial, el pronóstico, la confianza operativa y los factores interpretados, fungiendo como el reposi-

torio de datos de entrada directa para la orquestación contextual del Agente de Inteligencia Artificial desarrollado en etapas posteriores de la investigación.

3.9 Validación agronómica e interpretación de las explicaciones

Concluida la fase de generación de explicaciones locales para cada inferencia del modelo, se implementó un módulo analítico orientado a validar la coherencia agronómica subyacente en el espacio de decisiones del algoritmo. El objetivo primario de esta etapa fue examinar si los patrones de atribución matemática correspondían lógicamente a los principios físicos del estrés termo-hídrico, descartando relaciones espurias inducidas por el aprendizaje automático. El procedimiento se programó íntegramente en Python, apoyándose en la computación vectorizada de NumPy, las uniones relacionales de Pandas y las herramientas de interpretabilidad nativas de XGBoost.

3.9.1 Análisis de direccionalidad global y correlación de atribuciones

Para evaluar si el modelo interpretó de manera fidedigna la dinámica ambiental (sin afirmar causalidad estricta), se desarrolló una rutina para cuantificar la "dirección observada" de cada variable predictora. Mediante el uso de Pandas, las observaciones de cada característica fueron segmentadas en cuartiles, aislando el subconjunto de valores bajos (inferiores al percentil 25, Q_{25}) y el subconjunto de valores altos (superiores al percentil 75, Q_{75}).

Sobre estas particiones, el algoritmo promedió las contribuciones SHAP correspondientes y calculó el coeficiente de correlación de rango de Spearman entre los valores de la característica y sus impactos algorítmicos. Con base en esta estadística, el sistema catalogó el comportamiento empírico de cada factor, permitiendo documentar conclusiones deterministas, tales como verificar si los valores altos en el índice de humedad ($NDMI$) consistentemente reducían el nivel proyectado del Índice de Estrés Termo-Hídrico ($IETH_{t+1}$).

3.9.2 Estratificación y selección de casos agrícolas de estudio

Dada la focalización de la investigación en la estimación temprana del estrés termo-hídrico agrícola, se procedió a aislar metodológicamente el dominio espacial correspondiente a zonas de vocación agrícola (*Cropland*). Con el propósito de disponer de casos de estudio cualitativos para su interpretación agronómica, el conjunto de predicciones fue particionado según el nivel categórico de alerta estimada: Verde, Amarilla, Naranja y Roja.

Por cada estrato de severidad, se calculó el error absoluto medio y se seleccionaron dos tipos de registros. En primer lugar, se identificaron los casos representativos, correspondientes a aquellos registros cuya desviación se aproximó a la mediana del error dentro de su grupo, por lo que reflejan el com-

portamiento típico del modelo. En segundo lugar, se extrajeron los casos difíciles, definidos como aquellos escenarios que presentaron el error absoluto máximo dentro de su categoría, permitiendo evidenciar los límites operativos del modelo predictivo ante condiciones de mayor complejidad.

Para ambos conjuntos, se identificaron jerárquicamente las variables que contribuyeron en mayor medida al incremento del riesgo, así como aquellas que actuaron como factores atenuantes. Este análisis permitió complementar la evaluación estadística del modelo con una lectura interpretativa de los casos agrícolas más relevantes.

3.10 Implementación funcional de AgroAlerta

A partir del modelo predictivo desarrollado y validado en las fases anteriores, se construyó AgroAlerta como una implementación funcional orientada a facilitar la consulta, interpretación y comunicación de los resultados generados por el modelo. Esta plataforma fue concebida como una capa de interacción sobre el modelo predictivo, integrando las estimaciones mensuales del Índice de Estrés Termo-Hídrico (*IETH*), los niveles de alerta asociados y mecanismos de explicación que permiten comprender los factores ambientales que influyen en cada predicción. En este sentido, AgroAlerta no sustituye al modelo ni modifica su lógica de inferencia, sino que actúa como un medio para traducir los resultados técnicos en información accesible para usuarios, investigadores y actores vinculados al monitoreo agrícola.

3.10.1 Propósito de la implementación

El propósito principal de AgroAlerta fue demostrar la aplicabilidad operativa del modelo predictivo en un entorno de consulta interactiva. Para ello, la implementación permitió seleccionar puntos específicos del territorio, consultar periodos mensuales de análisis y obtener una estimación del nivel de estrés termo-hídrico proyectado. De esta manera, la plataforma sirvió como mecanismo de validación funcional, al permitir que las predicciones generadas por el modelo fueran consultadas de forma estructurada y contextualizada, evitando que los resultados permanecieran únicamente como archivos tabulares o métricas aisladas de evaluación.

3.10.2 Integración del modelo predictivo en el servicio de inferencia

La integración funcional del modelo se realizó mediante un servicio de inferencia encargado de recibir los parámetros de consulta, recuperar las variables correspondientes al punto y periodo seleccionado, ejecutar la predicción y devolver una respuesta estructurada. Este servicio permitió conectar el modelo entrenado con los datos operativos del proyecto, conservando la misma configuración metodológica utilizada durante el entrenamiento, incluyendo el horizonte temporal de predicción $t \rightarrow t + 1$, las variables de entrada definidas y los umbrales de clasificación de alerta. Como resultado, cada consulta

generó una salida compuesta por el valor estimado del *IETH*, la categoría de alerta correspondiente y los elementos explicativos asociados a la predicción.

3.10.3 Interfaz de consulta y visualización de resultados

La interfaz de AgroAlerta fue diseñada para permitir la exploración de los resultados del modelo de manera sencilla y orientada al usuario. A través de esta capa de presentación, se habilitó la selección de identificadores espaciales, fechas de análisis y puntos del territorio asociados a la malla de referencia. La interfaz permitió visualizar la predicción del *IETH*, el nivel de alerta generado y los principales factores que incidieron en el resultado. Esta etapa facilitó la interpretación de la información producida por el modelo, al presentar los resultados en un formato más comprensible que el dataset original y más cercano a un escenario de uso aplicado.

3.10.4 Asistente conversacional inteligente

Como complemento a la consulta estructurada, AgroAlerta incorporó un asistente conversacional inteligente orientado a responder preguntas sobre los resultados del modelo, los factores de riesgo identificados y el comportamiento de las variables explicativas. Este componente fue diseñado para operar sobre información previamente generada y validada, por lo que no calcula directamente el *IETH* ni reemplaza el proceso de inferencia del modelo predictivo. En cambio, consulta las predicciones disponibles, los datos asociados al punto seleccionado y las explicaciones generadas por el análisis de importancia de variables, produciendo una respuesta en lenguaje natural para facilitar la comprensión del resultado.

El flujo de interacción del agente de inteligencia artificial se resume en la Figura 3.4. Este esquema evidencia que el componente conversacional no calcula directamente el *IETH*, sino que consulta predicciones previamente generadas, herramientas internas y datos validados antes de producir una respuesta en lenguaje natural.




Figura 3.4 Flujo simplificado de interacción del agente de inteligencia artificial integrado en AgroAlerta.

Fuente: elaboración propia.

CAPÍTULO 4. ANÁLISIS DE RESULTADOS

En este capítulo se presentan los resultados obtenidos a partir de la extracción, armonización e integración de datos geoespaciales y variables agrometeorológicas. Estos resultados constituyen la base analítica para la construcción del conjunto de datos utilizado en el modelado predictivo del estrés termo-hídrico agrícola.

Dentro del análisis se distinguen dos componentes complementarios. El primero corresponde a la caracterización agrícola del territorio, mediante la cual se asignó una categoría de cultivo a cada unidad espacial de análisis a partir de patrones fenológicos y datos espectrales. El segundo corresponde al modelado predictivo del Índice de Estrés Termo-Hídrico (*IETH*), orientado a estimar el nivel de riesgo del mes siguiente a partir de variables climáticas, térmicas, espectrales y geoespaciales.

En este sentido, la clasificación fenológica de cultivos no constituye el resultado final del modelo, sino una etapa de apoyo para evaluar si la información agrícola contextual mejora la predicción del *IETH* o, en su defecto, si aporta principalmente a la interpretación agronómica de las alertas generadas.

4.1 Consolidación de las Series Temporales e Histórico de Variables

Como resultado de la ejecución de las rutinas de descarga y de preprocesamiento descritas en la metodología, se logró consolidar un repositorio de datos estructurado que abarca un horizonte temporal continuo de diez años, específicamente para el período comprendido entre 2016 y 2025.

El procesamiento de las imágenes de Sentinel-2 Nivel 2A permitió construir una serie limpia de valores de NDMI, habiendo superado los filtros de nubosidad restrictivos (menores al 30-40 %) aplicados durante los meses críticos del invierno salvadoreño. Asimismo, las series de precipitación de CHIRPS remuestreadas a 1 km y las matrices térmicas de Celsius derivadas de Sentinel-3 SLSTR quedaron alineadas de forma geométrica exacta sobre el Área de Interés (AOI) de Santa Ana.

4.2 Estructuración del Dataset Final de Predicción Agrícola

El resultado del cruce espacial mediante el algoritmo de muestreo por coordenadas (Coordinate Sampling) derivó en la creación de un dataset tabular unificado, optimizada para el algoritmo Random Forest y modelos de Gradient Boosting.

A través del procesamiento del índice NDVI correspondiente al año completo de análisis 2024, calculadas de forma representativa mediante agregaciones quincenales promedio y enmascaradas con los rásters fenológicos de cultivos de maíz y frijol provenientes de la plataforma ASIS del MARN, se obtuvo un dataset estructurado.

La matriz de entrada resultante quedó normalizada y organizada bajo la siguiente arquitectura de campos de datos por cada registro espacial (píxel):

ATRIBUTO	Tipo de Dato	Descripción Técnica
Id.píxel	Alfanumérico	Identificador único espacial del nodo indexado a 1 km.
Latitud	Numérico (Float)	Coordenada geográfica de control del centroide del píxel.
Longitud	Numérico (Float)	Coordenada geográfica de control del centroide del píxel.
Tipo.siembra	Categorico	Clasificación del cultivo según ciclo productivo detectado.
NDVI_Q1	Numérico (Float)	Valor promedio del índice de vigor en la primera quincena.
Dias.siembra_Q1	Numérico (Int)	Tiempo cronológico acumulado desde el inicio del ciclo en Q1.
NDVI_Q2	Numérico (Float)	Valor promedio del índice de vigor en la segunda quincena.
Dias.siembra_Q2	Numérico (Int)	Tiempo cronológico acumulado desde el inicio del ciclo en Q2.

Tabla 4.1 Estructura analítica de registros de la matriz de predicción agrícola

Fuente: elaboración propia.

Esta matriz de datos resultante refleja fielmente la dinámica espaciotemporal de la fenología local en el departamento, incorporando la asincronía de la siembra primera y postrera, sirviendo de pilar analítico para los procesos de validación de hiperparámetros y evaluación de precisión de los modelos predictivos.

4.3 Evaluación de la Coherencia Intra-anual y Dinámica de Rotación de Cultivos

La integración exitosa de la variable `Bandera_Cultivo` en el dataset multi-temporal permitió estructurar el análisis en dos dimensiones críticas: la variabilidad fenológica intra-anual (estacionalidad) y la dinámica de cambio inter-anual (uso del suelo). En primera instancia, los resultados demostraron una robusta consistencia de lógica interna al evaluar el comportamiento del Índice de Vegetación de Diferencia Normalizada (NDVI) mes a mes para una misma coordenada.

Las observaciones asociadas a la bandera de “Granos Básicos”, a pesar de compartir la misma clasificación durante todo el ciclo, reflejaron numéricamente las fases biológicas esperadas: de valores mínimos de NDVI inferiores a 0.25 durante los meses de enero y febrero (correspondientes al periodo de rastrojo y suelo expuesto post-cosecha) y picos máximos simétricos superiores a 0.75 en los meses de julio y octubre, lo cual coincide con la madurez foliar de las siembras estacionales de primera y postrera documentadas para la región occidental de El Salvador (Vintrou et al., 2012). Este comportamiento valida el diseño metodológico, demostrando que la asignación de una etiqueta anual no enmascara la variabilidad espectral del cultivo, sino que le otorga de un marco de interpretación agronómica correcto.

En segunda instancia, la estructura multi-anual del dataset facilitó la identificación geográfica de los patrones de rotación de cultivos y la transición en el uso de la tierra. Debido a que la clasificación DTW evalúa de forma independiente de cada año de calendario para un mismo punto coordenado,

el modelo fue capaz de capturar las decisiones de manejo agrícola inter-anales. Como se observa en los registros históricos analizados, diversas parcelas transicionaron de manera abrupta entre categorías; por ejemplo, coordenadas que entre los años 2017 y 2019 mantuvieron una firma representativa de “Granos Básicos” modificaron su comportamiento espectral a partir del año 2020, siendo reclasificadas de forma automática bajo la bandera de “Caña de Azúcar”. Este fenómeno responde a la expansión de monocultivos agroindustriales estables en las llanuras de transición de El Salvador, un patrón de cambio de cobertura que ha sido extensamente señalado en la literatura como un factor de transformación del paisaje agrario centroamericano (Yan & Roy, 2015).

4.4 Evaluación del aporte de la clasificación fenológica de cultivos

Con el propósito de evaluar si la clasificación fenológica de cultivos aportaba valor predictivo al modelo de estimación del Índice de Estrés Termo-Hídrico (*IETH*), se diseñó un experimento comparativo entre dos configuraciones equivalentes. El Modelo A fue entrenado sin incorporar la variable de cultivo fenológico estimado, mientras que el Modelo B incluyó dicha variable como atributo adicional dentro del conjunto de predictores. Ambos modelos utilizaron las mismas particiones de entrenamiento, validación y prueba, compuestas por 97,216 registros para entrenamiento, 21,837 registros para validación y 31,030 registros para prueba. Esta configuración permitió comparar ambos escenarios bajo condiciones homogéneas, evitando sesgos asociados a diferencias en la distribución de los datos.

La incorporación del cultivo fenológico estimado tuvo como finalidad determinar si la respuesta diferenciada de cultivos agrícolas estratégicos, como maíz, frijol, café y caña de azúcar, podía mejorar la capacidad del modelo para anticipar el estrés termo-hídrico del mes siguiente. En este sentido, la variable fenológica fue evaluada no solo como un posible predictor adicional, sino también como un mecanismo de contextualización agronómica para interpretar las alertas generadas por el modelo.

Como se muestra en la Figura 4.1, la evaluación se estructuró a partir de dos configuraciones del modelo predictivo. La primera excluye la variable de cultivo fenológico estimado, mientras que la segunda la incorpora como atributo adicional. Esta comparación permite determinar si la fenología estimada mejora el desempeño predictivo o si su utilidad se concentra principalmente en la interpretación posterior de los resultados.

Comparación de configuraciones del modelo predictivo de IETH




Figura 4.1 Esquema comparativo del modelo predictivo de *IETH* con y sin cultivo fenológico estimado.

Los resultados de la Tabla ?? evidencian que la incorporación del cultivo fenológico estimado generó una mejora marginal durante la fase de validación. El Modelo B presentó una ligera reducción del MAE, de 4.7395 a 4.6996, y del RMSE, de 6.3705 a 6.3489. Asimismo, el coeficiente de determinación aumentó de $R^2 = 0.9171$ a $R^2 = 0.9177$, mientras que la exactitud en la clasificación de alertas pasó de 0.8044 a 0.8069. No obstante, estas mejoras fueron reducidas y no se mantuvieron durante la fase de prueba.

En el conjunto de prueba, el Modelo B no superó al Modelo A. El MAE aumentó levemente de 4.9172 a 4.9183, el RMSE pasó de 6.6538 a 6.6707 y el coeficiente de determinación disminuyó de $R^2 = 0.9125$ a $R^2 = 0.9120$. De igual forma, la exactitud en la clasificación de alertas se redujo de 0.8092 a 0.8071, mientras que la subestimación crítica aumentó ligeramente de 0.0011 a 0.0012. La variación porcentual del MAE en prueba fue de -0.0218

A partir de estos resultados, se concluye que la clasificación fenológica de cultivos no debe considerarse un componente indispensable para maximizar el desempeño cuantitativo del modelo predictivo. Sin embargo, su valor metodológico se mantiene desde una perspectiva interpretativa, ya que permite analizar las predicciones del *IETH* en función de cultivos agrícolas estratégicos y facilita una lectura agronómica más comprensible de las alertas. Por tanto, la fenología estimada se conserva como una

variable de contextualización y análisis, pero no como un factor determinante para la selección del modelo predictivo final.

4.5 Análisis exploratorio de modelos estratificados por cultivo

Como análisis complementario, se evaluó un enfoque de modelado estratificado por tipo de cultivo, con el propósito de explorar si la respuesta del estrés termo-hídrico podía capturarse de manera diferenciada entre categorías agrícolas. Este experimento no sustituyó al modelo predictivo general seleccionado, sino que permitió analizar el comportamiento del algoritmo Random Forest al segmentar el dominio agrícola en grupos específicos, particularmente Granos Básicos y Caña de Azúcar. En la Tabla 4.2 se presentan las métricas obtenidas para este análisis exploratorio, considerando el error absoluto medio, la raíz del error cuadrático medio y el coeficiente de determinación.

Tipo de Cultivo (Bandera)	Coeficiente de Determinación (R^2)	MAE	RMSE
Granos Básicos	0.4036	9.03 puntos de IETH	11.24 puntos de IETH
Caña de Azúcar	0.3452	9.68 puntos de IETH	11.86 puntos de IETH

Tabla 4.2 Métricas de rendimiento del algoritmo Random Forest por tipo de cultivo

Fuente: elaboración propia.

El análisis comparativo de las métricas revela que el modelo orientado a Granos Básicos alcanzó un coeficiente de determinación ($R^2 = 0.4036$), explicando el 40.36 % de la variabilidad del estrés hídrico del mes subsiguiente. Por su parte, el modelo enfocado en Caña de Azúcar reportó un $R^2 = 0.3452$ (34.52 % de varianza explicada). Si bien estos coeficientes se consideran moderados dentro del aprendizaje estadístico general, en el ámbito de la agrometeorología satelital y el pronóstico temporal predictivo a escala de píxel son valores altamente competitivos. Esto se debe al “ruido” intrínseco de las series de tiempo ópticas causado por píxeles mixtos y microclimas variables (Kuhn & Johnson, 2013).

La verdadera robustez operacional del sistema se evidencia en los errores absolutos. El modelo de Granos Básicos demostró un MAE de apenas 9.03 puntos en la escala de 0 a 100 del IETH, mientras que la Caña de Azúcar registró un MAE de 9.68 puntos. Mantener el error medio por debajo de 10 puntos de diferencia absoluta valida la viabilidad del modelo como una herramienta predictiva institucional, superando las imprecisiones de los modelos climáticos de resolución gruesa que suelen promediar de forma homogénea las áreas de ladera y valles en El Salvador (Funk et al., 2019).

4.6 Jerarquía e Importancia de los Factores Físicos de la Sequía

La extracción de la importancia de variables (*feature importance*) expuso de manera empírica que los detonantes del estrés termo-hídrico operan bajo dinámicas físicas completamente distintas según el agroecosistema analizado. La Tabla 4.3 expone de mayor a menor el peso relativo que los árboles de decisión asignaron a cada variable predictora.

Rango	Granos Básicos		Caña de Azúcar	
	Variable Predictora	Peso Relativo (%)	Variable Predictora	Peso Relativo (%)
1°	precipitacion	27.54 %	LST_Celsius	26.82 %
2°	NDMI	27.48 %	mes_actual	20.48 %
3°	LST_Celsius	24.17 %	NDMI	19.55 %
4°	mes_actual	8.65 %	elevacion_msnm	12.19 %
5°	elevacion_msnm	6.23 %	precipitacion	11.41 %
6°	NDWI	5.93 %	NDWI	9.55 %

Tabla 4.3 Importancia relativa de las variables predictoras en el algoritmo Random Forest

Fuente: elaboración propia.

En el modelo de Granos Básicos, la dinámica está dominada de forma casi equitativa por el suministro inmediato de agua líquida a través de la precipitacion (27.54 %) y el contenido de humedad foliar medido por el NDMI (27.48 %). Agronómicamente, esto describe la altísima vulnerabilidad de los cultivos transitorios (como el maíz y el frijol), los cuales poseen sistemas radiculares superficiales y dependen por completo de la regularidad de las lluvias cortas para evitar el marchitamiento (Vogel et al., 2019).

Por el contrario, el modelo de Caña de Azúcar invierte las prioridades físicas. El factor dominante es el estrés térmico directo representado por la temperatura superficial (LST_Celsius, 26.82 %), seguido estrechamente por el factor cronológico estacional (mes_actual, 20.48 %). La variable precipitacion cae a un quinto lugar de importancia (11.41 %). Esta jerarquía describe con precisión la biología de un cultivo semi-perenne; la caña de azúcar cuenta con raíces profundas capaces de extraer agua de estratos inferiores del suelo, lo que la vuelve inmune a la falta de lluvia a corto plazo. No obstante, se muestra altamente sensible al calor extremo acumulado en el aire y al ciclo calendario que gobierna los periodos críticos de maduración y la quema controlada previa a la zafra (Inman et al., 2018).

4.7 Validación del Sistema de Alerta Temprana en Escenarios de Canícula

La utilidad metodológica de haber diseñado modelos predictivos independientes quedó demostrada al someter un mismo escenario climático extremo por el simulador de alertas. Al ingresar variables críticas correspondientes a un fenómeno de canícula severa en el mes de julio (mes_actual = 7, precipitacion = 0.0 mm, LST_Celsius = 39.5 °C y NDMI = -0.15), el sistema proyectó res-

puestas divergentes para el mes de agosto.

Para el sector de Granos Básicos, el modelo estimó de manera proactiva un incremento severo en el índice hídrico, proyectando un IETH de 63.99/100, lo que activó de forma automática una Alerta Naranja (Sequía Moderada). Bajo exactamente las mismas condiciones meteorológicas adversas, el modelo de Caña de Azúcar proyectó un IETH de apenas 31.67/100, clasificando el escenario bajo una Alerta Verde (Condición Óptima).

Este hallazgo es el aporte operativo más significativo de la tesis para instituciones como la Dirección General de Economía Agropecuaria del MAG en El Salvador. Comprueba de forma científica que una anomalía climática uniforme no se traduce en un riesgo homogéneo en el territorio. Mientras que una canícula severa en julio interrumpe la fase crítica de floración del maíz provocando un estrés destructivo en los minifundios (Alerta Naranja), el mismo escenario térmico es tolerado por la estructura robusta de los cañaverales (Alerta Verde). Disponer de un pronóstico estratificado con 30 días de anticipación permite pasar de una gestión de desastres puramente reactiva a una distribución inteligente, eficiente y dirigida de recursos y asistencia técnica a los sectores verdaderamente vulnerables del corredor seco salvadoreño.

4.7.1 Interpretabilidad de las Predicciones

Para que un sistema de alerta temprana sea útil en contextos agrícolas, no basta con generar una predicción numérica. Es necesario explicar por qué el modelo asigna determinado nivel de riesgo a una zona específica. En este sentido, la interpretación de las variables predictoras permite identificar los factores que más influyen en el incremento o disminución del IETH.

La importancia relativa de variables permite distinguir si una alerta fue provocada principalmente por déficit de precipitación, incremento de temperatura superficial, disminución de humedad foliar, condiciones topográficas o efectos estacionales. Esta información resulta fundamental para convertir la predicción en una recomendación agronómica comprensible y accionable.

Por ejemplo, una alerta naranja en granos básicos puede explicarse por una combinación de baja precipitación reciente, reducción del NDMI y aumento de LST durante una fase fenológica sensible. En cambio, una alerta similar en caña de azúcar podría estar más relacionada con acumulación térmica y estacionalidad del cultivo. Esta diferenciación evita interpretar la sequía agrícola como un fenómeno homogéneo y permite orientar mejor las acciones preventivas según el tipo de cultivo.

CAPÍTULO 5. CONCLUSIONES Y RECOMENDACIONES

5.1 Conclusiones

La investigación demostró la viabilidad técnica y metodológica de evaluar la susceptibilidad al estrés termo-hídrico en las zonas agrícolas del departamento de Santa Ana, El Salvador, mediante un enfoque integrado de sensores remotos, datos agrometeorológicos y aprendizaje automático. La fusión de información proveniente de Sentinel-2, MODIS y CHIRPS permitió consolidar el Índice de Estrés Termo-Hídrico (IETH) como un indicador representativo de la dinámica hidroclimática local. Asimismo, el algoritmo XGBoost se consolidó como la herramienta predictiva óptima, demostrando, bajo una arquitectura de rezago temporal $T \rightarrow T + 1$, la capacidad de AgroAlerta para anticipar con un mes de anticipación escenarios críticos de vulnerabilidad agrícola.

La integración de los índices espectrales NDVI, NDWI y NDMI, extraídos de Sentinel-2, demostró ser una estrategia metodológica robusta para caracterizar el estado fisiológico de la cobertura vegetal en el departamento de Santa Ana. El análisis evidenció que, mientras el NDVI resulta eficaz para identificar variaciones en el vigor vegetativo asociadas a los ciclos estacionales, el NDMI y el NDWI poseen una sensibilidad superior para alertar sobre condiciones críticas de déficit hídrico. En consecuencia, estos índices no solo reflejan la dinámica fenológica local, sino que se consolidan como variables predictoras fundamentales para la estimación anticipada del Índice de Estrés Termo-Hídrico (IETH) dentro del modelo predictivo de AgroAlerta.

La formulación del Índice de Estrés Termo-Hídrico (IETH) demostró ser una solución matemática y metodológica eficaz para sintetizar múltiples fuentes de información satelital, relacionadas con temperatura, vigor vegetal y humedad, en una única métrica estandarizada. La escala operativa de alertas implementada, compuesta por los niveles verde, amarillo, naranja y rojo, demostró una alta sensibilidad para categorizar los niveles de afectación agrícola, transformando datos geoespaciales complejos en un instrumento de fácil interpretación para apoyar la toma de decisiones.

La evaluación comparativa de modelos de aprendizaje automático determinó que el algoritmo XGBoost constituye la herramienta óptima para la predicción del IETH con un horizonte de un mes de anticipación, superando el desempeño de Random Forest debido a su mayor capacidad para capturar relaciones no lineales complejas entre las variables hidroclimáticas, espectrales y temporales. Asimismo, la arquitectura basada en rezagos temporales demostró ser metodológicamente robusta, ya que permitió modelar la persistencia de las condiciones hidroclimáticas y prevenir la fuga de información, conocida como *data leakage*.

La evaluación cuantitativa confirmó la alta precisión y estabilidad predictiva del modelo XGBoost, el cual alcanzó un coeficiente de determinación de $R^2 = 0.9122$ y un Error Absoluto Medio (MAE) de

4.90 puntos de IETH en el conjunto de prueba. El hecho de que el algoritmo explique más del 91 % de la variabilidad del índice demuestra que el error residual es bajo para fines de análisis predictivo y apoyo a la toma de decisiones agrícolas.

La implementación de la plataforma web interactiva AgroAlerta constituye la transferencia tecnológica tangible de esta investigación, al integrar modelos complejos de aprendizaje automático en un entorno operativo de libre acceso. El sistema demostró su viabilidad para democratizar el uso de datos geoespaciales, permitiendo a productores, técnicos e instituciones agrícolas consultar pronósticos hidrológicos y visualizar alertas tempranas de forma oportuna. En consecuencia, AgroAlerta se consolida como una innovación tecnológica orientada a fortalecer la resiliencia del sector agrícola en El Salvador, evidenciando cómo la convergencia entre la ciencia de datos, la ingeniería de teledetección aplicada y el desarrollo de sistemas inteligentes puede transformar el conocimiento predictivo en un mecanismo práctico para la gestión del riesgo climático.

5.2 Recomendaciones

Se recomienda establecer un programa sistemático de validación empírica en campo, conocido como *ground-truthing*, mediante la instrumentación de parcelas piloto representativas en los municipios agrícolas clave del departamento de Santa Ana. Específicamente, se sugiere la instalación de sensores de humedad del suelo por reflectometría o capacitancia a diferentes profundidades radiculares, en combinación con el monitoreo fenológico directo de los cultivos de maíz, sorgo y caña de azúcar. Esta recolección de datos *in situ* resultará fundamental para contrastar de forma estadística los valores estimados por el Índice de Estrés Termo-Hídrico (IETH) con el estado hídrico real de la planta y del suelo.

Con el propósito de subsanar las limitaciones por cobertura de nubes que afectan a los sensores ópticos durante la época lluviosa en El Salvador, se recomienda expandir la arquitectura de datos del modelo mediante la integración de sensores de radar de apertura sintética (SAR), específicamente de la misión Sentinel-1. Esta incorporación permitiría garantizar un flujo más continuo de información sobre las condiciones de humedad superficial, la constante dieléctrica y la rugosidad del suelo, reduciendo la dependencia exclusiva de imágenes ópticas.

Asimismo, se sugiere evaluar el desempeño de los algoritmos de aprendizaje automático bajo horizontes de predicción ampliados a mediano plazo, tales como $T + 2$ y $T + 3$ meses de anticipación. Esta extensión temporal permitiría otorgar un mayor margen de maniobra operativa a los productores e instituciones, facilitando una planificación más robusta de los ciclos de siembra y una gestión anticipada de los recursos hídricos.

A nivel de transferencia tecnológica, se propone la evolución arquitectónica del asistente virtual inte-

grado en AgroAlerta mediante la implementación de un sistema de Generación Aumentada por Recuperación (RAG). Esta optimización técnica permitiría interconectar el agente conversacional con bases de conocimiento contextualizadas que alberguen guías técnicas, manuales de cultivo del CEN-TA y recomendaciones fitosanitarias del Ministerio de Agricultura y Ganadería (MAG). De este modo, el sistema no se limitaría a comunicar los niveles de riesgo derivados del modelo XGBoost, sino que también proveería asesoría técnica complementaria y personalizada en lenguaje natural, adaptando las acciones de mitigación a las necesidades específicas de los agricultores según la alerta de su zona.

Finalmente, se recomienda evaluar la viabilidad de replicar este modelo metodológico en otros departamentos pertenecientes al Corredor Seco Centroamericano en El Salvador, tales como Ahuachapán y Sonsonate, con el propósito de consolidar una red de alerta temprana regional interconectada que fortalezca la resiliencia agroalimentaria del país ante los desafíos de la variabilidad climática.

REFERENCIAS

- Asilo, S., de Bie, K., Skidmore, A., Nelson, A., & Groen, T. A. (2014). A cloud-proof cropland classification approach using multi-temporal RADARSAT-2 SAR images. *Remote Sensing*, 6(3), 2110-2133. <https://doi.org/10.3390/rs6032110>
- Belgiu, M., & Csillik, O. (2018). Sentinel-2 cropland mapping using pixel-based and object-based time-weighted dynamic time warping analysis. *Remote Sensing of Environment*, 204, 509-523. <https://doi.org/10.1016/j.rse.2017.10.005>
- Beron de la Puente, F. J., Revollo, N., & Gil, V. (2023). Clasificación inteligente de cultivos de verano en la plataforma Google Earth Engine. *Memorias de las 52 JAIIO - CAI*. <https://doi.org/10.5281/ISSN:2451-7496>
- Bhatti, M. T., Gilani, H., Ashraf, M., Iqbal, M. S., & Munir, S. (2024). Field Validation of NDVI to Identify Crop Phenological Signatures. *Precision Agriculture*. <https://doi.org/10.1007/s11119-024-10165-6>
- Bravo-Ureta, B. E., Njuki, E., Palacios, A. C., & Salazar, L. (2022). *Agricultural Productivity in El Salvador: A Preliminary Analysis* (inf. téc. N.º IDB-WP-01319). Inter-American Development Bank.
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- Centro Nacional de Tecnología Agropecuaria y Forestal. (2018). *Guía técnica: El cultivo de maíz (Zea mays L.)* (inf. téc.). Programa de Granos Básicos; Ministerio de Agricultura y Ganadería. La Libertad, El Salvador.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Foerster, S., Kuester, T., Segl, K., Kaufmann, H., Rossner, G., & Itzerott, S. (2012). Crop type classification using time-series of satellite images: A review of methodologies for agricultural monitoring. *International Journal of Remote Sensing*, 33(16), 4912-4939. <https://doi.org/10.1080/01431161.2011.641321>

for Developers, G. (n.d.). Harmonized Sentinel-2 MSI: MultiSpectral Instrument, Level-2A (SR). [Last accessed 14 June 2026]. https://developers.google.com/earth-engine/datasets/catalog/COPERNICUS_S2_SR_HARMONIZED?hl=es-419

Gómez, C., White, J. C., & Wulder, M. A. (2016). Optical remotely sensed time series data for land cover classification: A review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 116, 55-72. <https://doi.org/10.1016/j.isprsjprs.2016.03.008>

Herrera, M. S. (2020). *Correlacion entre la humedad del suelo y los indices NDVI y NDWI como indicativo del estres hidrico en el cultivo de cana de azucar (Saccharum officinarum) en la variedad BC 001220, Ingenio Taboga 2019* [Tesis de maestría, Universidad Tecnica Nacional, Costa Rica]. <https://repositorio.utn.ac.cr/items/9b084b67-8b9f-4ffd-bf67-4be2a2d824eb/full>

Jensen, J. R. (2016). *Introductory digital image processing: A remote sensing perspective* (4th). Pearson.

Kogan, F. N. (2001). Operational Space Technology for Global Agricultural Monitoring. *Bulletin of the American Meteorological Society*, 82(9), 1949-1964. [https://doi.org/10.1175/1520-0477\(2001\)082\(1949:OSTFGA\)2.0.CO;2](https://doi.org/10.1175/1520-0477(2001)082(1949:OSTFGA)2.0.CO;2)

Maus, V., Cámara, G., Cartaxo, R., Sanchez, A., Ramos, F. M., & de Queiroz, G. R. (2016). A time-weighted dynamic time warping method for land-use and land-cover classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 9(8), 3729-3739. <https://doi.org/10.1109/JSTARS.2016.2517118>

Ministerio de Agricultura y Ganadería. (2019). *Anuario de estadísticas agropecuarias 2018-2019*. Dirección General de Economía Agropecuaria del Gobierno de El Salvador.

Ministerio de Medio Ambiente y Recursos Naturales. (2021). *Monitoreo de la sequía meteorológica en el Corredor Seco de El Salvador* (inf. téc.). Servicio Meteorológico Nacional. San Salvador, El Salvador.

Organización de las Naciones Unidas para la Alimentación y la Agricultura. (2018). *Sistemas de información sobre el calendario agrícola de los cultivos en América Latina y el Caribe*. FAO.

Ozyavuz, M., Bilgili, B., & Salici, A. (2015). Determination of Vegetation Changes with NDVI Method. *Journal of Environmental Protection and Ecology*, (1). <https://doi.org/10.1080/10804034.2015.1080403>

Rios C., C., Machaca V., V., Morales S., S., S., H., & A., A. (2025). Analysis of Water Stress Using Sentinel-2 NDWI Images for Optimization of Progressive Harvest Dates in Blueberry (*Vaccinium corymbosum*) Crops: A Case Study of the Peruvian District of Nuevo Chao in the La Libertad Region. *Engineering Proceedings*. <https://www.mdpi.com/2673-4591/83/1/27>

Sánchez-Azofeifa, A., Guzmán, J. A., Campos, F. A., Castro, S., Castro-Cid, R., Sharp, I., & Calvo-Alvarado, J. (2017). Twenty-first-century remote sensing and the Study of Tropical Dry Forests. *Biotropica*, 49(5), 585-598. <https://doi.org/10.1111/btp.12463>

Vintrou, E., Soumaré, M., Bégué, A., Claden, M., & Baron, C. (2012). Mapping agricultural land use in West Africa with multi-temporal satellite data and knowledge-based decision trees. *International Journal of Applied Earth Observation and Geoinformation*, 14(1), 6-16. <https://doi.org/10.1016/j.jag.2011.08.006>

Yan, L., & Roy, D. P. (2015). Large-area crop classification and rotation mapping using temporal sequences of Sentinel-2 and Landsat data. *Remote Sensing of Environment*, 162, 112-130. <https://doi.org/10.1016/j.rse.2015.02.010>

ANEXO A
PRIMER ANEXO

ANEXO B
SEGUNDO ANEXO

ANEXO C
TERCER ANEXO

